

Tartalomjegyzék

1. Bevezető	1
1.1. Motiváció és problémafelvetés	1
1.2. A dolgozat célja	2
1.3. A dolgozat felépítése	3
2. Szakirodalom és elméleti háttér	4
2.1. A bőrrák és a korai diagnózis jelentősége	4
2.1.1. A klinikai diagnosztikai folyamat	5
2.1.2. A hozzáférés korlátai	5
2.2. Klasszikus gépi tanulás a bőrelváltozások osztályozásában	6
2.3. A mély tanulás megjelenése: konvolúciós neurális hálók	6
2.4. A Vision Transformer és a figyelmi mechanizmus	7
2.5. Az ISIC adathalmazok és versenyek	8
2.6. Multimodális nagy nyelvi modellek a bőrgyógyászatban	9
2.7. A figyelmi mechanizmus és a Transformer	10
2.8. A Vision Transformer architektúrája	10
2.9. Átviteli tanulás és finomhangolás	12
2.10. Az osztály-egyensúlytalanság kezelése	12
2.11. Kiértékelési metrikák	13
2.12. Statisztikai elemzés	14
2.13. Kommunikációs technológiák: SSE és az MCP	15

3. Kutatási rész: a bőrelváltozás-osztályozó modell	16
3.1. Az ISIC 2024 adathalmaz és előkészítése	16
3.2. A Vision Transformer modell	17
3.2.1. Kétfázisú tanítás	17
3.2.2. Az osztály-egyensúlytalanság kezelése	18
3.2.3. Adataugmentáció	18
3.2.4. Hiperparaméterek	18
3.3. A ResNet-18 viszonyítási alap	19
3.4. A Gemini zero-shot viszonyítási alap	20
3.5. Kísérleti elrendezés	20
3.6. Eredmények	21
3.6.1. A tanítás konvergenciája	21
3.6.2. A ViT teljesítménye a teszhalmazon	21
3.6.3. Összehasonlítás a viszonyítási alapokkal	23
3.6.4. Statisztikai elemzés	25
3.6.5. Az eredmények megbeszélése és korlátai	25
4. Mérnöki rész: a DermAI alkalmazás	27
4.1. Követelmények	27
4.1.1. Funkcionális követelmények	27
4.1.2. Nem-funkcionális követelmények	28
4.2. Rendszerarchitektúra	28
4.2.1. Egy elemzési kérés életciklusa	29
4.3. A modellt kiszolgáló komponens: MCP-szerver	30
4.4. A backend	30
4.4.1. Végpontok	31
4.4.2. A Gemini integrációja és a képvalidáció	31
4.4.3. Token-szintű adatfolyam (SSE)	31
4.5. A mobilalkalmazás	32

4.5.1. Hálózati réteg	32
4.6. A webes felület	32
4.7. Hitelesítés és felhőalapú adattárolás	33
4.7.1. Hitelesítés	33
4.7.2. Adatbázis és fájl tárolás	33
4.8. Hálózati robusztusság és hibátűrés	34
4.9. Biztonsági megfontolások	34
5. Összefoglalás és jövőbeli munka	36
5.1. A dolgozat eredményeinek összegzése	36
5.2. Korlátok	37
5.3. Jövőbeli fejlesztési irányok	37
Irodalomjegyzék	38
A. Függelék	43
A.1. Alfejezet	43
A.1.1. Cím	43

Ábrák jegyzéke

2.1. Az ABCDE-szabály vizuális kritériumai.	5
2.2. Reprezentatív minták az ISIC 2024 adathalmazból.	9
2.3. A Vision Transformer (ViT) sematikus felépítése.	11
3.1. A ViT modell tanításának konvergenciája: a tanítási veszteség, valamint a validációs AUC és pAUC alakulása az epochok függvényében.	21
3.2. A ViT modell ROC-görbéje a teszhalmazon, a pAUC számításához használt $TPR \geq$ 0,80 tartomány kiemelésével.	23
4.1. A DermAI rendszer magas szintű architektúrája.	29

1. fejezet

Bevezető

1.1. Motiváció és problémafelvetés

A bőrrák napjaink egyik legelterjedtebb daganatos megbetegedése. A Nemzetközi Rákkutató Ügynökség (IARC) GLOBOCAN-bebecslései szerint 2022-ben világszerte több mint 1,5 millió új bőrrákos esetet regisztráltak; ezen belül a melanomák száma megközelítőleg 331 700 volt, mintegy 58 700 halálessel [1]. Bár a melanoma a bőrrákos esetek kisebb hányadát teszi ki, a bőrrák okozta halálozás túlnyomó részéért felel, mivel a korai felismerés hiányában gyorsan áttétet képezhet, drasztikusan csökkentve a túlélési esélyeket. Az időben, még lokalizált stádiumban felismert melanoma öt éves relatív túlélési aránya közel 100%, míg távoli áttét megjelenése esetén ez mintegy 35%-ra csökken [2]. A korai diagnózis tehát nem csupán orvosi, hanem népegészségügyi szempontból is kritikus fontosságú.

A hagyományos diagnosztikai folyamat egy dermatológus által végzett vizuális vizsgálatot és dermatoszkópos értékelést foglal magában, amelyhez magas szintű szakmai tudás és speciális eszközök szükségesek. A világ számos részén, különösen vidéki térségekben és fejlődő országokban, a bőrgyógyászati szakellátáshoz való hozzáférés korlátozott, ami késedelmes diagnózishoz és rosszabb kimenetelhez vezet. Emellett még fejlett egészségügyi rendszerekben is előfordul, hogy a betegek hosszú várakozási idő után jutnak szakorvosi vizsgálatához.

A mesterséges intelligencia, azon belül a mély tanulás megjelenése új lehetőségeket nyitott a bőrelváltozások automatikus osztályozásában. Az egyik úttörő tanulmányban Esteve és munkatársai kimutatták, hogy egy konvolúciós neurális háló bőrrák-osztályozásban eléri a tapasztalt dermatológusok

szintjét [3]. Ezt követően számos kutatás megerősítette, hogy a mélytanulás-alapú rendszerek képesek megközelíteni, sőt bizonyos feltételek mellett meghaladni az emberi szakértők teljesítményét [4, 5].

Ugyanakkor ezek a rendszerek kezdetben komoly korlátokkal rendelkeztek: kizárólag dermatoszkópos, nagy felbontású klinikai felvételeken működtek megbízhatóan, amelyek elkészítéséhez speciális eszközre és szakértelemre van szükség. A szelekciós torzítás is jelentős problémaként merült fel, hiszen az elérhető adathalmazok döntően klinikailag gyanús, már szakorvoshoz kerülő elváltozásokat tartalmaztak, ami a modellek általánosíthatóságát korlátozta. A HAM10000 [6], majd az ISIC versenysorozat adathalmazai [7, 8] lényegesen bővítették az elérhető annotált képanyagot, és egy egyéges értékelési keretet biztosítottak a kutatók számára.

Az okostelefonok elterjedése és folyamatosan fejlődő kamerarendszerei új perspektívát nyitottak: a bőrgyógyászati szűrés akár közvetlenül a beteg kezébe adható eszközöket is alkalmazhat. Egy ilyen rendszer képes lenne arra, hogy a felhasználó által készített fotó alapján jelezze, ha egy elváltozás szakorvosi vizsgálatot indokolhat, csökkentve ezzel mind a késői diagnózisok számát, mind az indokolatlan orvosi viziteket.

1.2. A dolgozat célja

Jelen dolgozat egy végponttól végpontig megvalósított bőrelváltozás-elemző rendszer tervezését és implementációját mutatja be, amely az ISIC 2024 versenyzadathalmazán [8] betanított Vision Transformer (ViT) [9] modellre épül.

A rendszer fő célkitűzései a következők:

- Egy Android mobilalkalmazás fejlesztése, amely lehetővé teszi a felhasználó számára, hogy fényképet készítsen vagy töltsön fel egy bőrelváltozásról, és azonnali, AI-alapú elemzést kapjon.
- A feltöltött kép minőségének és relevanciájának automatikus ellenőrzése egy nagy nyelvi modell (Gemini) segítségével, kiszűrve az értékelhetetlen vagy nem megfelelő felvételeket.
- A bőrelváltozás osztályozása *Benignus* vagy *Malignus* kategóriába egy ViT-alapú neurális hálóval, konfidencia-értékkal kiegészítve.

- Természetes nyelvű magyarázat és orvosi szempontú visszajelzés generálása a klasszifikációs eredmény alapján, az ABCDE-szabály ¹ figyelembevételével.
- A felhasználói interakciók és a feltöltött képek biztonságos tárolása felhőalapú infrastruktúrán.

Fontos hangsúlyozni, hogy a rendszer nem helyettesíti a szakorvosi diagnózist: kizárólag tájékoztató jellegű szűrőeszközként funkcionál, amely segíti a felhasználót abban, hogy időben döntsön a dermatológiai konzultáció szükségességéről.

1.3. A dolgozat felépítése

A dolgozat a következő fejezetekre tagolódik. A **Szakirodalom és elméleti háttér** fejezet áttekinti a bőrelváltozások gépi tanulással történő osztályozásának előzményeit – a konvolúciós neurális hálólóktól a Vision Transformer megjelenéséig –, az ISIC adathalmazok fejlődését, valamint ismerteti a rendszer mögötti kulcstechnológiákat: a ViT architektúrát, a figyelmi (attention) mechanizmust, az osztály-egyensúlytalanság kezelését, a kiértékelési metrikákat, illetve a nagy nyelvi modellek és a streaming-kommunikáció elvét. A **Kutatási rész** a bőrelváltozás-osztályozó modell fejlesztését és kiértékelését tárgyalja: az ISIC 2024 adathalmaz előkészítését, a ViT betanítását, a viszonyítási alapként szolgáló ResNet-18 és Gemini modelleket, valamint a kvantitatív eredményeket és a statisztikai elemzést. A **Mérnöki rész** a DermAI rendszer megvalósítását mutatja be: a követelményeket, a rendszerarchitektúrát, a modellkiszolgálást, a backendet, a mobil- és webalkalmazást, valamint a hitelesítést és a felhőalapú adattárolást. Végül az **Összefoglalás és jövőbeli munka** fejezet a dolgozat következtetéseit és a lehetséges továbbfejlesztési irányokat foglalja össze.

¹ Aszimmetria, határvonal, szín, átmérő, evolúció – a melanoma gyanújelei.

2. fejezet

Szakirodalom és elméleti háttér

Ez a fejezet két nagyobb egységből áll. Az első rész a bőrelváltozások gépi tanulással történő osztályozásának szakirodalmi előzményeit tekinti át – a klinikai diagnosztikai gyakorlattól a klasszikus gépi tanuláson és a konvolúciós neurális hálókön át a Vision Transformer és a multimodális nagy nyelvi modellek megjelenéséig. A második rész a dolgozatban felhasznált kulcstechnológiák elméleti háttérét ismerteti.

2.1. A bőrrák és a korai diagnózis jelentősége

A bőrrák a leggyakrabban diagnosztizált rosszindulatú daganatok közé tartozik világszerte. A Nemzetközi Rákkutató Ügynökség (IARC) GLOBOCAN-bebecslései szerint 2022-ben több mint 1,5 millió új bőrrákos esetet regisztráltak, ezen belül a melanomák száma megközelítőleg 331 700 volt, mintegy 58 700 halálesettel [1]. Bár a melanoma a bőrrákos esetek kisebb hányadát teszi ki, agresszív viselkedése és áttétképző hajlama miatt a bőrrák okozta halálozás túlnyomó részéért felel.

A betegség kimenetele döntően a felismerés stádiumától függ. A még lokalizált stádiumban diagnosztizált melanoma ötéves relatív túlélési aránya közel 100%, míg távoli áttét megjelenése esetén ez mintegy 35%-ra csökken [2]. Ez a markáns különbség teszi a korai felismerést népegészségügyi szempontból kiemelten fontossá: a diagnózis néhány hónapos késedelme is jelentősen ronthatja a beteg túlélési esélyeit.

2.1.1. A klinikai diagnosztikai folyamat

A melanoma klinikai gyanúja jellemzően vizuális vizsgálat alapján merül fel, amelyet dermatoszkópos értékelés egészít ki; a végleges diagnózist minden esetben szövettani vizsgálat (hisztopatológia) erősíti meg [10]. A magas kockázatú betegek nyomon követésében a szekvenciális digitális dermatoszkópia és a teljes testfelszín fényképezése segíti a korai melanomák kiszűrését [10]. Ez a folyamat magas szintű szakmai tapasztalatot és speciális eszközöket igényel.

A pigmentált bőrelváltozások szabad szemmel történő, gyors megítélését a klinikai gyakorlatban az úgynevezett ABCDE-szabály támogatja. A betűszó a melanomára jellemző öt figyelmeztető jeget foglalja össze: aszimmetria (*Asymmetry*), szabálytalan határvonal (*Border*), színbeli heterogenitás (*Color*), 6 mm-t meghaladó átmérő (*Diameter*), valamint az elváltozás időbeli változása (*Evolving*); az utóbbi, ötödik kritériummal Abbasi és munkatársai egészítették ki az eredeti ABCD-szabályt, hangsúlyozva a fejlődő elváltozások jelentőségét [11]. Az ABCDE-szabály egyszerűsége miatt mind a szakemberek, mind a betegek számára jól használható, ugyanakkor önmagában nem helyettesíti a műszeres és szövettani vizsgálatot.

[Ábra helye] – Az ABCDE-szabály szemléltetése: jóindulatú és rosszindulatú pigmentált elváltozások összehasonlítása. (Saját vagy jogtiszta forrásból származó ábrát illessz be.)

2.1. ábra. Az ABCDE-szabály vizuális kritériumai.

2.1.2. A hozzáférés korlátai

A bőrgyógyászati szakellátáshoz való hozzáférés világszerte egyenetlen. Vidéki térségekben és alacsonyabb jövedelmű országokban a szakorvosi kapacitás korlátozott, ami késedelmes diagnózishoz vezet; de még fejlett egészségügyi rendszerekben is jelentős várakozási idővel kell számolni a szakvizsgálatig. Ez a hozzáférési szakadék motiválja az olyan automatizált, akár okostelefonon is futó szűrőeszközök fejlesztését, amelyek elsődleges triázsként jelezhetik, ha egy elváltozás szakorvosi

vizsgálatot indokol.

2.2. Klasszikus gépi tanulás a bőrelváltozások osztályozásában

A mélytanulás elterjedése előtt a bőrelváltozás-osztályozó rendszerek jellemzően kétlépcsős felépítést követtek: először kézzel tervezett jellemzőket (*handcrafted features*) nyertek ki a képből, majd ezeken egy klasszikus gépi tanulási osztályozót – például tartóvektor-gépet (SVM), döntési fát vagy véletlen erdőt (Random Forest) – tanítottak be. A jellemzők gyakran közvetlenül az orvosi szempontokat tükrözték: az ABCDE-szabályhoz kapcsolódó alaki (aszimmetria, határvonal), színbeli (színmomentumok, hisztogramok) és textúra jellemzőket (például a szürkeszintű együttes előfordulási mátrixból, GLCM számított mutatókat).

Kassem és munkatársai szisztematikus áttekintése a terület módszertani fejlődését dokumentálja, és rámutat, hogy a klasszikus, kézi jellemzőkön alapuló megközelítések teljesítményét erősen korlátozza a jellemzőtervezés minősége és a felvételi körülmények (megvilágítás, felbontás, műtermékek) iránti érzékenység [12]. Ezek a rendszerek jellemzően jól kontrollált, dermatoszkópos felvételeken működtek megbízhatóan, általánosító képességük azonban korlátozott maradt. Mindazonáltal a kézi jellemzőkön alapuló osztályozók a mai napig értékes *viszonyítási alapként* (baseline) szolgálnak, mivel gyorsak, értelmezhetők, és megmutatják, mekkora teljesítmény érhető el a reprezentáció automatikus tanulása nélkül.

2.3. A mély tanulás megjelenése: konvolúciós neurális hálók

A konvolúciós neurális hálók (CNN-ek) áttörést hoztak a képosztályozásban azzal, hogy a jellemzőkinyerést és az osztályozást egyetlen, végponttól végpontig tanítható modellbe integrálták, megszüntetve a kézi jellemzőtervezés szükségességét. A bőrgyógyászati alkalmazások egyik úttörő munkájában Esteva és munkatársai kimutatták, hogy egy nagy képadatbázison előtanított CNN a bőrrák osztályozásában eléri a tapasztalt dermatológusok teljesítményét [3]. Ezt követően több vizsgálat is megerősítette, hogy a mélytanulás-alapú rendszerek megközelíthetik, sőt bizonyos, jól körülhatárolt feladatokban meg is haladhatják az emberi szakértők teljesítményét: Haenssle és munkatársai egy

CNN-t 58 dermatológussal vetettek össze dermatoszkópos melanoma-felismerésben [4], Brinker és munkatársai pedig arról számoltak be, hogy mély neurális hálók a melanoma képi osztályozásában felülmúlták a bevont bőrgyógyászokat [5].

E rendszerek teljesítményének kulcsa az *átviteli tanulás* (transfer learning): a modelleket először egy nagy, általános képadatbázison – jellemzően az ImageNet adathalmazon [13] – tanítják be, majd a megtanult vizuális reprezentációkat a jóval kisebb orvosi adathalmazra finomítják (fine-tuning). Az architektúrák fejlődése szintén hozzájárult az eredmények javulásához: a reziduális kapcsolatokat bevezető ResNet [14] lehetővé tette a nagyon mély hálók stabil tanítását, az EfficientNet pedig a hálózat mélységének, szélességének és felbontásának együttes, kiegyensúlyozott skálázásával ért el kedvező teljesítmény-paraméterszám arányt [15].

A korai rendszerek fontos korlátja volt, hogy elsősorban dermatoszkópos, nagy felbontású klinikai felvételeken működtek megbízhatóan, amelyek elkészítéséhez speciális eszköz és szakértelem szükséges. Emellett a szelekciós torzítás is jelentős problémát jelentett: az elérhető adathalmazok döntően már szakorvoshoz került, klinikailag gyanús elváltozásokat tartalmaztak, ami tovább korlátozta a modellek általánosíthatóságát hétköznapi felvételekre.

2.4. A Vision Transformer és a figyelmi mechanizmus

A természetesnyelv-feldolgozásban bevezetett Transformer-architektúra a *figyelmi* (attention) mechanizmusra épül, amely a bemenet elemei közötti összes páronkénti kapcsolatot képes közvetlenül modellezni, függetlenül azok távolságától [16]. Ezt az elvet a képosztályozásra a Vision Transformer (ViT) ültette át: a képet rögzített méretű foltokra (*patch*) bontja, ezeket lineárisan beágyazza, majd egy Transformer-kódoló dolgozza fel őket [9]. A konvolúciós hálókkal szemben a ViT nem rendelkezik beépített képi induktív torzítással (mint a lokalitás vagy az eltolás-invariancia), így a globális összefüggéseket rugalmasabban tanulja meg, cserébe viszont jellemzően nagyobb tanítóadatra vagy erőteljes előtanításra van szüksége a jó általánosításhoz [9].

A ViT-architektúra a bőrgyógyászati képosztályozásban is megjelent. Dagnaw és munkatársai például Vision Transformer és konvolúciós modelleket vetettek össze magyarázható mesterséges intelligencia (XAI) technikákkal kiegészítve, és a ViT-alapú, illetve a CNN-alapú modellek esetében

hasznos nagyságrendű pontosságot mértek [17]. Ez a megfigyelés alátámasztja, hogy a két architektúracsatlód összevetése – pontosan kontrollált, azonos adat- és tanítási feltételek mellett – önmagában is érdemi tudományos kérdés, amelyre a dolgozat kutatási része is kitér.

2.5. Az ISIC adathalmazok és versenyek

A bőrelváltozás-osztályozás kutatását jelentősen előmozdította az annotált, nyilvánosan elérhető adathalmazok megjelenése. A HAM10000 adathalmaz 10 015, több forrásból származó dermatoszkópos felvételt tartalmaz a gyakori pigmentált elváltozásokról, és egységes kiértékelési keretet biztosított a kutatóknak [6]. A Nemzetközi Bőrképzési Együttműködés (ISIC) versenysorozata tovább bővítette az elérhető képanyagot; Rotemberg és munkatársai egy beteg-központú, a képek mellett klinikai metaadatokat is tartalmazó adathalmazt mutattak be, hangsúlyozva a klinikai kontextus szerepét a melanoma azonosításában [7].

A jelen dolgozat szempontjából kiemelt jelentőségű az ISIC 2024 verseny (*Skin Cancer Detection with 3D-TBP*), amely a teljes testfelszín háromdimenziós fényképezéséből (3D total-body photography) kivágott, mintegy 400 000 elváltozás-képet tartalmaz, és binárisan – rosszindulatú vagy jóindulatú-to-intermedier kategóriába – történő osztályozást tűz ki célul [8]. Ezek a kivágott felvételek minőségükben közelebb állnak a hétköznapi, akár okostelefonnal készíthető képekhez, mint a klasszikus, nagy felbontású dermatoszkópos felvételek, ami a valós felhasználási helyzethez közelíti a feladatot.

Az ISIC 2024 adathalmaz egyik meghatározó jellemzője a rendkívül erős *osztály-egyensúlytalanság*: a rosszindulatú esetek a teljes adathalmaznak csupán töredékét (nagyságrendileg ezredrészét) teszik ki. Ennek megfelelően a verseny nem a hagyományos pontosságot, hanem a 80%-os érzékenység (true positive rate) feletti tartományra korlátozott, részleges görbe alatti területet (partial AUC) használja elsődleges metrikaként, amely orvosi releváns módon a magas érzékenységi tartományban méri a modellek teljesítményét [8]. Az osztály-egyensúlytalanság kezelésének módszertani hátterét, valamint a kiértékelési metrikák pontos definícióját e fejezet elméleti része tárgyalja részletesen.

[Ábra helye] – Példák az ISIC 2024 adathalmazból: jóindulatú (felső sor) és rosszindulatú (alsó sor) bőrelváltozások 3D-TBP kivágott felvételei.

2.2. ábra. Reprezentatív minták az ISIC 2024 adathalmazból.

2.6. Multimodális nagy nyelvi modellek a bőrgyógyászatban

A legutóbbi években a multimodális nagy nyelvi modellek (multimodal large language models, MLLM-ek) megjelenése új lehetőségeket nyitott az orvosi képértelmezésben. Ezek a modellek – mint a Google Gemini-családja [18] – egyszerre képesek képi és szöveges bemenet feldolgozására, és természetes nyelvű magyarázatot, indoklást is tudnak generálni.

A bőrgyógyászati alkalmazásukat több vizsgálat is értékelte. Cirone és munkatársai a GPT-4 Vision és a LLaVA modelleket vetették össze melanoma és jóindulatú elváltozások megkülönböztetésében, és azt találták, hogy a GPT-4V lényegesen jobban teljesített (85% pontosság a LLaVA 45%-ával szemben), ugyanakkor mindkét modell teljesítménye érzékelhetően romlott a sötétebb bőrtónusok esetén – ami a reprezentációs torzítás kockázatára és a sokszínűbb adathalmazok szükségességére hívja fel a figyelmet [19]. Zhou és munkatársai célzottan bőrgyógyászati rendszert építettek (SkinGPT-4), amelyben egy előtanított Vision Transformert egy nagy nyelvi modellel kapcsoltak össze, és valós eseteken értékelték autonóm diagnosztikai képességét [20].

E munkák tanulsága kettős. Egyrészt a multimodális nyelvi modellek erőssége a természetes nyelvű magyarázat és a felhasználóval folytatott párbeszéd, nem pedig a megbízható, kalibrált osztályozás – különösen erős osztály-egyensúlytalanság mellett. Másrészt a teljesítményük populációk közötti egyenetlensége óvatosságra int a klinikai felhasználásban. Ezek a megfontolások közvetlenül indokolják a jelen dolgozatban követett tervezési döntést: a *klasszifikációt* egy célzottan betanított, kalibrált képi modell (ViT) végzi, míg a nagy nyelvi modell (Gemini) szerepe a kép minőségének ellenőrzésére, az eredmény közérthető magyarázatára és a felhasználói kérdések megválaszolására korlátozódik. E

munkamegosztás részletes tárgyalása és empirikus alátámasztása a dolgozat kutatási, illetve mérnöki részében található.

A fejezet hátralévő része a dolgozatban felhasznált kulcstechnológiák elméleti háttérét ismerteti: a figyelmi mechanizmustól és a Vision Transformer felépítésétől az osztály-egyensúlytalanság kezelésén és a kiértékelési metrikákon át a kliens–szerver kommunikáció technológiáig.

2.7. A figyelmi mechanizmus és a Transformer

A Transformer-architektúra alapja az úgynevezett *skálázott pontszorzatos figyelem* (scaled dot-product attention), amely a bemenet elemei közötti összefüggéseket azok távolságától függetlenül modellezi [16]. A mechanizmus minden bemeneti elemhez három vektort rendel: egy lekérdezést (Q , query), egy kulcsot (K , key) és egy értéket (V , value). A kimenet az értékvektorok súlyozott összege, ahol a súlyokat a lekérdezések és kulcsok hasonlósága határozza meg:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V, \quad (2.1)$$

ahol d_k a kulcsvektorok dimenziója; a $\sqrt{d_k}$ skálázó tényező a pontszorzatok nagyságát stabilizálja, megakadályozva a softmax telítődését. A gyakorlatban a modell több, párhuzamos figyelmi „fejet” (multi-head attention) alkalmaz, amelyek különböző reprezentációs alterekben tanulnak összefüggéseket, így gazdagabb leírást képesek megragadni [16].

A Transformer-kódoló e figyelmi rétegeket helyzetenkénti, teljesen összekötött előreccsatolt rétegekkel (feed-forward), maradék (reziduális) kapcsolatokkal és rétegnormalizálással kombinálja. Mivel a figyelem önmagában érzéketlen az elemek sorrendjére, a bemenethez *helyzetkódolást* (positional encoding) adnak, amely a sorrendi információt visszacsempészi a modellbe.

2.8. A Vision Transformer architektúrája

A Vision Transformer (ViT) a természetesnyelv-feldolgozásban bevált Transformer-kódolót ülteti át a képosztályozásra [9]. A feldolgozás lépései a következők:

1. **Foltokra bontás és beágyazás.** A $H \times W$ méretű bemeneti képet rögzített méretű, nem átfedő foltokra (jellemzően 16×16 pixel) bontja. Minden foltot vektorrá lapít, majd egy lineáris vetítés egy rögzített dimenziójú beágyazási térbe képezi – ezek a „képtokenek”, a nyelvi modellek szótokenjeinek analógiái.
2. **Osztályozó token és helyzetkódolás.** A foltbeágyazások elé egy tanulható osztályozó token ([CLS]) fűz, amely a teljes kép összegzett reprezentációját hivatott hordozni. A sorrendi (térbeli) információt tanulható helyzetkódolás biztosítja.
3. **Transformer-kódoló.** A tokensorozatot több, egymásra épülő Transformer-kódoló réteg dolgozza fel; a többfejű önfigyelem révén minden folt közvetlen kapcsolatba kerülhet az összes többivel, így a modell a kép globális összefüggéseit is megragadja.
4. **Osztályozó fej.** A végső réteg [CLS] tokenjének reprezentációjára egy osztályozó fej (jellemzően egy- vagy kétrétegű perceptron) épül, amely az osztályok feletti döntést szolgáltatja.

A konvolúciós hálókkal szemben a ViT nem rendelkezik beépített képi induktív torzítással (lokalitás, eltolás-invariancia), ezért nagyobb adatmennyiséget vagy erős előtanítást igényel; cserébe a globális összefüggéseket rugalmasabban modellezi, és nagy adathalmazokon a CNN-ekkel versenyképes vagy azokat meghaladó teljesítményt ér el [9].

[Ábra helye] – A Vision Transformer feldolgozási folyamata: a kép foltokra bontása, lineáris beágyazás, helyzetkódolás, Transformer-kódoló rétegek, valamint a [CLS] tokenre épülő osztályozó fej. (Saját szerkesztésű ábrát illessz be.)

2.3. ábra. A Vision Transformer (ViT) sematikus felépítése.

2.9. Átviteli tanulás és finomhangolás

Az orvosi képadatok jellemzően korlátozott mennyiségben állnak rendelkezésre, ami megnehezíti a nagy kapacitású modellek – különösen a ViT – nulláról történő betanítását. Az *átviteli tanulás* (transfer learning) erre kínál megoldást: a modellt először egy nagy, általános képadatbázison (jellemzően az ImageNet adathalmazon [13]) tanítják be, ahol általános vizuális reprezentációkat – éleket, textúrákat, alakzatokat – sajátít el. Az így előtanított modellt ezután a célfeladat kisebb adathalmazán *finomhangolják* (fine-tuning).

A finomhangolás során bevett gyakorlat a *differenciált tanulási ráta* alkalmazása: az előtanított törzshálót (backbone) kis tanulási rátával frissítik, hogy a megtanult reprezentációk ne sérüljenek, míg az újonnan inicializált osztályozó fejet nagyobb rátával tanítják, mivel azt a feladatra nulláról kell megtanulni. A tanulás stabilitását a *bemelegítés* (warmup) is segíti, amely a kezdeti néhány epochban fokozatosan emeli a tanulási rátát, megelőzve a hideg fej által okozott nagy, destabilizáló lépéseket.

2.10. Az osztály-egyensúlytalanság kezelése

Az orvosi szűrési feladatok jellemzően erősen kiegyensúlyozatlanok: a pozitív (beteg) esetek a teljes adathalmaznak csupán töredékét teszik ki. Ilyenkor a hagyományos keresztentropia-veszteséget a sok, könnyen osztályozható negatív példa uralja, és a modell hajlamos a többségi osztály felé torzítani. A szakirodalom több, egymást kiegészítő technikát kínál e probléma kezelésére.

Súlyozott mintavételezés. Az egyik megközelítés a tanító batch-ek osztályeloszlásának kiegyensúlyozása: minden mintát az osztálya gyakoriságával fordítottan arányos súllyal választunk, így a ritka pozitív esetek a tanítás során felülreprezentálttá válnak.

Fókuszveszteség (focal loss). A Lin és munkatársai által bevezetett fókuszveszteség a keresztentropiát úgy alakítja át, hogy a jól osztályozott példák hozzájárulását lecsökkenti, és a tanulást a nehéz, félreosztályozott esetekre összpontosítja [21]:

$$\text{FL}(p_t) = -\alpha_t (1 - p_t)^\gamma \log(p_t), \quad (2.2)$$

ahol p_t a helyes osztályhoz rendelt becsült valószínűség, $\gamma \geq 0$ a fókuszáló paraméter (amely a könnyű példák súlyát csökkenti), α_t pedig egy osztályszúly, amely a pozitív és negatív esetek közötti egyensúlyt finomhangolja. A $\gamma = 0$ választás visszaadja a súlyozott keresztentropiát.

Kétfázisú tanítás. A kiegyensúlyozott mintavételezés mellett betanított modell kimeneti valószínűségei eltérhetnek a valós, erősen kiegyensúlyozatlan előfordulási aránytól. Ezt egy második, kalibráló fázis korrigálhatja, amelyben a modellt a valós eloszlású adaton, kisebb tanulási rátával tanítjuk tovább, így a kimeneti valószínűségek a tényleges priorhoz igazodnak.

2.11. Kiértékelési metrikák

Erősen kiegyensúlyozatlan feladatban a nyers pontosság (accuracy) félrevezető, hiszen a többségi osztály triviális megjósolásával is magas érték érhető el. Ezért orvosi szűrésnél a tévesztés-mátrixból (confusion matrix) származtatott, osztályérzékeny metrikákat alkalmazunk. Jelölje TP , TN , FP és FN rendre a valódi pozitív, valódi negatív, hamis pozitív és hamis negatív esetek számát.

$$\text{Érzékenység (sensitivity)} = \frac{TP}{TP + FN}, \quad \text{Specifitás (specificity)} = \frac{TN}{TN + FP}, \quad (2.3)$$

$$\text{PPV} = \frac{TP}{TP + FP}, \quad \text{NPV} = \frac{TN}{TN + FN}. \quad (2.4)$$

Az **érzékenység** azt méri, hogy a modell a valóban rosszindulatú eseteknek mekkora hányadát ismeri fel – szűrőeszköznél ez a legkritikusabb mutató, mivel a fel nem ismert rák (hamis negatív) a legsúlyosabb kimenetel. A **negatív prediktív érték** (NPV) azt fejezi ki, hogy a „jóindulatú” besorolás mennyire megbízható.

ROC-görbe és AUC. A bináris osztályozók döntési küszöbtől független értékelésére a *működési jelleggörbét* (Receiver Operating Characteristic, ROC) használjuk, amely a valódi pozitív arányt (érzékenység) a hamis pozitív arány ($FPR = FP / (FP + TN)$) függvényében ábrázolja a küszöb változtatásával. A görbe alatti terület (Area Under the Curve, AUC) egyetlen számba sűríti a rangsorolási képességet: értéke 0,5 (véletlen találgatás) és 1,0 (tökéletes elkülönítés) között mozog.

Részleges AUC (pAUC). Erős egyensúlytalanságnál és klinikai kontextusban gyakran csak a görbe egy meghatározott szakasza érdekes. Az ISIC 2024 verseny elsődleges metrikája a 80%-os érzékenység feletti tartományra korlátozott részleges AUC (partial AUC), amely kifejezetten a klinikailag elvárt, magas érzékenységi tartományban méri a teljesítményt; a metrika értéke $[0, 0,2]$ tartományba esik, ahol 0,2 a tökéletes osztályozó értéke [8].

Kalibráció és Brier-pontszám. A jó rangsorolás (magas AUC) nem garantálja, hogy a modell által kiadott valószínűségek megbízhatóak. A *kalibráció* azt méri, hogy a becsült valószínűségek mennyire felelnek meg a tényleges bekövetkezési aránynak; Guo és munkatársai rámutattak, hogy a modern neurális hálók gyakran rosszul kalibráltak [22]. A kalibráció egyik összegző mérőszáma a Brier-pontszám, a becsült valószínűség és a tényleges címke közötti átlagos négyzetes eltérés:

$$\text{Brier} = \frac{1}{N} \sum_{i=1}^N (p_i - y_i)^2, \quad (2.5)$$

ahol p_i a i -edik mintára becsült valószínűség, $y_i \in \{0, 1\}$ a valódi címke; az alacsonyabb érték jobb kalibrációt jelez.

2.12. Statisztikai elemzés

Mivel a tesztalmazban a pozitív esetek száma korlátozott, a pontbecslések (érzékenység, specificitás, AUC) mellett azok bizonytalanságát is jelölni kell. Az arányjellegű metrikákhoz (érzékenység, specificitás) az egzakt, binomiális eloszláson alapuló Clopper–Pearson-féle konfidencia-intervallum ad megbízható becslést kis mintaszám esetén is. Az AUC esetében a DeLong-féle, nemparaméteres módszer szolgáltat konfidencia-intervallumot, illetve teszi lehetővé két modell AUC-értékének páros összehasonlítását; a módszer egy gyors, korszerű implementációját Sun és Xu adta meg [23]. E statisztikai eszközök biztosítják, hogy a modellek közötti különbségekről tett állítások ne csupán a mintavételi zaj következményei legyenek.

2.13. Kommunikációs technológiák: SSE és az MCP

A dolgozatban bemutatott rendszer valós idejű, token-szintű válaszközvetítést és egy nyelvi modellt kiszolgáló komponensekkel való kommunikációt igényel; ezt két technológia teszi lehetővé.

Szerver-küldött események (SSE). A szerver-küldött események (Server-Sent Events) a HTML szabvány részét képező, egyirányú, szerverről kliensre irányuló adatfolyam-mechanizmus egyetlen, tartós HTTP-kapcsolaton keresztül [24]. Az SSE különösen alkalmas a nagy nyelvi modellek token-szintű, fokozatos válaszainak továbbítására, mivel a kliens a szöveget generálással egyidejűleg, darabonként jeleníti meg, jelentősen javítva a felhasználói élményt.

Model Context Protocol (MCP). A Model Context Protocol az Anthropic által 2024-ben közzétett nyílt szabvány, amely egységesíti a nagy nyelvi modellek és a külső eszközök, adatforrások közötti kommunikációt [25]. Az MCP a JSON-RPC 2.0 üzenetformátumra épül [26], és többféle átviteli réteget támogat, többek között a helyi folyamatok közötti szabványos be- és kimeneti (stdio) csatornát. A dolgozat rendszerében az MCP biztosítja a backend és a modellt kiszolgáló komponens közötti, jól strukturált kommunikációt; e megoldás részletes tárgyalása a mérnöki részben található.

3. fejezet

Kutatási rész: a bőrelváltozás-osztályozó modell

Ez a fejezet a bőrelváltozás-osztályozó modell fejlesztését és kiértékelését mutatja be. Először az ISIC 2024 adathalmaz előkészítését ismertetjük, majd a Vision Transformer modellt és annak tanítási folyamatát, ezt követően a két viszonyítási alapot (a ResNet-18 konvolúciós hálót és a Gemini nagy nyelvi modellt), végül a kísérleti elrendezést és az elért eredményeket.

3.1. Az ISIC 2024 adathalmaz és előkészítése

A kísérletekhez az ISIC 2024 verseny (*Skin Cancer Detection with 3D-TBP*) nyilvános tanító adathalmazát használtuk [8]. Az adathalmaz a teljes testfelszín háromdimenziós fényképezéséből kivágott, mintegy 401 000 bőrelváltozás-felvételt tartalmaz, amelyek mindegyikéhez bináris címke tartozik (jóindulatú vagy rosszindulatú). Az adathalmaz meghatározó tulajdonsága a rendkívül erős osztály-egyensúlytalanság: a rosszindulatú esetek száma mindössze 393, ami megközelítőleg 1:1000 pozitív–negatív arányt jelent.

A v3 előzetes kísérletektől eltérően – amelyek a többségi (jóindulatú) osztály 50%-os aldmintázásával dolgoztak – a végleges modellt a **teljes** adathalmazon tanítottuk, hogy a negatív osztály teljes változatosságát kihasználjuk. Az adathalmazt rétegzett (stratifikált) módon, rögzített véletlenmaggal (*seed* = 42) osztottuk fel tanító, validációs és teszhalmazzra 70:15:15 arányban; a teszhalmazt a ta-

nítás teljes folyamata alatt érintetlenül hagytuk, és kizárólag a végső kiértékeléshez használtuk fel. A felosztás eredményét a 3.1. táblázat foglalja össze.

3.1. táblázat. Az ISIC 2024 adathalmaz rétegzett felosztása (teljes adathalmaz, $seed = 42$).

Részhalmaz	Összes kép	Rosszindulatú (pozitív)
Tanító (train)	280 741	275
Validációs (val)	60 159	59
Teszt (test)	60 159	59
Összesen	401 059	393

3.2. A Vision Transformer modell

A fő modell egy ImageNet-en előtanított Vision Transformer (`vit_base_patch16_224`) [9], amelyet a `timm` könyvtárból [27] töltöttünk be. A törzsháló a 224×224 pixeles bemenetből egy 768 dimenziós reprezentációt állít elő, amelyre egy egyedi osztályozó fejet illesztettünk: rétegnormalizálás, dropout ($p = 0,3$), egy 256 neuronos lineáris réteg GELU aktivációval, majd egy újabb dropout ($p = 0,2$) és a kétosztályos kimeneti réteg.

3.2.1. Kétfázisú tanítás

A modellt két fázisban tanítottuk, hogy egyszerre kezeljük az osztály-egyensúlytalanságot és a kimeneti valószínűségek kalibrációját:

- **1. fázis – kiegyensúlyozott tanítás.** Súlyozott mintavételezéssel (`WeightedRandomSampler`) közel 1:1 arányú batch-eket állítottunk elő, így a ritka pozitív esetek a tanítás során felülreprezentálttá váltak. A veszteségfüggvény súlyozott fókuszveszteség [21] volt.
- **2. fázis – kalibráció.** A modellt a valós, erősen kiegyensúlyozatlan eloszlású adaton, tizedére csökkentett tanulási rátával tanítottuk tovább, hogy a kimeneti valószínűségek a tényleges priorhoz igazodjanak.

3.2.2. Az osztály-egyensúlytalanság kezelése

Az egyensúlytalanságot három, egymást kiegészítő technikával kezeltük: (i) súlyozott mintavételezés a kiegyensúlyozott batch-ekhez; (ii) súlyozott fókuszvesztés, amely a nehéz, félreosztályozott eseteket helyezi előtérbe (2.2. egyenlet, $\alpha = 0,25$, $\gamma = 2,0$, a pozitív osztály súlya 7,0); valamint (iii) a kisebbségi osztályra alkalmazott erősebb képaugmentáció. A számítási költség közben tartására az 1. fázis epochonkénti mintaszámát 50 000-re korlátoztuk; mivel a kiegyensúlyozott mintavételezés a 275 pozitív esetet erősen felülmintázza, ez a korlátozás a tanítási stratégiát érdemben nem befolyásolja, viszont gyakoribb validációt és korai leállítást tesz lehetővé.

3.2.3. Adataugmentáció

A túltanulás csökkentésére tanítás közben véletlenszerű augmentációt alkalmaztunk. A többségi (jóindulatú) osztályra alapszintű transzformációkat – vízszintes és függőleges tükrözés, elforgatás, szín-jitter és affin torzítás –, a kisebbségi (rosszindulatú) osztályra ezeknél erősebb augmentációt (nagyobb szögű forgatás, erősebb szín-jitter, perspektivikus torzítás, elmosás) használtunk, hogy az egyes pozitív példák minél több, eltérő változatban kerüljenek a modell elé. A validációs és teszhalmazon nem alkalmaztunk augmentációt, biztosítva a determinisztikus, reprodukálható kiértékelést.

3.2.4. Hiperparaméterek

A tanítás hiperparamétereit a 3.2. táblázat foglalja össze. Az optimalizáló AdamW volt, differenciált tanulási rátával (a törzsháló kisebb, a fej nagyobb rátát kapott), háromepochos lineáris bemelegítéssel, amelyet koszinusz ütemezésű csökkentés követett. A tanítás vegyes pontosságú (mixed precision) módban, gradiens-akkumulációval futott, az effektív batch-méret 128 volt.

3.2. táblázat. A ViT modell tanításának fő hiperparaméterei.

Paraméter	Érték
Architektúra	vit_base_patch16_224 (ImageNet-előtanított)
Bemeneti felbontás	224×224
Batch-méret	32 (effektív 128, grad. akkumuláció $\times 4$)
Optimalizáló	AdamW, súlycsökkenés 10^{-2}
Tanulási ráta (törzs)	2×10^{-6}
Tanulási ráta (fej)	2×10^{-5}
Ütemezés	3 epoch warmup + koszinusz csökkenés
1. fázis epochszám	18 (korai leállítási, türelem = 5)
2. fázis epochszám	3 (kalibráció)
Mintaszám / epoch	50 000
Fókuszvesztés	$\alpha = 0,25$, $\gamma = 2,0$, pozitív súly = 7,0

3.3. A ResNet-18 viszonyítási alap

Viszonyítási alapként egy ImageNet-en előtanított ResNet-18 hálót [14] is betanítottunk, amely a mély tanulásban széles körben alkalmazott, standard konvolúciós referenciamodell. A ResNet-18 **pontosan ugyanazt** a feldolgozási folyamatot használja, mint a ViT – azonos adatfelosztás (azonos véletlenmaggal, így azonos tesztalmez), azonos egyensúlytalanság-kezelés, azonos kiértékelési protokoll –, így a teljesítménykülönbség értelmezésekor a tanítási és kiértékelési feltételek nem jelentenek zavaró tényezőket. A finomhangoláshoz – mivel a konvolúciós hálók nagyobb tanulási rátát viselnek el – a törzsháló, illetve a fej tanulási rátáját 1×10^{-5} , illetve 1×10^{-4} értékre emeltük; minden egyéb beállítás megegyezett a ViT-ével.

Fontos ugyanakkor megjegyezni, hogy a ResNet-18 lényegesen kevesebb paraméterrel rendelkezik (mintegy 11 millió), mint a ViT-Base (mintegy 86 millió). A két modell tehát nem csupán az architektúrában (konvolúció kontra figyelem), hanem a kapacitásában is különbözik; a ResNet-18-at ezért *standard viszonyítási alapként* kezeljük, nem pedig szigorúan azonos kapacitású kontrollként. A

megfigyelt teljesítménykülönbséget ennek megfelelően a két tényező együttes hatásaként értelmezzük.

3.4. A Gemini zero-shot viszonyítási alap

Második viszonyítási alapként a Google Gemini multimodális nagy nyelvi modelljét [18] (a `gemini-2.5-flash` változatot) értékeltük *zero-shot* módban, azaz célzott betanítás nélkül. A modell minden képhez egy minimális szöveges utasítást kapott, amely a rosszindulatúság valószínűségének $[0, 1]$ skálán történő becslésére kérte; sem példákat (*few-shot*), sem klinikai metaadatot nem adtunk a bemenethez. Mivel a Gemini API-alapú, soronkénti lekérdezése a teljes, mintegy 60 000 elemű teszhalmazon költséges és lassú lenne, a Gemini-kiértékelést egy 2 000 képes részhalmazon végeztük, amely a teszhalmaz **összes** pozitív esetét és véletlenszerűen mintavételezett negatív eseteket tartalmazott; a tisztességes összehasonlítás érdekében a ViT modellt ugyanezen a részhalmazon is kiértékeltek.

A Gemini szerepe a dolgozatban kettős szempontból tanulságos: egyrészt megmutatja, mire képes egy általános célú, célzott betanítás nélküli multimodális modell ezen a feladaton, másrészt rávilágít a célzottan betanított, kalibrált osztályozó modell előnyeire – összhangban a szakirodalmi megfigyelésekkel [19].

3.5. Kísérleti elrendezés

A modelleket a Kaggle felhőplatformján, NVIDIA Tesla T4 GPU-n tanítottuk és értékeltük. Az implementáció a PyTorch keretrendszerre [28], a modellek betöltése a `timm` könyvtárra [27], a metrikák és statisztikai számítások pedig a `scikit-learn` könyvtárra [29] épültek. A reprodukálhatóság érdekében minden véletlenszerű folyamatot rögzített maggal ($seed = 42$) inicializáltunk.

A kiértékelést két klinikailag értelmezhető *működési ponton* végeztük: a $\geq 0,90$ érzékenységnél (klinikai szűrési standard) és a $\geq 0,80$ érzékenységnél (az ISIC 2024 verseny pAUC-küszöbe). A döntési küszöböt minden esetben a validációs halmazon kalibráltuk, majd a rögzített küszöböt alkalmaztuk a teszhalmazon. A teljesítményt a 2.3–2.4. egyenletekben definiált metrikákkal, az AUC-val és a hivatalos ISIC 2024 pAUC-val mértük; a pontbecslések bizonytalanságát Clopper–Pearson-féle (arányok) és DeLong-féle (AUC) konfidencia-intervallumokkal [23] jelöltük, a modellek közöt-


ti AUC-különbségeket pedig a DeLong-féle páros teszttel vizsgáltuk. A valószínűségi kalibrációt a Brier-pontszámmal [22] jellemeztük.

3.6. Eredmények

Ebben a szakaszban a ViT modell teljesítményét értékeljük a tesztalmazon, majd összevetjük a ResNet-18, az EVA02 és a Gemini viszonyítási alapokkal.

3.6.1. A tanítás konvergenciája

A 3.1. ábra a tanítás során mért veszteség, valamint a validációs AUC és pAUC alakulását mutatja epochonként. A validációs AUC a kezdeti 0,73-ról 0,90-re, a pAUC 0,055-ről 0,132-re emelkedett; a legjobb validációs pAUC a 11. epochnál állt elő, a korai leállítást pedig a 16. epochnál aktiválódott. A második (kalibrációs) fázis a validációs metrikákat érdemben nem változtatta, így a végső modell lényegében az első fázis legjobb állapota.



3.1. ábra. A ViT modell tanításának konvergenciája: a tanítási veszteség, valamint a validációs AUC és pAUC alakulása az epochok függvényében.


3.6.2. A ViT teljesítménye a tesztalmazon

A 3.3. táblázat a ViT modell teljesítményét foglalja össze a két működési ponton.

3.3. táblázat. A ViT modell teljesítménye a tesztalmazon (60 159 kép, 59 pozitív), két működési ponton.

Metrika	Érzékenység $\geq 0,90$	Érzékenység $\geq 0,80$
AUC (95% CI)	0,939 (0,915–0,963)	
pAUC (TPR $\geq 0,80$)	0,159	
Brier-pontszám	0,047	
Küszöb	0,170	0,270
Érzékenység (95% CI)	0,966 (0,883–0,996)	0,881 (0,771–0,951)
Specifitás (95% CI)	0,668 (0,664–0,671)	0,843 (0,840–0,846)
PPV / NPV	0,003 / 1,000	0,005 / 1,000

A 3.2. ábra a ViT modell ROC-görbét mutatja, kiemelve a pAUC számításához használt, $TPR \geq 0,80$ tartományt.



3.2. ábra. A ViT modell ROC-görbéje a teszhalmazon, a pAUC számításához használt $TPR \geq 0,80$ tartomány kiemelésével.

3.6.3. Összehasonlítás a viszonyítási alapokkal

A 3.4. táblázat a négy modellt veti össze a két közvetlenül összehasonlítható minőség-mérőszám – az AUC és a hivatalos ISIC 2024 pAUC – mentén. Mindkét mutató a modellek rangsorolási képességét méri, és független a döntési küszöbtől, így akkor is értelmes az összevetésük, ha az egyes modellek saját, szivárgásmentes (held-out) halmazukon kerültek kiértékelésre.

3.4. táblázat. A négy modell összehasonlítása az AUC és a hivatalos pAUC mentén. Az EVA02 a saját, szivárgásmentes validációs foldján szerepel (a modellt a teljes adat 80%-án tanították, így a mi teszhalmazonkon történő kiértékelése adatszivárgást okozna); a Gemini csak egy 2 000 elemű részhalmazon futott, a pAUC-ja a korábbi (eltérő) definícióval készült, ezért nem szerepel.

Modell	AUC	pAUC	Kiértékelési halmaz
ViT-Base (saját, finomhangolt)	0,939	0,159	teszt (60 159, 59 poz.)
EVA02 (legjobb image-only ref.)	0,929	0,158	val-fold (1 651, 79 poz.)
ResNet-18 (CNN, viszonyítási alap)	0,876	0,122	teszt (60 159, 59 poz.)
Gemini 2.5 Flash (zero-shot)	0,740	–	részhalmaz (2 000, 59 poz.)

ViT kontra ResNet-18 (azonos teszhalmaz). A két modell pontosan ugyanazon a teszhalmazon, azonos feldolgozási folyamattal került kiértékelésre, így a tanítási és kiértékelési feltételek nem zavaró tényezők (a kapacitásbeli különbségre az előző szakaszban tett megjegyzés mellett). A ViT minden mutatóban érdemben felülmúlja a ResNet-et: AUC 0,939 kontra 0,876, pAUC 0,159 kontra 0,122. A különbség a magas érzékenységgű tartományban a legmarkánsabb: a $\geq 0,80$ érzékenységi ponton a specificitás 0,843 kontra 0,625, a $\geq 0,90$ ponton pedig 0,668 kontra 0,400 – vagyis a ViT azonos érzékenység mellett lényegesen kevesebb téves riasztást ad.

ViT kontra EVA02 (a legjobb image-only Kaggle modell). A ViT-Base gyakorlatilag egyenrangú a verseny legerősebb tisztán képi modelljével: a hivatalos pAUC szinte azonos (0,159 kontra 0,158), az AUC pedig hasonló (0,939 kontra 0,929). Mivel mindkettő szivárgásmentes halmazon, a hivatalos metrikával készült, a párhuzam tisztességes – noha nem ugyanazon a halmazon. Fontos azonban, hogy az EVA02 a natív 336×336 felbontásán fut (szemben a ViT 224×224 -ével), ezért ez nem szigorú, azonos felbontású kontroll, hanem a legjobb publikált image-only megoldással szembeni viszonyítás. A két modell specificitása nem vethető össze közvetlenül, mivel az EVA02 kiértékelési halmaza jóval kisebb és eltérő prevalenciájú.

ViT kontra Gemini (zero-shot). A célzott betanítás nélküli, általános célú Gemini modell jelentősen elmarad (AUC 0,740): hajlamos a legtöbb elváltozást gyanúsnak jelölni, ezért a specificitása

alacsony. Ez megerősíti a rendszer tervezési döntését, amely a klasszifikációt egy célzottan betanított modellre, a magyarázatot pedig a nagy nyelvi modellre bízta.

3.6.4. Statisztikai elemzés

A modellek rangsorolási teljesítményének bizonytalanságát a DeLong-féle 95%-os konfidencia-intervallumok jellemzik. A ViT AUC-jának intervalluma (0,915–0,963) és a ResNet-é (0,837–0,914) gyakorlatilag nem fed át, ami a két modell közötti különbség statisztikai szignifikanciájára utal. A mentett predikciókból a DeLong-féle páros teszt formálisan is elvégezhető, mivel a ViT és a ResNet ugyanazon a tesztalmazon került kiértékelésre.

A valószínűségi kalibrációt a Brier-pontszám jellemzi. Mindkét képi modell Brier-pontszáma (ViT: 0,047, ResNet: 0,075) magasabb a triviális, a prevalenciát jósló alapvonalénál (0,001), ami a kimeneti valószínűségek gyenge kalibráltságát jelzi – ez az erős osztály-egyensúlytalanság és a kiegyensúlyozott mintavételezés ismert következménye. A ViT ugyanakkor jobban kalibrált, mint a ResNet. Hangsúlyozandó, hogy a rangsorolás (AUC, pAUC) erős; a nyers valószínűségek utólagos kalibrálása a jövőbeli munka tárgya.

3.6.5. Az eredmények megbeszélése és korlátai

Az eredmények fő tanulsága, hogy a finomhangolt ViT-Base modell eléri a verseny legjobb tisztán képi megoldásának (EVA02) szintjét, miközben jelentősen felülmúlja mind a klasszikus konvolúciós alapot (ResNet-18), mind a zero-shot nagy nyelvi modellt (Gemini). A magas érzékenységgű működési ponton mért közel tökéletes negatív prediktív érték ($NPV \approx 1,0$) klinikai szűrőeszközként kedvező: a „jóindulatú” besorolás megbízható.

Az értelmezésnél több korlátot figyelembe kell venni. (i) A tesztalmazban csak 59 pozitív eset szerepel, ami a metrikák – különösen az érzékenység és a pAUC – becslését érzékennyé teszi a mintavételi zajra; ezt a megadott konfidencia-intervallumok tükrözik. (ii) A pozitív prediktív érték (PPV) nagyon alacsony ($\approx 0,005$), ami az extrém, $\sim 1:1000$ arányú osztály-egyensúlytalanság közvetlen következménye – nagyszámú negatív eset mellett még jó specificitás mellett is sok a téves pozitív. (iii) Az EVA02 eltérő (kisebb, magasabb prevalenciájú) halmazon és felbontáson került kiértékelésre, ezért

referenciaként, nem szigorú kontrollként értelmezendő. (iv) A kimeneti valószínűségek kalibrációja további javítást igényel.

4. fejezet

Mérnöki rész: a DermAI alkalmazás

Ez a fejezet a DermAI rendszer mérnöki megvalósítását mutatja be: a betanított osztályozó modellt egy teljes, végponttól végpontig működő alkalmazássá egészíti ki, amely okostelefonon és webböngészőben egyaránt elérhető. Először a követelményeket és a rendszerarchitektúrát ismertetjük, majd komponensenként a megvalósítást: a modellt kiszolgáló réteget, a backendet, a mobil- és webalkalmazást, a hitelesítést és a felhőalapú adattárolást, végül a hálózati hibatűrést és a biztonsági megfontolásokat.

4.1. Követelmények

4.1.1. Funkcionális követelmények

A rendszerrel szemben támasztott fő funkcionális elvárások a következők:

- A felhasználó fényképet készíthet vagy tölthet fel egy bőrelváltozásról (kamera vagy galéria).
- A rendszer a feldolgozás előtt ellenőrzi a kép minőségét és relevanciáját, és elutasítja az értékelhetetlen felvételeket.
- A bőrelváltozást egy ViT-alapú modell osztályozza (jóindulatú / rosszindulatú), konfidencia-értékkel.

- A rendszer természetes nyelvű magyarázatot ad az eredményről, az ABCDE-szabály figyelembevételével.
- A felhasználó utólagos kérdéseket tehet fel az elváltozással kapcsolatban (párbeszéd).
- A felhasználó bejelentkezik, és a feltöltött képek, valamint a beszélgetések a saját fiókjához kötve, biztonságosan tárolódnak.
- A felhasználó visszanézheti korábbi munkameneteit (előzmények).

4.1.2. Nem-funkcionális követelmények

- **Reszponzivitás:** az AI-válaszok token-szintű, fokozatos megjelenítése, hogy a felhasználó ne egy hosszú várakozás után, hanem folyamatosan kapjon visszajelzést.
- **Hibatűrés:** a rendszer alkalmazkodjon a változó hálózati körülményekhez és a modellt kiszolgáló komponens időszakos elérhetetlenségéhez.
- **Biztonság:** a felhasználói adatok hitelesített hozzáférés mögött, felhasználónként elkülönítve tárolódjanak; a titkos kulcsok ne kerüljenek a forráskódba.
- **Hordozhatóság:** a modelt kiszolgáló komponens címe futás közben módosítható legyen, hogy a (gyakran változó címen elérhető) GPU-háttér újraindítása ne igényelje az alkalmazás újratelepítését.

4.2. Rendszerarchitektúra

A DermAI több, jól elkülönülő komponensből álló, elosztott rendszer. A két kliens (Android alkalmazás és webes felület) külön-külön backendhez kapcsolódik, amelyek azonban közös elveken működnek, és ugyanazt a modelt kiszolgáló réteget, illetve felhőszolgáltatásokat használják. A komponensek és kapcsolataik áttekintését a 4.1. ábra mutatja.

- **Android alkalmazás** (Kotlin) – a mobil kliens; a **Flask** alapú backendhez [30] kapcsolódik.

- **Webes felület** (HTML/JavaScript) – a böngészőkliens; a **FastAPI** alapú backendhez [31] kapcsolódik.
- **Modellt kiszolgáló réteg** – egy MCP-szerver [25], amely a GPU-n futó ViT modellt szolgáltató meg.
- **Gemini 2.5 Flash** [18] – a képvalidációt, a magyarázatgenerálást és a párbeszédet végző nagy nyelvi modell.
- **Firestore** [32] – hitelesítés (Authentication), adatbázis (Firestore) és fájl tárolás (Storage).

[Ábra helye] – A DermAI rendszer komponensdiagramja: a két kliens (Android, web), a hozzájuk tartozó backendek (Flask, FastAPI), a modellt kiszolgáló MCP-réteg és a GPU-n futó ViT, valamint a Firebase és a Gemini szolgáltatások kapcsolatai. (Saját szerkesztésű ábrát illessz be.)

4.1. ábra. A DermAI rendszer magas szintű architektúrája.

4.2.1. Egy elemzési kérés életciklusa

Egy kép elemzésének tipikus folyamata a következő lépésekből áll:

1. A kliens elküldi a képet és a hitelesítő tokenet a backendnek.
2. A backend ellenőrzi a tokenet, majd a képet a Gemini modellnek továbbítja *minőség- és relevanciaellenőrzésre*. Ha a kép nem értékelhető (pl. nem bőrelváltozás, túl távoli, életlen vagy több léziót tartalmaz), a folyamat itt megszakad, és a felhasználó célzott visszajelzést kap.
3. Megfelelő kép esetén a backend feltölti a képet a felhasználó tárhelyére (Firestore Storage), majd az MCP-rétegen keresztül lefuttatja a ViT-osztályozást.

4. A backend létrehozza vagy frissíti a munkamenet rekordját a Firestore adatbázisban.
5. A backend a klasszifikációs eredményt belefoglalja a Gemini számára összeállított utasításba, és a magyarázatot **token-szintű adatfolyamként** (SSE) küldi vissza a kliensnek.

4.3. A modellt kiszolgáló komponens: MCP-szerver

A betanított ViT modell a backendtől elkülönített, GPU-val rendelkező környezetben (Google Colab) fut, és HTTP-végponton fogadja a klasszifikációs kéréseket. A backend és e modellszolgáló közötti kommunikációt egy MCP- (Model Context Protocol) szerver [25] közvetíti, amely a backendből indított alfolyamatként, szabványos be- és kimeneti (stdio) csatornán, JSON-RPC 2.0 üzenetekkel [26] kommunikál. Egy klasszifikációs kérés üzenetformátuma például:

```
{"jsonrpc": "2.0", "id": 1, "method": "tools/call",  
  "params": {"name": "classify_lesion",  
             "arguments": {"image_base64": "..."}}}
```

Az MCP-szerver a kapott, base64 kódolású képet továbbítja a GPU-n futó modell `/classify` végpontjának, és a választ – a címkét, a konfidenciát és az osztályonkénti pontszámokat – adja vissza a backendnek. A megoldás egyik kulcseleme egy `update_model_url` metódus, amely lehetővé teszi a modellszolgáló címének **futás közbeni** módosítását: mivel a GPU-háttér újraindításakor a nyilvános cím (alagút) megváltozik, e mechanizmus révén a backend új cím esetén sem igényel újraindítást.

4.4. A backend

A rendszer két backendet tartalmaz, amelyek a két klienst szolgálják ki, de azonos belső felépítést követnek. A mobil kliens egy **Flask** [30] alapú szerveret, a webes felület pedig egy **FastAPI** [31] alapú szerveret használ. Mindkét backend ugyanazt az MCP-klienst, ugyanazt a Gemini-integrációt és ugyanazokat a Firebase-szolgáltatásokat használja.

4.4.1. Végpontok

A webes (FastAPI) backend főbb végpontjait a 4.1. táblázat foglalja össze; a mobil (Flask) backend ezekkel funkcionálisan egyenértékű végpontokat biztosít.

4.1. táblázat. A webes backend (FastAPI) főbb végpontjai.

Metódus	Útvonal	Funkció
POST	/analyze	Kép elemzése (validálás, osztályozás, magyarázat)
POST	/chat	Utólagos kérdés (kép nélkül), párbeszéd
GET	/history/{id}	Egy korábbi munkamenet lekérése
GET	/sessions	A felhasználó munkameneteinek listája
PUT	/model-url	A modellkiszolgáló címének frissítése
GET	/health	Állapotellenőrzés

4.4.2. A Gemini integrációja és a képvalidáció

A nagy nyelvi modell (Gemini 2.5 Flash) a rendszerben három feladatot lát el. Az **elsődleges szűrés** során a feltöltött képet egy rögzített utasítással értékeli, amely egyetlen kódot kér vissza: OK (értékelhető), NOT_SKIN, TOO_FAR, MULTIPLE, BLURRY vagy NOT_ASSESSABLE. Ha a kód nem OK, a felhasználó a hibának megfelelő, célzott útmutatást kap (például: tartsa közelebb a kamerát, vagy fényképezzen egyetlen léziót). A **magyarázatgenerálás** során a Gemini a ViT klasszifikációs eredményét beépítve, az ABCDE-szabály szerint értelmezi az elváltozást, közérthető nyelven. Végül a Gemini kezeli a felhasználó **utólagos kérdéseit** is, a beszélgetés előzményeinek figyelembevételével.

4.4.3. Token-szintű adatfolyam (SSE)

A reszponzív felhasználói élmény érdekében a Gemini válaszait nem egyben, hanem token-szintű adatfolyamként továbbítjuk a kliensnek, szerver-küldött események (Server-Sent Events) formájában [24]. Az adatfolyam egyes eseményei egy-egy szövegdarabot tartalmaznak, a lezárást pedig egy különleges jelző jelzi:

```
data: {"token": "Az elváltozás "}
```

```
data: {"token": "aszimmetrikus, ..."}  
data: [DONE]
```

Így a felhasználó a szöveget a generálással egyidejűleg, folyamatosan látja megjelenni.

4.5. A mobilalkalmazás

A mobil kliens natív Android alkalmazás, Kotlin nyelven. Indításkor egy bejelentkező képernyő (LoginActivity) fogadja a felhasználót, ahol Google-fiókkal jelentkezhet be; sikeres hitelesítés után a fő képernyőre (MainActivity) jut.

A fő képernyő chat-alapú felületet biztosít: a felhasználó a kamerával fényképet készíthet (egy dedikált CameraActivity segítségével), vagy a galériából választhat képet, majd szöveges üzenettel együtt elküldheti azt elemzésre. A beérkező AI-válaszokat a felület token-szintű adatfolyamként, folyamatosan jeleníti meg, a klasszifikáció eredményét pedig egy színkódolt jelvény (jóindulatú / rosszindulatú) emeli ki. A menüből elérhető a korábbi munkamenetek előzménye, az alkalmazás ismertetője (About), a hálózati beállítások, valamint a kijelentkezés.

4.5.1. Hálózati réteg

Az alkalmazás hálózati rétege az OkHttp és a Retrofit könyvtárakra épül. A streaming (SSE) válaszokat egy Kotlin Flow kezeli, az állapotot pedig egy ChatViewModel tartja karban, így az adatfolyam a képernyő-forgatást is túléli. A backend címét egy beállítási rétegben (NetworkConfig) tároljuk, amely a SharedPreferences-ben őrzi a felhasználó által megadott vagy az alapértelmezett címet – ez teszi lehetővé, hogy az alkalmazás mindig ott keresse a backendet, ahol az ténylegesen elérhető.

4.6. A webes felület

A webes felület egy egyoldalas, sötét témájú alkalmazás, amely a FastAPI backend által kiszolgált sablonra épül. A felület a Firebase JavaScript SDK-t használja a Google-alapú bejelentkezéshez: amíg a felhasználó nincs bejelentkezve, egy bejelentkező réteg takarja a felületet, sikeres hitelesítés

után pedig megjelenik a chat-felület. Minden, a backendhez intézett kérés tartalmazza a felhasználó hitelesítő tokenjét. A felületről elérhető egy külön ismertető (About) oldal, valamint a kijelentkezés is. A token-szintű válaszokat a böngésző a szerver-küldött események feldolgozásával jeleníti meg fokozatosan.

4.7. Hitelesítés és felhőalapú adattárolás

A rendszer a Firebase szolgáltatásait [32] használja a hitelesítéshez és az adattároláshoz.

4.7.1. Hitelesítés

A bejelentkezés mindkét platformon Google-fiókkal, a Firebase Authentication segítségével történik. A kliens a sikeres bejelentkezés után egy azonosítótokent (ID token) kap, amelyet minden backend-kéréshez mellékel az `Authorization` fejlécben. A backend e tokent szerveroldalon ellenőrzi a Firebase Admin SDK segítségével, és a kérésből kinyeri a felhasználó egyedi azonosítóját (`uid`); érvénytelen vagy hiányzó token esetén a kérést elutasítja.

4.7.2. Adatbázis és fájl tárolás

A munkameneteket a Firestore adatbázis tárolja, munkamenetenként egy dokumentumban, amely tartalmazza a tulajdonos azonosítóját, a klasszifikáció eredményét, a feltöltött kép azonosítóját és a beszélgetés üzeneteit. A dokumentum szerkezete vázlatosan:

```
sessions/{session_id}
```

```
user_id      : a tulajdonos Firebase-azonosítója
created_at   : létrehozás időbélyege
source       : "web" vagy "android"
image_id     : a feltöltött kép azonosítója
classification : {label, confidence, all_scores}
messages     : [{role, text, timestamp}, ...]
```

A feltöltött képeket a Firebase Storage tárolja, **felhasználónként elkülönített** útvonalon: `users/{uid}/lesio`. Így a képek a feltöltő felhasználó fiókjához kötődnek, és a munkamenetek listázásakor a backend a tulajdonos azonosítója szerint szűr, biztosítva, hogy minden felhasználó kizárólag a saját adatait érje el.

4.8. Hálózati robusztusság és hibatűrés

Mivel a rendszer több, egymástól független szolgáltatásra támaszkodik – és a modellt kiszolgáló GPU-háttér címe is változhat –, a hálózati hibatűrés kiemelt tervezési szempont volt. A megvalósított mechanizmusok:

- **Újrapróbálkozás exponenciális visszalépéssel.** A REST-hívásokhoz egy `OkHttp`-elfogó (interceptor), az SSE-adatfolyamhoz pedig a Kotlin Flow `retryWhen` operátora biztosít automatikus újrapróbálkozást átmeneti hálózati hiba esetén.
- **Az MCP-kliens önjavítása.** A backend MCP-kliense a sikertelen hívásokat többször újrapróbálja, és szükség esetén újraindítja a modellt kiszolgáló alfolyamatot.
- **Dinamikus címkezelés.** A modellkiszolgáló címe futás közben frissíthető (`update_model_url`, illetve a `/model-url` végpont), a backend címe pedig a kliensoldali beállításokban módosítható, így a rendszer alkalmazkodik a változó nyilvános címekhez.

4.9. Biztonsági megfontolások

A rendszer a titkos kulcsokat (a Gemini API-kulcsot és a Firebase hozzáférési adatokat) környezeti változókból, futásidőben tölti be, és **soha nem tárolja a forráskódban**; e fájlokat a verziókezelés is kizárja. A backend minden védett végponton ellenőrzi a Firebase azonosítótokent, így a klasszifikációs és párbeszéd-funkciók kizárólag hitelesített felhasználók számára érhetők el. A felhasználói adatok – a feltöltött képek és a munkamenetek – felhasználónként elkülönítve tárolódnak, így egy felhasználó nem férhet hozzá más adataihoz.

Hangsúlyozandó továbbá, hogy a rendszer kialakítása tudatosan **tájékoztató jellegű**: a klasszifikációt egy célzottan betanított, kalibrált képi modell végzi, míg a nagy nyelvi modell szerepe a magyarázatra és a párbeszédre korlátozódik. A rendszer nem helyettesíti a szakorvosi diagnózist, hanem szűrőeszközként segíti a felhasználót a dermatológiai konzultáció szükségességének megítélésében.

5. fejezet

Összefoglalás és jövőbeli munka

5.1. A dolgozat eredményeinek összegzése

A dolgozatban egy végponttól végpontig megvalósított, AI-alapú bőrelváltozás-elemző rendszert (DermAI) terveztünk és valósítottunk meg, amely a korai bőrrákszűrést egy okostelefonon és webböngészőben egyaránt elérhető eszközzel támogatja. A munka két, egymást kiegészítő pillérre épült.

A **kutatási rész** egy Vision Transformer modellt tanított be az ISIC 2024 adathalmazon a bőrelváltozások jóindulatú/rosszindulatú osztályozására, megfelelő figyelmet fordítva az adathalmaz rendkívül erős osztály-egyensúlytalanságára (súlyozott mintavételezés, fókuszvesztés, kétfázisú tanítás). A modellt két viszonyítási alappal vetettük össze: egy azonos feltételek mellett betanított ResNet-18 konvolúciós hálóval (az architektúra hatásának izolálására) és egy zero-shot Gemini nagy nyelvi modellel. A kiértékelés a hivatalos ISIC 2024 részleges AUC metrikán, két klinikailag értelmezhető működési ponton, valamint statisztikai szignifikancia-vizsgálattal (DeLong-teszt, konfidencia-intervallumok) és kalibrációs elemzéssel (Brier-pontszám) történt. A finomhangolt ViT-Base modell a teszhalmazon AUC 0,939-et és pAUC 0,159-et ért el, és minden mutatóban érdemben felülmúlta a ResNet-18 konvolúciós alapot (AUC 0,876, pAUC 0,122) – különösen a magas érzékenységű tartományban, ahol azonos érzékenység mellett lényegesen jobb specificitást nyújtott. A zero-shot Gemini modell jelentősen elmaradt (AUC 0,740). A ViT egyúttal gyakorlatilag elérte a verseny legjobb tisztán képi modelljének (EVA02) szintjét is (pAUC 0,158), ami a saját modell versenyképességét igazolja.

A **mérnöki rész** a betanított modellt egy teljes, működő alkalmazássá egészítette ki: natív Android

klients, webes felület, két backend (Flask, illetve FastAPI), a modellt kiszolgáló MCP-réteg, valamint a Gemini nagy nyelvi modellre épülő képvalidáció, magyarázatgenerálás és párbeszéd. A rendszer a felhasználói adatokat hitelesített hozzáférés mögött, felhasználónként elkülönítve tárolja (Firebase), a token-szintű válaszközvetítést szerver-küldött eseményekkel valósítja meg, és több szintű hálózati hibatűréssel alkalmazkodik a változó környezethez.

5.2. Korlátok

Az eredmények értelmezésekor több korlátot figyelembe kell venni:

- **Kevés pozitív eset.** Az ISIC 2024 adathalmazban mindössze 393 rosszindulatú eset szerepel, a teszhalmazban 59. Ez a metrikák – különösen az érzékenység és a pAUC – becslését érzékenyíti a mintavételi zajra, amit a megadott konfidencia-intervallumok tükröznek.
- **Kizárólag képi bemenet.** A modell csak a képet használja; az ISIC 2024 verseny tapasztalata szerint a klinikai metaadatok bevonása érdemben javíthatja a teljesítményt.
- **Adathalmaz-jellegű torzítások.** A 3D-TBP felvételek nem fedik le a hétköznapi okostelefonos fényképezés teljes változatosságát, és a populációs reprezentáció (például a bőrtónusok eloszlása) korlátozott lehet, ami az általánosíthatóságot befolyásolja.
- **Tájékoztató jelleg.** A rendszer nem klinikai diagnosztikai eszköz; kimenete nem helyettesíti a szakorvosi vizsgálatot.

5.3. Jövőbeli fejlesztési irányok

A dolgozat eredményei több irányban is folytathatók:

- **Multimodális fúzió.** A képi modell és a klinikai metaadatok együttes felhasználása (például gradiens-alapú döntésifa-együttessel kombinálva), az ISIC 2024 győztes megoldásainak mintájára, várhatóan tovább javítaná a teljesítményt.

- **Kalibráció és bizonytalanságbecslés.** A kimeneti valószínűségek utólagos kalibrálása (például hőmérséklet-skálázással) és a predikciós bizonytalanság becslése növelné a klinikai megbízhatóságot.
- **Robusztusság és méltányosság.** Sokszínűbb – különböző bőrtónusokat és felvételi körülményeket lefedő – adathalmazokon történő tanítás és kiértékelés csökkentené a populációk közötti teljesítménykülönbségeket.
- **Magyarázhatóság.** A figyelmi térképek vagy más vizuális magyarázó technikák integrálása átláthatóbbá tenné a modell döntéseit a felhasználó és a szakorvos számára.
- **Klinikai validáció.** A rendszer valós környezetben, prospektív vizsgálatban történő értékelése elengedhetetlen a tényleges klinikai hasznosság igazolásához.

Összességében a dolgozat azt mutatta meg, hogy egy modern, figyelem-alapú képi modell és egy nagy nyelvi modell összehangolt alkalmazásával egy hozzáférhető, felhasználóbarát bőrrákszűrő rendszer építhető, amely – a fenti korlátok tudatában – értékes első lépés lehet a korai felismerés támogatásában.

Irodalomjegyzék

- [1] International Agency for Research on Cancer, „Melanoma of skin — GLOBOCAN 2022.” Global Cancer Observatory, World Health Organization, 2024. <https://gco.iarc.who.int/media/globocan/factsheets/cancers/16-melanoma-of-skin-fact-sheet.pdf>.
- [2] National Cancer Institute, „Cancer stat facts: Melanoma of the skin.” Surveillance, Epidemiology, and End Results (SEER) Program, 2024. <https://seer.cancer.gov/statfacts/html/melan.html>.
- [3] A. Esteva, B. Kuprel, R. A. Novoa, J. Ko, S. M. Swetter, H. M. Blau, and S. Thrun, „Dermatologist-level classification of skin cancer with deep neural networks,” *Nature*, vol. 542, no. 7639, pp. 115–118, 2017.
- [4] H. A. Haenssle, C. Fink, R. Schneiderbauer, F. Toberer, T. Buhl, A. Blum, A. Kalloo, A. B. H. Hassen, L. Thomas, A. Enk, *et al.*, „Man against machine: diagnostic performance of a deep learning convolutional neural network for dermoscopic melanoma recognition in comparison to 58 dermatologists,” *Annals of Oncology*, vol. 29, no. 8, pp. 1836–1842, 2018.
- [5] T. J. Brinker, A. Hekler, A. H. Enk, J. Klode, A. Hauschild, C. Berking, B. Schilling, S. Haferkamp, D. Schadendorf, M. Schlaak, *et al.*, „Deep neural networks are superior to dermatologists in melanoma image classification,” *European Journal of Cancer*, vol. 119, pp. 11–17, 2019.
- [6] P. Tschandl, C. Rosendahl, and H. Kittler, „The HAM10000 dataset, a large collection of multi-source dermoscopic images of common pigmented skin lesions,” *Scientific Data*, vol. 5, no. 1, pp. 1–9, 2018.

- [7] V. Rotemberg, N. Kurtansky, B. Betz-Stablein, L. Caffery, E. Chousakos, N. Codella, M. Combalia, S. Dusza, P. Guitera, D. Gutman, *et al.*, „A patient-centric dataset of images and metadata for identifying melanomas using clinical context,” *Scientific Data*, vol. 8, no. 1, p. 34, 2021.
- [8] ISIC Archive, „ISIC 2024 – skin cancer detection with 3D-TBP.” <https://www.kaggle.com/competitions/isic-2024-challenge/>, 2024. Kaggle verseny.
- [9] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, *et al.*, „An image is worth 16x16 words: Transformers for image recognition at scale,” in *International Conference on Learning Representations*, 2021.
- [10] C. Garbe, T. Amaral, K. Peris, A. Hauschild, P. Arenberger, *et al.*, „European consensus-based interdisciplinary guideline for melanoma. Part 1: Diagnostics: Update 2022,” *European Journal of Cancer*, vol. 170, pp. 236–255, 2022.
- [11] N. R. Abbasi, H. M. Shaw, D. S. Rigel, R. J. Friedman, W. H. McCarthy, I. Osman, A. W. Kopf, and D. Polsky, „Early diagnosis of cutaneous melanoma: revisiting the ABCD criteria,” *JAMA*, vol. 292, no. 22, pp. 2771–2776, 2004.
- [12] M. A. Kassem, K. M. Hosny, R. Damasevicius, and M. M. Eltoukhy, „Machine learning and deep learning methods for skin lesion classification and diagnosis: a systematic review,” *Diagnostics*, vol. 11, no. 8, 2021.
- [13] O. Russakovsky, J. Deng, H. Su, J. Krause, S. Satheesh, S. Ma, Z. Huang, A. Karpathy, A. Khosla, M. Bernstein, A. C. Berg, and L. Fei-Fei, „ImageNet large scale visual recognition challenge,” *International Journal of Computer Vision*, vol. 115, no. 3, pp. 211–252, 2015.
- [14] K. He, X. Zhang, S. Ren, and J. Sun, „Deep residual learning for image recognition,” in *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 770–778, 2016.
- [15] M. Tan and Q. Le, „EfficientNet: Rethinking model scaling for convolutional neural networks,” in *International Conference on Machine Learning*, pp. 6105–6114, PMLR, 2019.

- [16] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, „Attention is all you need,” *Advances in Neural Information Processing Systems*, vol. 30, 2017.
- [17] G. H. Dagnaw, M. El Mouhtadi, and M. Mustapha, „Skin cancer classification using vision transformers and explainable artificial intelligence,” *Journal of Medical Artificial Intelligence*, vol. 7, 2024.
- [18] Gemini Team, Google, „Gemini: A family of highly capable multimodal models.” arXiv preprint arXiv:2312.11805, 2023. <https://arxiv.org/abs/2312.11805>.
- [19] K. Cirone, M. Akrou, L. Abid, and A. Oakley, „Assessing the utility of multimodal large language models (GPT-4 vision and large language and vision assistant) in identifying melanoma across different skin tones,” *JMIR Dermatology*, vol. 7, p. e55508, 2024.
- [20] J. Zhou, X. He, L. Sun, J. Xu, X. Chen, Y. Chu, L. Zhou, X. Liao, B. Zhang, S. Afvari, and X. Gao, „Pre-trained multimodal large language model enhances dermatological diagnosis using SkinGPT-4,” *Nature Communications*, vol. 15, p. 5649, 2024.
- [21] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, „Focal loss for dense object detection,” in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pp. 2980–2988, 2017.
- [22] C. Guo, G. Pleiss, Y. Sun, and K. Q. Weinberger, „On calibration of modern neural networks,” in *Proceedings of the 34th International Conference on Machine Learning (ICML)*, vol. 70, pp. 1321–1330, PMLR, 2017.
- [23] X. Sun and W. Xu, „Fast implementation of DeLong’s algorithm for comparing the areas under correlated receiver operating characteristic curves,” *IEEE Signal Processing Letters*, vol. 21, no. 11, pp. 1389–1393, 2014.
- [24] WHATWG, „HTML living standard — server-sent events,” 2024. <https://html.spec.whatwg.org/multipage/server-sent-events.html>.

- [25] Anthropic, „Model context protocol – specification.” Open standard, 2024. <https://modelcontextprotocol.io/specification>.
- [26] JSON-RPC Working Group, „JSON-RPC 2.0 specification,” 2013. <https://www.jsonrpc.org/specification>.
- [27] R. Wightman, „PyTorch image models (timm).” GitHub repository, 2019. <https://github.com/huggingface/pytorch-image-models>.
- [28] A. Paszke, S. Gross, F. Massa, A. Lerer, J. Bradbury, G. Chanan, T. Killeen, Z. Lin, N. Gimelshein, L. Antiga, *et al.*, „PyTorch: An imperative style, high-performance deep learning library,” in *Advances in Neural Information Processing Systems*, vol. 32, 2019.
- [29] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, *et al.*, „Scikit-learn: Machine learning in Python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [30] Pallets Projects, „Flask – web development, one drop at a time.” Dokumentáció, 2024. <https://flask.palletsprojects.com/>.
- [31] S. Ramírez, „FastAPI.” Dokumentáció, 2024. <https://fastapi.tiangolo.com/>.
- [32] Google, „Firebase documentation.” Dokumentáció, 2024. <https://firebase.google.com/docs>.

A. függelék

Függelék

A.1. Alfejezet

A.1.1. Cím

Alcím