

Tartalomjegyzék

Ábrák jegyzéke

1. fejezet

Bevezető

1.1. Motiváció és problémafelvetés

A bőrrák napjaink egyik legelterjedtebb daganatos megbetegedése. A Globális Rákstatisztikák (GLOBOCAN) legfrissebb adatai szerint évente több mint egymillió új melanoma-esetet diagnosztizálnak világszerte, és a korai felismerés hiányában a betegség gyorsan áttétet képezhet, drasztikusan csökkentve a túlélési esélyeket [?]. Ezzel szemben az időben felismert, még felszíni stádiumban lévő melanoma esetén az ötéves túlélési arány meghaladja a 98%-ot, míg előrehaladott stádiumban ez az arány 20% alá esik [?]. A korai diagnózis tehát nem csupán orvosi, hanem népegészségügyi szempontból is kritikus fontosságú.

A hagyományos diagnosztikai folyamat egy dermatológus által végzett vizuális vizsgálatot és dermatoszkópos értékelést foglal magában, amelyhez magas szintű szakmai tudás és speciális eszközök szükségesek. A világ számos részén, különösen vidéki térségekben és fejlődő országokban, a bőrgyógyászati szakellátáshoz való hozzáférés korlátozott, ami késedelmes diagnózishoz és rosszabb kimenetelhez vezet. Emellett még fejlett egészségügyi rendszerekben is előfordul, hogy a betegek hosszú várakozási idő után jutnak szakorvosi vizsgálatához.

A mesterséges intelligencia, azon belül a mély tanulás megjelenése új lehetőségeket nyitott a bőrelváltozások automatikus osztályozásában. Az egyik úttörő tanulmányban Esteva és munkatársai kimutatták, hogy egy konvolúciós neurális háló bőrrák-osztályozásban eléri a tapasztalt dermatológusok szintjét [?]. Ezt követően számos kutatás megerősítette, hogy a mélytanulás-alapú rendszerek képesek

megközelíteni, sőt bizonyos feltételek mellett meghaladni az emberi szakértők teljesítményét [?, ?].

Ugyanakkor ezek a rendszerek kezdetben komoly korlátokkal rendelkeztek: kizárólag dermatoszkópos, nagy felbontású klinikai felvételeken működtek megbízhatóan, amelyek elkészítéséhez speciális eszközre és szakértelemre van szükség. A szelekciós torzítás is jelentős problémaként merült fel, hiszen az elérhető adathalmazok döntően klinikailag gyanús, már szakorvoshoz kerülő elváltozásokat tartalmaztak, ami a modellek általánosíthatóságát korlátozta. A HAM10000 [?], majd az ISIC versenysorozat adathalmazai [?, ?] lényegesen bővítették az elérhető annotált képanyagot, és egy egy-séges értékelési keretet biztosítottak a kutatók számára.

Az okostelefonok elterjedése és folyamatosan fejlődő kamerarendszerei új perspektívát nyitottak: a bőrgyógyászati szűrés akár közvetlenül a beteg kezébe adható eszközöket is alkalmazhat. Egy ilyen rendszer képes lenne arra, hogy a felhasználó által készített fotó alapján jelezze, ha egy elváltozás szakorvosi vizsgálatot indokolhat, csökkentve ezzel mind a késői diagnózisok számát, mind az indokolatlan orvosi viziteket.

1.2. A dolgozat célja

Jelen dolgozat egy végponttól végpontig megvalósított bőrelváltozás-elemző rendszer tervezését és implementációját mutatja be, amely az ISIC 2024 versenydathalmazán [?] betanított Vision Transformer (ViT) [?] modellre épül.

A rendszer fő célkitűzései a következők:

- Egy Android mobilalkalmazás fejlesztése, amely lehetővé teszi a felhasználó számára, hogy fényképet készítsen vagy töltsön fel egy bőrelváltozásról, és azonnali, AI-alapú elemzést kapjon.
- A feltöltött kép minőségének és relevanciájának automatikus ellenőrzése egy nagy nyelvi modell (Gemini) segítségével, kiszűrve az értékelhetetlen vagy nem megfelelő felvételeket.
- A bőrelváltozás osztályozása *Benignus* vagy *Malignus* kategóriába egy ViT-alapú neurális háló-val, konfidencia-értékkel kiegészítve.

- Természetes nyelvű magyarázat és orvosi szempontú visszajelzés generálása a klasszifikációs eredmény alapján, az ABCDE-szabály ¹ figyelembevételével.
- A felhasználói interakciók és a feltöltött képek biztonságos tárolása felhőalapú infrastruktúrán.

Fontos hangsúlyozni, hogy a rendszer nem helyettesíti a szakorvosi diagnózist: kizárólag tájékoztató jellegű szűrőeszközként funkcionál, amely segíti a felhasználót abban, hogy időben döntsön a dermatológiai konzultáció szükségességéről.

1.3. A dolgozat felépítése

A dolgozat a következő fejezetekre tagolódik. A **Szakirodalom áttekintése** fejezetben bemutatjuk a mély tanulás bőrgyógyászati alkalmazásainak legfontosabb előzményeit, az ISIC adathalmazok fejlődését, valamint a Vision Transformer architektúra megjelenését és jelentőségét a képosztályozásban. Az **Elméleti áttekintés** fejezet a rendszer mögötti kulcstechnológiákat ismerteti: a ViT architektúrát, a Gemini nagy nyelvi modell alkalmazását, a server-küldött esemény (SSE) alapú streaming-protokolt, illetve a felhőalapú adattárolás elvét. A **Rendszer specifikációi** fejezet a funkcionális és nem-funkcionális követelményeket, valamint az architektúrális döntéseket részletezi. A **Gyakorlati megvalósítás** fejezet a backend, a mobilalkalmazás és a modell tanítási folyamatának implementációját tárgyalja. Az **Eredmények** fejezetben a modell teljesítményét értékeljük kvantitatív metrikák alapján, és bemutatjuk a rendszer működését valós képeken. Végül az **Összefoglalás** a dolgozat következtetéseit és a lehetséges jövőbeli fejlesztési irányokat foglalja össze.

¹ Aszimmetria, határvonala, szín, átmérő, evolúció – a melanoma gyanújelei.

2. fejezet

Szakirodalom áttekintése

2.1. Cím 1

2.1.1. Alcím 1

Táblázat:

Kritériumok	Vrep	ARGoS	Gazebo
Ingyenes	Igen, van fizetős verzió is	Igen	Igen
Absztrakciós szint	Valósághű	Emelkedett absztrakciós szintet ajánl	Valósághű
Robotrajokra optimalizált	Nem optimalizált	Teljesen optimalizált	Képes, nagyobb erőforrás-igény, mint az ARGOS-nak
Nyílt forráskódú	Igen	Igen	Igen
Támogatott programozási nyelvek	C/C++, Python, Java, Lua, Matlab, Octave	C/C++ és Lua	C/C++
Valós robotok modelljei	Igen	Igen	Igen

2.1. ábra. V-REP, ARGoS, Gazebo összehasonlítása

Hivatkozás a táblázatra: ??

3. fejezet

Elméleti áttekintés

3.1. Elméleti áttekintés

Pszeudokód:

Data: Tanulási tényező ($\alpha \in (0, 1]$), $\varepsilon > 0$

Véletlenszerű érték minden $Q_1(s, a)$ és $Q_2(s, a)$ -nek, kivéve $Q(\text{terminális}, \cdot) = 0$, $s \in S$, $a \in A$;

for minden *epizód* **do**

 S inicializálása;

repeat

$A \leftarrow$ cselekvés, S állapotban ε -greedy szerint $Q_1 + Q_2$;

A cselekedet végrehajtása, R és S' megfigyelése;

if 50% *eséllyel* **then**

$Q_1(S, A) \leftarrow Q_1(S, A) + \alpha[R + \gamma Q_2(S', \arg \max_a Q_1(S', a)) - Q_1(S, A)]$

else

$Q_2(S, A) \leftarrow Q_2(S, A) + \alpha[R + \gamma Q_1(S', \arg \max_a Q_2(S', a)) - Q_2(S, A)]$

end

$S \leftarrow S'$;

until S *terminális állapot*;

end

Algorithm 1: Dupla Q-tanulás [?].

Hivatkozás pszeudokódra: ??.

4. fejezet

Rendszer specifikációi

4.1. Cím 1

5. fejezet

Gyakorlati megvalósítás

5.1. Ágensek vezérlése

A model elkészítéséhez a következő lépéseket tettem meg: Data Preprocessing Feature Engineering Class imbalance megoldás, mivel a megadott adatbázisban.

Hivatkozásra példa

Az ágensek vezérléséhez a potenciálmező navigációs módszer volt felhasználva. Ez egy bevált módszer a robotrajok vezérléséhez [?]. Az alapötlete, hogy az akadályok taszító erővel hatnak az ágensre és a cél vonzó erővel. Ennek a két erőnek az eredője határozza meg az irányt amerre érdemes haladni.

5.1.1. Potenciálmező navigáció

Egyenletekre példa

A potenciálmező navigációs módszernél az erők nagysága az (??) egyenlet szerint van kiszámolva.

$$\begin{cases} |\vec{f}_{push}| = ae^{-\frac{(x-b_{push})^2}{2c_{push}^2}} \\ |\vec{f}_{pull}| = ae^{-\frac{(x-b_{pull})^2}{2c_{pull}^2}} \end{cases} \quad (5.1)$$

- a: Gauss görbe magassága

- b: Gauss görbe középpontja
- c: Gauss görbe szélessége

$$\vec{f}_{robot} = \sum_i \vec{f}_{push_i} + \sum_i \vec{f}_{pull_i} \quad (5.2)$$


Az eredő vektor a (??) képlet szerint volt kiszámolva.

6. fejezet

Eredmények

6.1. Cím 1

Eredmények leírása



6.1. ábra. 30 követő ágens, egy vezér

7. fejezet

Összefoglalás

7.1. Összefoglalás

A. függelék

Függelék

A.1. Alfejezet

A.1.1. Cím

Alcím