

Tartalomjegyzék

1. Bevezető	1
1.1. Motiváció és problémafelvetés	1
1.2. A dolgozat célja	2
1.3. A dolgozat felépítése	3
2. Szakirodalom és elméleti háttér	4
2.1. A bőrrák és a korai diagnózis jelentősége	4
2.1.1. A klinikai diagnosztikai folyamat	5
2.1.2. A hozzáférés korlátai	5
2.2. Klasszikus gépi tanulás a bőrelváltozások osztályozásában	6
2.3. A mély tanulás megjelenése: konvolúciós neurális hálók	6
2.4. A Vision Transformer és a figyelmi mechanizmus	7
2.5. Az ISIC adathalmazok és versenyek	8
2.6. Multimodális nagy nyelvi modellek a bőrgyógyászatban	9
2.7. A figyelmi mechanizmus és a Transformer	10
2.8. A Vision Transformer architektúrája	10
2.9. Átviteli tanulás és finomhangolás	12
2.10. Az osztály-egyensúlytalanság kezelése	12
2.11. Kiértékelési metrikák	13
2.12. Statisztikai elemzés	14
2.13. Kommunikációs technológiák: SSE és az MCP	15

3. Kutatási rész: a bőrelváltozás-osztályozó modell	16
4. Mérnöki rész: a DermAI alkalmazás	17
5. Összefoglalás és jövőbeli munka	18
5.1. Összefoglalás	18
Irodalomjegyzék	18
A. Függelék	23
A.1. Alfejezet	23
A.1.1. Cím	23

Ábrák jegyzéke

2.1. Az ABCDE-szabály vizuális kritériumai.	5
2.2. Reprezentatív minták az ISIC 2024 adathalmazból.	9
2.3. A Vision Transformer (ViT) sematikus felépítése.	11

1. fejezet

Bevezető

1.1. Motiváció és problémafelvetés

A bőrrák napjaink egyik legelterjedtebb daganatos megbetegedése. A Nemzetközi Rákkutató Ügynökség (IARC) GLOBOCAN-bebecslései szerint 2022-ben világszerte több mint 1,5 millió új bőrrákos esetet regisztráltak; ezen belül a melanomák száma megközelítőleg 331 700 volt, mintegy 58 700 halálessel [1]. Bár a melanoma a bőrrákos esetek kisebb hányadát teszi ki, a bőrrák okozta halálozás túlnyomó részéért felel, mivel a korai felismerés hiányában gyorsan áttétet képezhet, drasztikusan csökkentve a túlélési esélyeket. Az időben, még lokalizált stádiumban felismert melanoma öt éves relatív túlélési aránya közel 100%, míg távoli áttét megjelenése esetén ez mintegy 35%-ra csökken [2]. A korai diagnózis tehát nem csupán orvosi, hanem népegészségügyi szempontból is kritikus fontosságú.

A hagyományos diagnosztikai folyamat egy dermatológus által végzett vizuális vizsgálatot és dermatoszkópos értékelést foglal magában, amelyhez magas szintű szakmai tudás és speciális eszközök szükségesek. A világ számos részén, különösen vidéki térségekben és fejlődő országokban, a bőrgyógyászati szakellátáshoz való hozzáférés korlátozott, ami késedelmes diagnózishoz és rosszabb kimenetelhez vezet. Emellett még fejlett egészségügyi rendszerekben is előfordul, hogy a betegek hosszú várakozási idő után jutnak szakorvosi vizsgálathoz.

A mesterséges intelligencia, azon belül a mély tanulás megjelenése új lehetőségeket nyitott a bőrelváltozások automatikus osztályozásában. Az egyik úttörő tanulmányban Esteva és munkatársai kimutatták, hogy egy konvolúciós neurális háló bőrrák-osztályozásban eléri a tapasztalt dermatológusok

szintjét [3]. Ezt követően számos kutatás megerősítette, hogy a mélytanulás-alapú rendszerek képesek megközelíteni, sőt bizonyos feltételek mellett meghaladni az emberi szakértők teljesítményét [4, 5].

Ugyanakkor ezek a rendszerek kezdetben komoly korlátokkal rendelkeztek: kizárólag dermatoszkópos, nagy felbontású klinikai felvételeken működtek megbízhatóan, amelyek elkészítéséhez speciális eszközre és szakértelemre van szükség. A szelekciós torzítás is jelentős problémaként merült fel, hiszen az elérhető adathalmazok döntően klinikailag gyanús, már szakorvoshoz kerülő elváltozásokat tartalmaztak, ami a modellek általánosíthatóságát korlátozta. A HAM10000 [6], majd az ISIC versenysorozat adathalmazai [7, 8] lényegesen bővítették az elérhető annotált képanyagot, és egy egyéges értékelési keretet biztosítottak a kutatók számára.

Az okostelefonok elterjedése és folyamatosan fejlődő kamerarendszerei új perspektívát nyitottak: a bőrgyógyászati szűrés akár közvetlenül a beteg kezébe adható eszközöket is alkalmazhat. Egy ilyen rendszer képes lenne arra, hogy a felhasználó által készített fotó alapján jelezze, ha egy elváltozás szakorvosi vizsgálatot indokolhat, csökkentve ezzel mind a késői diagnózisok számát, mind az indokolatlan orvosi viziteket.

1.2. A dolgozat célja

Jelen dolgozat egy végponttól végpontig megvalósított bőrelváltozás-elemző rendszer tervezését és implementációját mutatja be, amely az ISIC 2024 versenyzadathalmazán [8] betanított Vision Transformer (ViT) [9] modellre épül.

A rendszer fő célkitűzései a következők:

- Egy Android mobilalkalmazás fejlesztése, amely lehetővé teszi a felhasználó számára, hogy fényképet készítsen vagy töltsön fel egy bőrelváltozásról, és azonnali, AI-alapú elemzést kapjon.
- A feltöltött kép minőségének és relevanciájának automatikus ellenőrzése egy nagy nyelvi modell (Gemini) segítségével, kiszűrve az értékelhetetlen vagy nem megfelelő felvételeket.
- A bőrelváltozás osztályozása *Benignus* vagy *Malignus* kategóriába egy ViT-alapú neurális hálóval, konfidencia-értékkal kiegészítve.

- Természetes nyelvű magyarázat és orvosi szempontú visszajelzés generálása a klasszifikációs eredmény alapján, az ABCDE-szabály ¹ figyelembevételével.
- A felhasználói interakciók és a feltöltött képek biztonságos tárolása felhőalapú infrastruktúrán.

Fontos hangsúlyozni, hogy a rendszer nem helyettesíti a szakorvosi diagnózist: kizárólag tájékoztató jellegű szűrőeszközként funkcionál, amely segíti a felhasználót abban, hogy időben döntsön a dermatológiai konzultáció szükségességéről.

1.3. A dolgozat felépítése

A dolgozat a következő fejezetekre tagolódik. A **Szakirodalom és elméleti háttér** fejezet áttekinti a bőrelváltozások gépi tanulással történő osztályozásának előzményeit – a konvolúciós neurális hálólóktól a Vision Transformer megjelenéséig –, az ISIC adathalmazok fejlődését, valamint ismerteti a rendszer mögötti kulcstechnológiákat: a ViT architektúrát, a figyelmi (attention) mechanizmust, az osztály-egyensúlytalanság kezelését, a kiértékelési metrikákat, illetve a nagy nyelvi modellek és a streaming-kommunikáció elvét. A **Kutatási rész** a bőrelváltozás-osztályozó modell fejlesztését és kiértékelését tárgyalja: az ISIC 2024 adathalmaz előkészítését, a ViT betanítását, a viszonyítási alapként szolgáló ResNet-18 és Gemini modelleket, valamint a kvantitatív eredményeket és a statisztikai elemzést. A **Mérnöki rész** a DermAI rendszer megvalósítását mutatja be: a követelményeket, a rendszerarchitektúrát, a modellkiszolgálást, a backendet, a mobil- és webalkalmazást, valamint a hitelesítést és a felhőalapú adattárolást. Végül az **Összefoglalás és jövőbeli munka** fejezet a dolgozat következtetéseit és a lehetséges továbbfejlesztési irányokat foglalja össze.

¹ Aszimmetria, határvonal, szín, átmérő, evolúció – a melanoma gyanújelei.

2. fejezet

Szakirodalom és elméleti háttér

Ez a fejezet két nagyobb egységből áll. Az első rész a bőrelváltozások gépi tanulással történő osztályozásának szakirodalmi előzményeit tekinti át – a klinikai diagnosztikai gyakorlattól a klasszikus gépi tanuláson és a konvolúciós neurális hálókön át a Vision Transformer és a multimodális nagy nyelvi modellek megjelenéséig. A második rész a dolgozatban felhasznált kulcstechnológiák elméleti háttérét ismerteti.

2.1. A bőrrák és a korai diagnózis jelentősége

A bőrrák a leggyakrabban diagnosztizált rosszindulatú daganatok közé tartozik világszerte. A Nemzetközi Rákkutató Ügynökség (IARC) GLOBOCAN-bebecslései szerint 2022-ben több mint 1,5 millió új bőrrákos esetet regisztráltak, ezen belül a melanomák száma megközelítőleg 331 700 volt, mintegy 58 700 halálesettel [1]. Bár a melanoma a bőrrákos esetek kisebb hányadát teszi ki, agresszív viselkedése és áttétképző hajlama miatt a bőrrák okozta halálozás túlnyomó részéért felel.

A betegség kimenetele döntően a felismerés stádiumától függ. A még lokalizált stádiumban diagnosztizált melanoma ötéves relatív túlélési aránya közel 100%, míg távoli áttét megjelenése esetén ez mintegy 35%-ra csökken [2]. Ez a markáns különbség teszi a korai felismerést népegészségügyi szempontból kiemelten fontossá: a diagnózis néhány hónapos késedelve is jelentősen ronthatja a beteg túlélési esélyeit.

2.1.1. A klinikai diagnosztikai folyamat

A melanoma klinikai gyanúja jellemzően vizuális vizsgálat alapján merül fel, amelyet dermatoszkópos értékelés egészít ki; a végleges diagnózist minden esetben szövettani vizsgálat (hisztopatológia) erősíti meg [10]. A magas kockázatú betegek nyomon követésében a szekvenciális digitális dermatoszkópia és a teljes testfelszín fényképezése segíti a korai melanomák kiszűrését [10]. Ez a folyamat magas szintű szakmai tapasztalatot és speciális eszközöket igényel.

A pigmentált bőrelváltozások szabad szemmel történő, gyors megítélését a klinikai gyakorlatban az úgynevezett ABCDE-szabály támogatja. A betűszó a melanomára jellemző öt figyelmeztető jeget foglalja össze: aszimmetria (*Asymmetry*), szabálytalan határvonal (*Border*), színbeli heterogenitás (*Color*), 6 mm-t meghaladó átmérő (*Diameter*), valamint az elváltozás időbeli változása (*Evolving*); az utóbbi, ötödik kritériummal Abbasi és munkatársai egészítették ki az eredeti ABCD-szabályt, hangsúlyozva a fejlődő elváltozások jelentőségét [11]. Az ABCDE-szabály egyszerűsége miatt mind a szakemberek, mind a betegek számára jól használható, ugyanakkor önmagában nem helyettesíti a műszeres és szövettani vizsgálatot.

[Ábra helye] – Az ABCDE-szabály szemléltetése: jóindulatú és rosszindulatú pigmentált elváltozások összehasonlítása. (Saját vagy jogtiszta forrásból származó ábrát illessz be.)

2.1. ábra. Az ABCDE-szabály vizuális kritériumai.

2.1.2. A hozzáférés korlátai

A bőrgyógyászati szakellátáshoz való hozzáférés világszerte egyenetlen. Vidéki térségekben és alacsonyabb jövedelmű országokban a szakorvosi kapacitás korlátozott, ami késedelmes diagnózishoz vezet; de még fejlett egészségügyi rendszerekben is jelentős várakozási idővel kell számolni a szakvizsgálatig. Ez a hozzáférési szakadék motiválja az olyan automatizált, akár okostelefonon is futó szűrőeszközök fejlesztését, amelyek elsődleges triázsként jelezhetik, ha egy elváltozás szakorvosi

vizsgálatot indokol.

2.2. Klasszikus gépi tanulás a bőrelváltozások osztályozásában

A mélytanulás elterjedése előtt a bőrelváltozás-osztályozó rendszerek jellemzően kétlépcsős felépítést követtek: először kézzel tervezett jellemzőket (*handcrafted features*) nyertek ki a képből, majd ezeken egy klasszikus gépi tanulási osztályozót – például tartóvektor-gépet (SVM), döntési fát vagy véletlen erdőt (Random Forest) – tanítottak be. A jellemzők gyakran közvetlenül az orvosi szempontokat tükrözték: az ABCDE-szabályhoz kapcsolódó alaki (aszimmetria, határvonal), színbeli (színmomentumok, hisztogramok) és textúra jellemzőket (például a szürkeszintű együttes előfordulási mátrixból, GLCM számított mutatókat).

Kassem és munkatársai szisztematikus áttekintése a terület módszertani fejlődését dokumentálja, és rámutat, hogy a klasszikus, kézi jellemzőkön alapuló megközelítések teljesítményét erősen korlátozza a jellemzőtervezés minősége és a felvételi körülmények (megvilágítás, felbontás, műtermékek) iránti érzékenység [12]. Ezek a rendszerek jellemzően jól kontrollált, dermatoszkópos felvételeken működtek megbízhatóan, általánosító képességük azonban korlátozott maradt. Mindazonáltal a kézi jellemzőkön alapuló osztályozók a mai napig értékes *viszonyítási alapként* (baseline) szolgálnak, mivel gyorsak, értelmezhetők, és megmutatják, mekkora teljesítmény érhető el a reprezentáció automatikus tanulása nélkül.

2.3. A mély tanulás megjelenése: konvolúciós neurális hálók

A konvolúciós neurális hálók (CNN-ek) áttörést hoztak a képosztályozásban azzal, hogy a jellemzőkinyerést és az osztályozást egyetlen, végponttól végpontig tanítható modellbe integrálták, megszüntetve a kézi jellemzőtervezés szükségességét. A bőrgyógyászati alkalmazások egyik úttörő munkájában Esteva és munkatársai kimutatták, hogy egy nagy képadatbázison előtanított CNN a bőrrák osztályozásában eléri a tapasztalt dermatológusok teljesítményét [3]. Ezt követően több vizsgálat is megerősítette, hogy a mélytanulás-alapú rendszerek megközelíthetik, sőt bizonyos, jól körülhatárolt feladatokban meg is haladhatják az emberi szakértők teljesítményét: Haenssle és munkatársai egy

CNN-t 58 dermatológussal vetettek össze dermatoszkópos melanoma-felismerésben [4], Brinker és munkatársai pedig arról számoltak be, hogy mély neurális hálók a melanoma képi osztályozásában felülmúlták a bevont bőrgyógyászokat [5].

E rendszerek teljesítményének kulcsa az *átviteli tanulás* (transfer learning): a modelleket először egy nagy, általános képadatbázison – jellemzően az ImageNet adathalmazon [13] – tanítják be, majd a megtanult vizuális reprezentációkat a jóval kisebb orvosi adathalmazra finomítják (fine-tuning). Az architektúrák fejlődése szintén hozzájárult az eredmények javulásához: a reziduális kapcsolatokat bevezető ResNet [14] lehetővé tette a nagyon mély hálók stabil tanítását, az EfficientNet pedig a hálózat mélységének, szélességének és felbontásának együttes, kiegyensúlyozott skálázásával ért el kedvező teljesítmény-paraméterszám arányt [15].

A korai rendszerek fontos korlátja volt, hogy elsősorban dermatoszkópos, nagy felbontású klinikai felvételeken működtek megbízhatóan, amelyek elkészítéséhez speciális eszköz és szakértelem szükséges. Emellett a szelekciós torzítás is jelentős problémát jelentett: az elérhető adathalmazok döntően már szakorvoshoz került, klinikailag gyanús elváltozásokat tartalmaztak, ami tovább korlátozta a modellek általánosíthatóságát hétköznapi felvételekre.

2.4. A Vision Transformer és a figyelmi mechanizmus

A természetesnyelv-feldolgozásban bevezetett Transformer-architektúra a *figyelmi* (attention) mechanizmusra épül, amely a bemenet elemei közötti összes páronkénti kapcsolatot képes közvetlenül modellezni, függetlenül azok távolságától [16]. Ezt az elvet a képosztályozásra a Vision Transformer (ViT) ültette át: a képet rögzített méretű foltokra (*patch*) bontja, ezeket lineárisan beágyazza, majd egy Transformer-kódoló dolgozza fel őket [9]. A konvolúciós hálókkal szemben a ViT nem rendelkezik beépített képi induktív torzítással (mint a lokalitás vagy az eltolás-invariancia), így a globális összefüggéseket rugalmasabban tanulja meg, cserébe viszont jellemzően nagyobb tanítóadatra vagy erőteljes előtanításra van szüksége a jó általánosításhoz [9].

A ViT-architektúra a bőrgyógyászati képosztályozásban is megjelent. Dagnaw és munkatársai például Vision Transformer és konvolúciós modelleket vetettek össze magyarázható mesterséges intelligencia (XAI) technikákkal kiegészítve, és a ViT-alapú, illetve a CNN-alapú modellek esetében

hasznos nagyságrendű pontosságot mértek [17]. Ez a megfigyelés alátámasztja, hogy a két architektúracsatlás összevetése – pontosan kontrollált, azonos adat- és tanítási feltételek mellett – önmagában is érdemi tudományos kérdés, amelyre a dolgozat kutatási része is kitér.

2.5. Az ISIC adathalmazok és versenyek

A bőrelváltozás-osztályozás kutatását jelentősen előmozdította az annotált, nyilvánosan elérhető adathalmazok megjelenése. A HAM10000 adathalmaz 10 015, több forrásból származó dermatoszkópos felvételt tartalmaz a gyakori pigmentált elváltozásokról, és egységes kiértékelési keretet biztosított a kutatóknak [6]. A Nemzetközi Bőrképzési Együttműködés (ISIC) versenysorozata tovább bővítette az elérhető képanyagot; Rotemberg és munkatársai egy beteg-központú, a képek mellett klinikai metaadatokat is tartalmazó adathalmazt mutattak be, hangsúlyozva a klinikai kontextus szerepét a melanoma azonosításában [7].

A jelen dolgozat szempontjából kiemelt jelentőségű az ISIC 2024 verseny (*Skin Cancer Detection with 3D-TBP*), amely a teljes testfelszín háromdimenziós fényképezéséből (3D total-body photography) kivágott, mintegy 400 000 elváltozás-képet tartalmaz, és binárisan – rosszindulatú vagy jóindulatú-to-intermedier kategóriába – történő osztályozást tűz ki célul [8]. Ezek a kivágott felvételek minőségükben közelebb állnak a hétköznapi, akár okostelefonnal készíthető képekhez, mint a klasszikus, nagy felbontású dermatoszkópos felvételek, ami a valós felhasználási helyzethez közelíti a feladatot.

Az ISIC 2024 adathalmaz egyik meghatározó jellemzője a rendkívül erős *osztály-egyensúlytalanság*: a rosszindulatú esetek a teljes adathalmaznak csupán töredékét (nagyságrendileg ezredrészét) teszik ki. Ennek megfelelően a verseny nem a hagyományos pontosságot, hanem a 80%-os érzékenység (true positive rate) feletti tartományra korlátozott, részleges görbe alatti területet (partial AUC) használja elsődleges metrikaként, amely orvosi releváns módon a magas érzékenységi tartományban méri a modellek teljesítményét [8]. Az osztály-egyensúlytalanság kezelésének módszertani hátterét, valamint a kiértékelési metrikák pontos definícióját e fejezet elméleti része tárgyalja részletesen.

[Ábra helye] – Példák az ISIC 2024 adathalmazból: jóindulatú (felső sor) és rosszindulatú (alsó sor) bőrelváltozások 3D-TBP kivágott felvételei.

2.2. ábra. Reprezentatív minták az ISIC 2024 adathalmazból.

2.6. Multimodális nagy nyelvi modellek a bőrgyógyászatban

A legutóbbi években a multimodális nagy nyelvi modellek (multimodal large language models, MLLM-ek) megjelenése új lehetőségeket nyitott az orvosi képértelmezésben. Ezek a modellek – mint a Google Gemini-családja [18] – egyszerre képesek képi és szöveges bemenet feldolgozására, és természetes nyelvű magyarázatot, indoklást is tudnak generálni.

A bőrgyógyászati alkalmazásukat több vizsgálat is értékelte. Cirone és munkatársai a GPT-4 Vision és a LLaVA modelleket vetették össze melanoma és jóindulatú elváltozások megkülönböztetésében, és azt találták, hogy a GPT-4V lényegesen jobban teljesített (85% pontosság a LLaVA 45%-ával szemben), ugyanakkor mindkét modell teljesítménye érzékelhetően romlott a sötétebb bőrtónusok esetén – ami a reprezentációs torzítás kockázatára és a sokszínűbb adathalmazok szükségességére hívja fel a figyelmet [19]. Zhou és munkatársai célzottan bőrgyógyászati rendszert építettek (SkinGPT-4), amelyben egy előtanított Vision Transformert egy nagy nyelvi modellel kapcsoltak össze, és valós eseteken értékelték autonóm diagnosztikai képességét [20].

E munkák tanulsága kettős. Egyrészt a multimodális nyelvi modellek erőssége a természetes nyelvű magyarázat és a felhasználóval folytatott párbeszéd, nem pedig a megbízható, kalibrált osztályozás – különösen erős osztály-egyensúlytalanság mellett. Másrészt a teljesítményük populációk közötti egyenetlensége óvatosságra int a klinikai felhasználásban. Ezek a megfontolások közvetlenül indokolják a jelen dolgozatban követett tervezési döntést: a *klasszifikációt* egy célzottan betanított, kalibrált képi modell (ViT) végzi, míg a nagy nyelvi modell (Gemini) szerepe a kép minőségének ellenőrzésére, az eredmény közérthető magyarázatára és a felhasználói kérdések megválaszolására korlátozódik. E

munkamegosztás részletes tárgyalása és empirikus alátámasztása a dolgozat kutatási, illetve mérnöki részében található.

A fejezet hátralévő része a dolgozatban felhasznált kulcstechnológiák elméleti háttérét ismerteti: a figyelmi mechanizmustól és a Vision Transformer felépítésétől az osztály-egyensúlytalanság kezelésén és a kiértékelési metrikákon át a kliens–szerver kommunikáció technológiáig.

2.7. A figyelmi mechanizmus és a Transformer

A Transformer-architektúra alapja az úgynevezett *skálázott pontszorzatos figyelem* (scaled dot-product attention), amely a bemenet elemei közötti összefüggéseket azok távolságától függetlenül modellezi [16]. A mechanizmus minden bemeneti elemhez három vektort rendel: egy lekérdezést (Q , query), egy kulcsot (K , key) és egy értéket (V , value). A kimenet az értékvektorok súlyozott összege, ahol a súlyokat a lekérdezések és kulcsok hasonlósága határozza meg:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V, \quad (2.1)$$

ahol d_k a kulcsvektorok dimenziója; a $\sqrt{d_k}$ skálázó tényező a pontszorzatok nagyságát stabilizálja, megakadályozva a softmax telítődését. A gyakorlatban a modell több, párhuzamos figyelmi „fejet” (multi-head attention) alkalmaz, amelyek különböző reprezentációs alterekben tanulnak összefüggéseket, így gazdagabb leírást képesek megragadni [16].

A Transformer-kódoló e figyelmi rétegeket helyzetenkénti, teljesen összekötött előreccsatolt rétegekkel (feed-forward), maradék (reziduális) kapcsolatokkal és rétegnormalizálással kombinálja. Mivel a figyelem önmagában érzéketlen az elemek sorrendjére, a bemenethez *helyzetkódolást* (positional encoding) adnak, amely a sorrendi információt visszacsempészi a modellbe.

2.8. A Vision Transformer architektúrája

A Vision Transformer (ViT) a természetesnyelv-feldolgozásban bevált Transformer-kódolót ülteti át a képosztályozásra [9]. A feldolgozás lépései a következők:

1. **Foltokra bontás és beágyazás.** A $H \times W$ méretű bemeneti képet rögzített méretű, nem átfedő foltokra (jellemzően 16×16 pixel) bontja. Minden foltot vektorrá lapít, majd egy lineáris vetítés egy rögzített dimenziójú beágyazási térbe képezi – ezek a „képtokenek”, a nyelvi modellek szótokenjeinek analógiái.
2. **Osztályozó token és helyzetkódolás.** A foltbeágyazások elé egy tanulható osztályozó token ([CLS]) fűz, amely a teljes kép összegzett reprezentációját hivatott hordozni. A sorrendi (térbeli) információt tanulható helyzetkódolás biztosítja.
3. **Transformer-kódoló.** A tokensorozatot több, egymásra épülő Transformer-kódoló réteg dolgozza fel; a többfejű önfigyelem révén minden folt közvetlen kapcsolatba kerülhet az összes többivel, így a modell a kép globális összefüggéseit is megragadja.
4. **Osztályozó fej.** A végső réteg [CLS] tokenjének reprezentációjára egy osztályozó fej (jellemzően egy- vagy kétrétegű perceptron) épül, amely az osztályok feletti döntést szolgáltatja.

A konvolúciós hálókkal szemben a ViT nem rendelkezik beépített képi induktív torzítással (lokalitás, eltolás-invariancia), ezért nagyobb adatmennyiséget vagy erős előtanítást igényel; cserébe a globális összefüggéseket rugalmasabban modellezi, és nagy adathalmazokon a CNN-ekkel versenyképes vagy azokat meghaladó teljesítményt ér el [9].

[Ábra helye] – A Vision Transformer feldolgozási folyamata: a kép foltokra bontása, lineáris beágyazás, helyzetkódolás, Transformer-kódoló rétegek, valamint a [CLS] tokenre épülő osztályozó fej. (Saját szerkesztésű ábrát illessz be.)

2.3. ábra. A Vision Transformer (ViT) sematikus felépítése.

2.9. Átviteli tanulás és finomhangolás

Az orvosi képadatok jellemzően korlátozott mennyiségben állnak rendelkezésre, ami megnehezíti a nagy kapacitású modellek – különösen a ViT – nulláról történő betanítását. Az *átviteli tanulás* (transfer learning) erre kínál megoldást: a modellt először egy nagy, általános képadatbázison (jellemzően az ImageNet adathalmazon [13]) tanítják be, ahol általános vizuális reprezentációkat – éleket, textúrákat, alakzatokat – sajátít el. Az így előtanított modellt ezután a célfeladat kisebb adathalmazán *finomhangolják* (fine-tuning).

A finomhangolás során bevett gyakorlat a *differenciált tanulási ráta* alkalmazása: az előtanított törzshálót (backbone) kis tanulási rátával frissítik, hogy a megtanult reprezentációk ne sérüljenek, míg az újonnan inicializált osztályozó fejet nagyobb rátával tanítják, mivel azt a feladatra nulláról kell megtanulni. A tanulás stabilitását a *bemelegítés* (warmup) is segíti, amely a kezdeti néhány epochban fokozatosan emeli a tanulási rátát, megelőzve a hideg fej által okozott nagy, destabilizáló lépéseket.

2.10. Az osztály-egyensúlytalanság kezelése

Az orvosi szűrési feladatok jellemzően erősen kiegyensúlyozatlanok: a pozitív (beteg) esetek a teljes adathalmaznak csupán töredékét teszik ki. Ilyenkor a hagyományos keresztentrópia-veszteséget a sok, könnyen osztályozható negatív példa uralja, és a modell hajlamos a többségi osztály felé torzítani. A szakirodalom több, egymást kiegészítő technikát kínál e probléma kezelésére.

Súlyozott mintavételezés. Az egyik megközelítés a tanító batch-ek osztályeloszlásának kiegyensúlyozása: minden mintát az osztálya gyakoriságával fordítottan arányos súllyal választunk, így a ritka pozitív esetek a tanítás során felülreprezentálttá válnak.

Fókuszveszteség (focal loss). A Lin és munkatársai által bevezetett fókuszveszteség a keresztentrópiát úgy alakítja át, hogy a jól osztályozott példák hozzájárulását lecsökkenti, és a tanulást a nehéz, félreosztályozott esetekre összpontosítja [21]:

$$\text{FL}(p_t) = -\alpha_t (1 - p_t)^\gamma \log(p_t), \quad (2.2)$$

ahol p_t a helyes osztályhoz rendelt becsült valószínűség, $\gamma \geq 0$ a fókuszáló paraméter (amely a könnyű példák súlyát csökkenti), α_t pedig egy osztállysúly, amely a pozitív és negatív esetek közötti egyensúlyt finomhangolja. A $\gamma = 0$ választás visszaadja a súlyozott keresztentropiát.

Kétfázisú tanítás. A kiegyensúlyozott mintavételezés mellett betanított modell kimeneti valószínűségei eltérhetnek a valós, erősen kiegyensúlyozatlan előfordulási aránytól. Ezt egy második, kalibráló fázis korrigálhatja, amelyben a modellt a valós eloszlású adaton, kisebb tanulási rátával tanítjuk tovább, így a kimeneti valószínűségek a tényleges priorhoz igazodnak.

2.11. Kiértékelési metrikák

Erősen kiegyensúlyozatlan feladatban a nyers pontosság (accuracy) félrevezető, hiszen a többségi osztály triviális megjósolásával is magas érték érhető el. Ezért orvosi szűrésnél a tévesztés-mátrixból (confusion matrix) származtatott, osztályérzékeny metrikákat alkalmazunk. Jelölje TP , TN , FP és FN rendre a valódi pozitív, valódi negatív, hamis pozitív és hamis negatív esetek számát.

$$\text{Érzékenység (sensitivity)} = \frac{TP}{TP + FN}, \quad \text{Specifitás (specificity)} = \frac{TN}{TN + FP}, \quad (2.3)$$

$$\text{PPV} = \frac{TP}{TP + FP}, \quad \text{NPV} = \frac{TN}{TN + FN}. \quad (2.4)$$

Az **érzékenység** azt méri, hogy a modell a valóban rosszindulatú eseteknek mekkora hányadát ismeri fel – szűrőeszköznél ez a legkritikusabb mutató, mivel a fel nem ismert rák (hamis negatív) a legsúlyosabb kimenetel. A **negatív prediktív érték** (NPV) azt fejezi ki, hogy a „jóindulatú” besorolás mennyire megbízható.

ROC-görbe és AUC. A bináris osztályozók döntési küszöbtől független értékelésére a *működési jelleggörbét* (Receiver Operating Characteristic, ROC) használjuk, amely a valódi pozitív arányt (érzékenység) a hamis pozitív arány ($FPR = FP / (FP + TN)$) függvényében ábrázolja a küszöb változtatásával. A görbe alatti terület (Area Under the Curve, AUC) egyetlen számba sűríti a rangsorolási képességet: értéke 0,5 (véletlen találgatás) és 1,0 (tökéletes elkülönítés) között mozog.

Részleges AUC (pAUC). Erős egyensúlytalanságnál és klinikai kontextusban gyakran csak a görbe egy meghatározott szakasza érdekes. Az ISIC 2024 verseny elsődleges metrikája a 80%-os érzékenység feletti tartományra korlátozott részleges AUC (partial AUC), amely kifejezetten a klinikailag elvárt, magas érzékenységi tartományban méri a teljesítményt; a metrika értéke $[0, 0,2]$ tartományba esik, ahol 0,2 a tökéletes osztályozó értéke [8].

Kalibráció és Brier-pontszám. A jó rangsorolás (magas AUC) nem garantálja, hogy a modell által kiadott valószínűségek megbízhatóak. A *kalibráció* azt méri, hogy a becsült valószínűségek mennyire felelnek meg a tényleges bekövetkezési aránynak; Guo és munkatársai rámutattak, hogy a modern neurális hálók gyakran rosszul kalibráltak [22]. A kalibráció egyik összegző mérőszáma a Brier-pontszám, a becsült valószínűség és a tényleges címke közötti átlagos négyzetes eltérés:

$$\text{Brier} = \frac{1}{N} \sum_{i=1}^N (p_i - y_i)^2, \quad (2.5)$$

ahol p_i a i -edik mintára becsült valószínűség, $y_i \in \{0, 1\}$ a valódi címke; az alacsonyabb érték jobb kalibrációt jelez.

2.12. Statisztikai elemzés

Mivel a tesztalmazban a pozitív esetek száma korlátozott, a pontbecslések (érzékenység, specificitás, AUC) mellett azok bizonytalanságát is jelölni kell. Az arányjellegű metrikákhoz (érzékenység, specificitás) az egzakt, binomiális eloszláson alapuló Clopper–Pearson-féle konfidencia-intervallum ad megbízható becslést kis mintaszám esetén is. Az AUC esetében a DeLong-féle, nemparaméteres módszer szolgáltat konfidencia-intervallumot, illetve teszi lehetővé két modell AUC-értékének páros összehasonlítását; a módszer egy gyors, korszerű implementációját Sun és Xu adta meg [23]. E statisztikai eszközök biztosítják, hogy a modellek közötti különbségekről tett állítások ne csupán a mintavételi zaj következményei legyenek.

2.13. Kommunikációs technológiák: SSE és az MCP

A dolgozatban bemutatott rendszer valós idejű, token-szintű válaszközvetítést és egy nyelvi modellt kiszolgáló komponensekkel való kommunikációt igényel; ezt két technológia teszi lehetővé.

Szerver-küldött események (SSE). A szerver-küldött események (Server-Sent Events) a HTML szabvány részét képező, egyirányú, szerverről kliensre irányuló adatfolyam-mechanizmus egyetlen, tartós HTTP-kapcsolaton keresztül [24]. Az SSE különösen alkalmas a nagy nyelvi modellek token-szintű, fokozatos válaszainak továbbítására, mivel a kliens a szöveget generálással egyidejűleg, darabonként jeleníti meg, jelentősen javítva a felhasználói élményt.

Model Context Protocol (MCP). A Model Context Protocol az Anthropic által 2024-ben közzétett nyílt szabvány, amely egységesíti a nagy nyelvi modellek és a külső eszközök, adatforrások közötti kommunikációt [25]. Az MCP a JSON-RPC 2.0 üzenetformátumra épül [26], és többféle átviteli réteget támogat, többek között a helyi folyamatok közötti szabványos be- és kimeneti (stdio) csatornát. A dolgozat rendszerében az MCP biztosítja a backend és a modellt kiszolgáló komponens közötti, jól strukturált kommunikációt; e megoldás részletes tárgyalása a mérnöki részben található.

3. fejezet

Kutatási rész: a bőrelváltozás-osztályozó modell

4. fejezet

Mérnöki rész: a DermAI alkalmazás

5. fejezet

Összefoglalás és jövőbeli munka

5.1. Összefoglalás

Irodalomjegyzék

- [1] International Agency for Research on Cancer, „Melanoma of skin — GLOBOCAN 2022.” Global Cancer Observatory, World Health Organization, 2024. <https://gco.iarc.who.int/media/globocan/factsheets/cancers/16-melanoma-of-skin-fact-sheet.pdf>.
- [2] National Cancer Institute, „Cancer stat facts: Melanoma of the skin.” Surveillance, Epidemiology, and End Results (SEER) Program, 2024. <https://seer.cancer.gov/statfacts/html/melan.html>.
- [3] A. Esteva, B. Kuprel, R. A. Novoa, J. Ko, S. M. Swetter, H. M. Blau, and S. Thrun, „Dermatologist-level classification of skin cancer with deep neural networks,” *Nature*, vol. 542, no. 7639, pp. 115–118, 2017.
- [4] H. A. Haenssle, C. Fink, R. Schneiderbauer, F. Toberer, T. Buhl, A. Blum, A. Kalloo, A. B. H. Hassen, L. Thomas, A. Enk, *et al.*, „Man against machine: diagnostic performance of a deep learning convolutional neural network for dermoscopic melanoma recognition in comparison to 58 dermatologists,” *Annals of Oncology*, vol. 29, no. 8, pp. 1836–1842, 2018.
- [5] T. J. Brinker, A. Hekler, A. H. Enk, J. Klode, A. Hauschild, C. Berking, B. Schilling, S. Haferkamp, D. Schadendorf, M. Schlaak, *et al.*, „Deep neural networks are superior to dermatologists in melanoma image classification,” *European Journal of Cancer*, vol. 119, pp. 11–17, 2019.
- [6] P. Tschandl, C. Rosendahl, and H. Kittler, „The HAM10000 dataset, a large collection of multi-source dermoscopic images of common pigmented skin lesions,” *Scientific Data*, vol. 5, no. 1, pp. 1–9, 2018.

- [7] V. Rotemberg, N. Kurtansky, B. Betz-Stablein, L. Caffery, E. Chousakos, N. Codella, M. Combalia, S. Dusza, P. Guitera, D. Gutman, *et al.*, „A patient-centric dataset of images and metadata for identifying melanomas using clinical context,” *Scientific Data*, vol. 8, no. 1, p. 34, 2021.
- [8] ISIC Archive, „ISIC 2024 – skin cancer detection with 3D-TBP.” <https://www.kaggle.com/competitions/isic-2024-challenge/>, 2024. Kaggle verseny.
- [9] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, *et al.*, „An image is worth 16x16 words: Transformers for image recognition at scale,” in *International Conference on Learning Representations*, 2021.
- [10] C. Garbe, T. Amaral, K. Peris, A. Hauschild, P. Arenberger, *et al.*, „European consensus-based interdisciplinary guideline for melanoma. Part 1: Diagnostics: Update 2022,” *European Journal of Cancer*, vol. 170, pp. 236–255, 2022.
- [11] N. R. Abbasi, H. M. Shaw, D. S. Rigel, R. J. Friedman, W. H. McCarthy, I. Osman, A. W. Kopf, and D. Polsky, „Early diagnosis of cutaneous melanoma: revisiting the ABCD criteria,” *JAMA*, vol. 292, no. 22, pp. 2771–2776, 2004.
- [12] M. A. Kassem, K. M. Hosny, R. Damasevicius, and M. M. Eltoukhy, „Machine learning and deep learning methods for skin lesion classification and diagnosis: a systematic review,” *Diagnostics*, vol. 11, no. 8, 2021.
- [13] O. Russakovsky, J. Deng, H. Su, J. Krause, S. Satheesh, S. Ma, Z. Huang, A. Karpathy, A. Khosla, M. Bernstein, A. C. Berg, and L. Fei-Fei, „ImageNet large scale visual recognition challenge,” *International Journal of Computer Vision*, vol. 115, no. 3, pp. 211–252, 2015.
- [14] K. He, X. Zhang, S. Ren, and J. Sun, „Deep residual learning for image recognition,” in *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 770–778, 2016.
- [15] M. Tan and Q. Le, „EfficientNet: Rethinking model scaling for convolutional neural networks,” in *International Conference on Machine Learning*, pp. 6105–6114, PMLR, 2019.

- [16] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, „Attention is all you need,” *Advances in Neural Information Processing Systems*, vol. 30, 2017.
- [17] G. H. Dagnaw, M. El Mouhtadi, and M. Mustapha, „Skin cancer classification using vision transformers and explainable artificial intelligence,” *Journal of Medical Artificial Intelligence*, vol. 7, 2024.
- [18] Gemini Team, Google, „Gemini: A family of highly capable multimodal models.” arXiv preprint arXiv:2312.11805, 2023. <https://arxiv.org/abs/2312.11805>.
- [19] K. Cirone, M. Akrou, L. Abid, and A. Oakley, „Assessing the utility of multimodal large language models (GPT-4 vision and large language and vision assistant) in identifying melanoma across different skin tones,” *JMIR Dermatology*, vol. 7, p. e55508, 2024.
- [20] J. Zhou, X. He, L. Sun, J. Xu, X. Chen, Y. Chu, L. Zhou, X. Liao, B. Zhang, S. Afvari, and X. Gao, „Pre-trained multimodal large language model enhances dermatological diagnosis using SkinGPT-4,” *Nature Communications*, vol. 15, p. 5649, 2024.
- [21] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, „Focal loss for dense object detection,” in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pp. 2980–2988, 2017.
- [22] C. Guo, G. Pleiss, Y. Sun, and K. Q. Weinberger, „On calibration of modern neural networks,” in *Proceedings of the 34th International Conference on Machine Learning (ICML)*, vol. 70, pp. 1321–1330, PMLR, 2017.
- [23] X. Sun and W. Xu, „Fast implementation of DeLong’s algorithm for comparing the areas under correlated receiver operating characteristic curves,” *IEEE Signal Processing Letters*, vol. 21, no. 11, pp. 1389–1393, 2014.
- [24] WHATWG, „HTML living standard — server-sent events,” 2024. <https://html.spec.whatwg.org/multipage/server-sent-events.html>.

- [25] Anthropic, „Model context protocol – specification.” Open standard, 2024. <https://modelcontextprotocol.io/specification>.
- [26] JSON-RPC Working Group, „JSON-RPC 2.0 specification,” 2013. <https://www.jsonrpc.org/specification>.

A. függelék

Függelék

A.1. Alfejezet

A.1.1. Cím

Alcím