

SAPIENTIA ERDÉLYI MAGYAR TUDOMÁNYEGYETEM

MAROSVÁSÁRHELYI KAR

SZÁMÍTÁSTECHNIKA SZAK

**BŐRELVÁLTOZÁSOK ROSSZINDULATÚSÁGÁNAK
OSZTÁLYOZÁSA VISION TRANSFORMER MODELLEL
ÉS SZÁMÍTÁSTECHNIKAI ALKALMAZÁSA**

Vezetőtanár:

Dr. Iclănzan David Andrei docens

Hallgató:

Fábián Ervin

Marosvásárhely, 2026

UNIVERSITATEA „SAPIENTIA” DIN CLUJ-NAPOCA
FACULTATEA DE ȘTIINȚE TEHNICE ȘI UMANISTE, TÎRGU-MUREȘ
SPECIALIZAREA CALCULATOARE

CLASIFICAREA MALIGNITĂȚII LEZIUNILOR CUTANATE
CU UN MODEL VISION TRANSFORMER
ȘI APLICAREA SA INFORMATICĂ

Coordonator științific:
Conf. Dr. Iclănzan David Andrei

Absolvent:
Fábián Ervin

Târgu-Mureș, 2026

UNIVERSITATEA „SAPIENTIA” din CLUJ-NAPOCA Facultatea de Științe Tehnice și Umaniste din Târgu Mureș Specializarea: Calculatoare		Viza facultății:
LUCRARE DE DIPLOMĂ		
Coordonator științific: Conferențiar dr. Iclanzan David		Candidat: Ervin Fábíán Anul absolvirii: 2026
a) Tema lucrării de licență: Dezvoltarea și evaluarea unui sistem informatic bazat pe inteligență artificială pentru analiza imaginilor cu leziuni cutanate și clasificarea acestora în categorii benigne sau maligne. Lucrarea va aborda utilizarea metodelor moderne de învățare profundă, în special a arhitecturilor de tip Vision Transformer, pentru sprijinirea procesului de screening preliminar al cancerului de piele. Sistemul va include și o aplicație informatică prin care utilizatorul poate încărca sau captura imagini, obținând o analiză automată, un scor de risc și o explicație orientativă, fără a substitui diagnosticul medical de specialitate. b) Problemele principale tratate: - Studiu bibliografic privind cancerul de piele, melanomul, importanța depistării precoce și metodele clinice de evaluare vizuală a leziunilor cutanate, inclusiv criterii precum regula ABCDE. - Analiza metodelor existente de clasificare automată a leziunilor cutanate, de la metode clasice de machine learning până la rețele neuronale convoluționale și modele de tip Vision Transformer. - Studiarea seturilor de date publice relevante pentru clasificarea leziunilor cutanate, cu accent pe structura datelor, etichetare, dezechilibrul claselor și cerințele de preprocesare. - Proiectarea unui flux de preprocesare a imaginilor, incluzând redimensionarea, normalizarea, augmentarea datelor și împărțirea corectă în seturi de antrenare, validare și testare. - Antrenarea și ajustarea fină a unui model de tip Vision Transformer pentru clasificarea imaginilor dermatologice în clase benigne și maligne. - Implementarea cel puțin a unui model de referință, de exemplu o rețea convoluțională, pentru compararea performanței modelului principal. - Tratarea problemei dezechilibrului sever al claselor prin metode adecvate, cum ar fi eșantionarea, ponderarea claselor sau strategii de antrenare în mai multe etape. - Evaluarea modelelor utilizând metrici adecvate pentru probleme medicale dezechilibrate, precum AUC, pAUC, sensibilitate, specificitate, matrice de confuzie și curbe ROC. - Analiza limitărilor sistemului, în special riscul de rezultate fals negative/fals pozitive, dependența de calitatea imaginilor și imposibilitatea înlocuirii diagnosticului medical. - Proiectarea unei aplicații informatice care permite încărcarea sau capturarea imaginilor și afișarea rezultatului clasificării într-o formă clară pentru utilizator. - Implementarea unui backend sau serviciu de inferență care primește imaginile, aplică modelul antrenat și returnează rezultatul analizei. - Implementarea unor mecanisme minime de autentificare, gestionare a datelor utilizatorilor și stocare securizată a imaginilor și rezultatelor. - Integrarea unei componente de generare a explicațiilor în limbaj natural, astfel încât rezultatul să fie prezentat ca recomandare orientativă, nu ca diagnostic. - Testarea funcțională a aplicației și validarea fluxului complet: încărcare imagine, analiză automată, returnare rezultat, afișare explicație și salvare istoric. - Documentarea deciziilor de proiectare, a arhitecturii sistemului, a procesului de antrenare, a rezultatelor obținute și a limitărilor etice și tehnice.		

c) Desene obligatorii:

- Diagrama arhitecturală a sistemului, care să prezinte componentele principale: aplicația client, backendul, modulul de inferență AI, baza de date/stocarea imaginilor și eventualele servicii externe.
- Diagrama cazurilor de utilizare, incluzând cel puțin utilizatorul obișnuit, autentificarea, încărcarea/capturarea unei imagini, solicitarea analizei, vizualizarea rezultatului și consultarea istoricului.
- Diagrama fluxului de date pentru procesul de analiză a unei imagini, de la preluarea imaginii până la afișarea rezultatului.
- Diagrama procesului de antrenare și evaluare a modelului, incluzând preprocesarea datelor, augmentarea, antrenarea, validarea, testarea și calculul metricilor.
- Diagrama de secvență pentru o cerere de analiză, ilustrând comunicarea dintre client, backend, modelul AI și sistemul de stocare.
- Matrice de confuzie, curbe ROC și grafice comparative ale performanței modelelor evaluate.
- Wireframe-uri sau schițe ale interfeței utilizator pentru ecranele principale: autentificare, încărcare imagine, rezultat analiză și istoric.

d) Softuri obligatorii:

- Un modul de preprocesare a imaginilor dermatologice, care să realizeze pregătirea datelor pentru antrenare și inferență.
- Un model de învățare profundă bazat pe Vision Transformer, antrenat sau ajustat fin pentru clasificarea leziunilor cutanate în clase benigne și maligne.
- Cel puțin un model de referință pentru comparație, de exemplu un model CNN, antrenat și evaluat în condiții comparabile.
- Scripturi sau notebook-uri pentru antrenarea, validarea și testarea modelelor, cu salvarea rezultatelor și a metricilor relevante.
- Un serviciu backend/API care primește imagini, rulează modelul de clasificare și returnează predicția, scorul de încredere și informațiile asociate.
- O aplicație client, mobilă sau web, care permite utilizatorului să încarce sau să captureze imagini ale leziunilor cutanate.
- Un modul de afișare a rezultatului analizei, incluzând categoria estimată, scorul de risc/confidență și o explicație orientativă.
- Un modul de autentificare și gestionare a utilizatorilor.
- Un sistem de stocare pentru imaginile încărcate, rezultatele analizelor și istoricul utilizatorului, cu separarea datelor pe utilizatori.
- Mecanisme de validare minimă a intrărilor, tratare a erorilor și avertizare clară că aplicația are rol informativ și nu oferă diagnostic medical.
- O suită minimă de teste funcționale pentru verificarea principalelor fluxuri ale aplicației.

e) Bibliografia recomandată:

Esteva, A., Kuprel, B., Novoa, R. A., Ko, J., Swetter, S. M., Blau, H. M., & Thrun, S. "Dermatologist-level classification of skin cancer with deep neural networks". *Nature*, 542, 115–118, 2017.

Codella, N. C. F., Gutman, D., Celebi, M. E., et al. "Skin lesion analysis toward melanoma detection: A challenge at the 2017 International Symposium on Biomedical Imaging". *IEEE ISBI*, 2018.

Tschandl, P., Rosendahl, C., & Kittler, H. "The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions". *Scientific Data*, 5, 180161, 2018.

Dosovitskiy, A., Beyer, L., Kolesnikov, A., et al. "An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale". *International Conference on Learning Representations*, 2021.

He, K., Zhang, X., Ren, S., & Sun, J. "Deep Residual Learning for Image Recognition". IEEE Conference on Computer Vision and Pattern Recognition, 2016.

Goodfellow, I., Bengio, Y., & Courville, A. Deep Learning. MIT Press, 2016.

Chollet, F. Deep Learning with Python. Manning Publications, 2021.

Géron, A. Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow. O'Reilly Media, 2022.

Bishop, C. M. Pattern Recognition and Machine Learning. Springer, 2006.

Hastie, T., Tibshirani, R., & Friedman, J. The Elements of Statistical Learning: Data Mining, Inference, and Prediction. Springer, 2009.

International Skin Imaging Collaboration. ISIC Archive. (<https://www.isic-archive.com>)

Kaggle. ISIC 2024 - Skin Cancer Detection with 3D-TBP. (<https://www.kaggle.com/competitions/isic-2024-challenge>)

American Academy of Dermatology. ABCDEs of Melanoma. (<https://www.aad.org>)

National Cancer Institute. Melanoma Treatment and Skin Cancer Information. (<https://www.cancer.gov>)

Abbas, Q., Celebi, M. E., García, I. F., & Ahmad, W. "Melanoma recognition framework based on expert definition of ABCD for dermoscopic images". Skin Research and Technology, 19(1), 2013.

f) Termene obligatorii de consultații: săptămânal

g) Locul și durata practicii: Universitatea „Sapientia” din Cluj-Napoca,
Facultatea de Științe Tehnice și Umaniste din Târgu Mureș

Primit tema la data de: 2 mai 2025

Termen de predare: 29 iunie 2026

Semnătura Director Departament

Semnătura responsabilului
programului de studiu

Semnătura coordonatorului



Semnătura candidatului



Kivonat

A bőrrák, és különösen a melanoma korai felismerés esetén jól kezelhető, késői stádiumban azonban romlik a túlélési esély; a bőrgyógyászati szakellátáshoz való hozzáférés ugyanakkor világszerte egyenetlen. Éppen ezért jelen dolgozat célja egy mély tanuláson alapuló mesterséges intelligencia modell, mely képes a bőrelváltozások kép alapú osztályozására, és az e köré épülő webböngészőben és mobil eszközön elérhető, „bőrdaganat-szűrő” rendszer bemutatása, amely a bőrléziók szakorvosi vizsgálatának indokoltságát jelzi.

Osztályozóként transzfertanulással finomhangolt Vision Transformer (ViT) modellt használtunk, melyet az ISIC 2024-es adathalmazán tanítottunk, így alkalmassá vált nem-dermatoszkópos bőrlézió-felvételek klasszifikációjára. A modellt azonos feltételek mellett betanított ResNet-18 konvolúciós hálózattal, az ISIC versenygyőztes EVA02 modelljével és Gemini 2.5 Flash nagy nyelvi modellel hasonlítottuk össze. A finomhangolt ViT a teszt halmazon AUC 0,939-et ért el, érdemben felülmúlva a konvolúciós alapot, és elérve az EVA02 szintjét. A betanított osztályozó modellt egy teljes alkalmazással egészítettük ki: mobil- és webklienssel, a modellt kiszolgáló MCP-réteggel, a Gemini modellre épülő képvalidációval és természetes nyelvű magyarázattal, valamint hitelesített, felhasználónként elkülönített felhőalapú adattárolással.

Kulcsszavak: bőrrák, melanoma, mély tanulás, Vision Transformer, transzfertanulás, ISIC 2024, nagy nyelvi modell, mobil egészségügy

Abstract

Skin cancer, and melanoma in particular, is highly treatable when detected early, but the chances of survival deteriorate at advanced stages; at the same time, access to specialist dermatological care is unevenly distributed worldwide. The aim of this thesis is therefore to present a deep-learning-based artificial-intelligence model capable of image-based classification of skin lesions, together with the „skin-cancer screening” system built around it, accessible both in a web browser and on mobile devices, which indicates the extent to which a specialist examination of a skin lesion is warranted.

As the classifier we used a Vision Transformer (ViT) model fine-tuned with transfer learning, trained on the ISIC 2024 database, which made it suitable for classifying non-dermoscopic skin-lesion images. We compared the model with a ResNet-18 convolutional baseline trained under identical conditions, with the ISIC competition-winning EVA02 model, and with the Gemini 2.5 Flash large language model. On the test set the fine-tuned ViT reached an AUC of 0.939, substantially outperforming the convolutional baseline and matching the level of EVA02.

We extended the trained classifier model into a complete application, comprising mobile and web clients, an MCP layer serving the model, Gemini-based image validation and natural-language explanation, and authenticated, per-user cloud storage.

Keywords: skin cancer, melanoma, deep learning, Vision Transformer, transfer learning, ISIC 2024, large language model, mobile health

Abstract

Cancerul de piele, în special melanomul, este foarte tratabil atunci când este depistat precoce, însă șansele de supraviețuire scad în stadiile avansate; în același timp, accesul la îngrijire dermatologică de specialitate este distribuit inegal la nivel mondial. De aceea, scopul prezentei lucrări este de a prezenta un model de inteligență artificială bazat pe învățare profundă, capabil să clasifice leziunile cutanate pe baza imaginilor, precum și sistemul de „screening al cancerului de piele” construit în jurul acestuia, accesibil atât într-un browser web, cât și pe dispozitive mobile, care semnalează în ce măsură este justificată examinarea de specialitate a unei leziuni cutanate.

Drept clasificator am folosit un model Vision Transformer (ViT) ajustat fin prin învățare prin transfer, antrenat pe baza de date ISIC 2024, devenind astfel potrivit pentru clasificarea imaginilor non-dermatoscopice de leziuni cutanate. Am comparat modelul cu o rețea convoluțională ResNet-18 antrenată în condiții identice, cu modelul EVA02 câștigător al competiției ISIC și cu modelul lingvistic de mari dimensiuni Gemini 2.5 Flash. Pe setul de testare, modelul ViT ajustat fin a atins un AUC de 0,939, depășind substanțial modelul convoluțional de referință și egalând nivelul EVA02.

Am extins modelul de clasificare antrenat într-o aplicație completă, cuprinzând clienți mobili și web, un strat MCP care servește modelul, validarea imaginilor și explicații în limbaj natural bazate pe Gemini, precum și stocare în cloud autenticată și separată pe utilizatori.

Cuvinte cheie: cancer de piele, melanom, învățare profundă, Vision Transformer, învățare prin transfer, ISIC 2024, model lingvistic de mari dimensiuni, sănătate mobilă

Tartalomjegyzék

1. Bevezető	1
1.1. Motiváció és problémafelvetés	1
1.2. A dolgozat célja	2
1.3. A dolgozat felépítése	3
2. Szakirodalmi áttekintés	4
2.1. A bőrrák és a korai diagnózis jelentősége	4
2.1.1. A klinikai diagnosztikai folyamat	5
2.1.2. A hozzáférés korlátai	6
2.2. Klasszikus gépi tanulás a bőrelváltozások osztályozásában	7
2.3. A mély tanulás megjelenése: konvolúciós neurális hálók	7
2.4. A Vision Transformer megjelenése	8
2.5. Az ISIC adathalmaz	9
2.6. Multimodális nagy nyelvi modellek a bőrgyógyászatban	10
3. Elméleti háttér	11
3.1. A mesterséges neuron és a többrétegű perceptron	11
3.2. Aktivációs függvények	13
3.3. A neurális hálók tanítása	13
3.3.1. Veszteségfüggvények	14
3.3.2. Gradiens-alapú tanulás és hiba-visszaterjesztés	14
3.3.3. Optimalizálók: az SGD-től az AdamW-ig	14

3.3.4.	Regularizáció és a túltanulás megelőzése	15
3.4.	Konvolúciós neurális hálók	16
3.4.1.	A konvolúciós réteg	16
3.4.2.	Az összevonó réteg	16
3.4.3.	Reziduális kapcsolatok és a ResNet	17
3.5.	A figyelmi mechanizmus és a Transformer	17
3.6.	A Vision Transformer architektúrája	18
3.7.	Transzfertanulás és finomhangolás	19
3.8.	Az osztály-egyensúlytalanság kezelése	20
3.9.	Kiértékelési metrikák	21
3.10.	Statisztikai elemzés	23
3.11.	Kommunikációs technológiák: SSE és az MCP	23
4.	A bőrelváltozás-osztályozó modell fejlesztése és kiértékelése	25
4.1.	Az ISIC 2024 adathalmaz és előkészítése	25
4.2.	A Vision Transformer modell	26
4.2.1.	Kétfázisú tanítás	26
4.2.2.	Az osztály-egyensúlytalanság kezelése	27
4.2.3.	Adataugmentáció	27
4.2.4.	Hiperparaméterek	27
4.3.	A ResNet-18 viszonyítási alap	28
4.4.	Az EVA02 viszonyítási alap	29
4.5.	A Gemini zero-shot viszonyítási alap	29
4.6.	Kísérleti elrendezés	30
4.6.1.	Reprodukálhatóság	30
4.7.	Eredmények	31
4.7.1.	A tanítás konvergenciája	31
4.7.2.	A ViT teljesítménye a teszhalmazon	32
4.7.3.	A ResNet-18 teljesítménye	35

4.7.4.	Összehasonlítás a viszonyítási alapokkal	36
4.7.5.	Statisztikai elemzés	38
4.7.6.	Az eredmények megbeszélése és korlátai	39
5.	A rendszer tervezése és megvalósítása	40
5.1.	Követelmények	40
5.1.1.	Funkcionális követelmények	40
5.1.2.	Nem-funkcionális követelmények	42
5.2.	Rendszerarchitektúra	42
5.2.1.	Egy elemzési kérés életciklusa	44
5.3.	A modellt kiszolgáló komponens: MCP-szerver	46
5.4.	A backend	46
5.4.1.	Végpontok	47
5.4.2.	A Gemini integrációja és a képvalidáció	47
5.4.3.	Token-szintű adatfolyam (SSE)	48
5.5.	A mobilalkalmazás	48
5.5.1.	Kameramodul és makrófelvétel	49
5.5.2.	Hálózati réteg	49
5.6.	A webes felület	49
5.7.	Hitelesítés és felhőalapú adattárolás	50
5.7.1.	Hitelesítés	50
5.7.2.	Adatbázis és fájl tárolás	50
5.8.	Hálózati robusztusság és hibatűrés	51
5.9.	Biztonsági megfontolások	51
6.	Összefoglalás és jövőbeli munka	53
6.1.	A dolgozat eredményeinek összegzése	53
6.2.	Korlátok	54
6.3.	Jövőbeli fejlesztési irányok	55

Irodalomjegyzék	56
A. A mesterséges intelligencia használata	62

Ábrák jegyzéke

2.1.	Az ABCDE-szabály öt kritériuma valós felvételeken: a felső sor jóindulatú (nem melanoma), az alsó sor melanoma eseteket szemléltet az aszimmetria (A), a határvonal (B), a szín (C), az átmérő (D) és az időbeli változás, evolúció (E) szempontjából. Forrás: Science Learning Hub (sciencelearn.org.nz).	6
2.2.	Reprezentatív minták az ISIC 2024 adathalmazból.	10
3.1.	Balra: a mesterséges neuron, amely a bemenetek súlyozott összegét egy aktivációs függvényen vezeti át. Jobbra: a többrétegű perceptron, amelyben a teljesen összekötött rétegek a bemenetből a kimenet felé továbbítják a jelet.	12
3.2.	A konvolúciós neurális háló sematikus felépítése: a konvolúciós és összevonó rétegek ismételt alkalmazásával egyre absztraktabb jellemzőterképeket nyer ki a képből, majd egy teljesen összekötött réteg végzi az osztályozást.	17
3.3.	A Vision Transformer (ViT) sematikus felépítése: a kép foltokra bontása, lineáris beágyazás és helyzetkódolás, a [CLS] tokennel kiegészített tokenszekvencia feldolgozása a Transformer-kódoló rétegeiben, végül a [CLS] reprezentációra épülő osztályozó fej, amely a jóindulatú/rosszindulatú döntést adja.	19
3.4.	A kétfázisú tanítási stratégia: az első, kiegyensúlyozott fázis a diszkriminatív jellemzők megtanulását célozza, a második, kalibráló fázis pedig a kimeneti valószínűségeket a valós előfordulási arányhoz igazítja.	21
4.1.	A ViT modell tanításának konvergenciája: a tanítási veszteség, valamint a validációs AUC és pAUC alakulása az epochok függvényében.	32

4.2.	Tanítási konvergencia: a ViT-Base és a ResNet-18 validációs AUC-jának (bal) és pAUC-jának (jobb) alakulása epochonként, az első (kiegyensúlyozott) tanítási fázisban.	32
4.3.	A ViT modell ROC-görbéje a teszhalmazon, a pAUC számításához használt $TPR \geq 0,80$ tartomány kiemelésével.	34
4.4.	A ViT modell által becsült rosszindulatúság-valószínűségek eloszlása a teszhalmazon, osztályonként (logaritmikus függőleges tengely). A szaggatott vonalak a két működési pont döntési küszöbét jelölik.	35
4.5.	A ViT és a ResNet-18 tévesztési mátrixai a teszhalmazon, a két működési ponton (VP: valódi pozitív, VN: valódi negatív, HP: hamis pozitív, HN: hamis negatív). A színskála logaritmikus, az extrém osztály-egyensúlytalanság miatt.	36
4.6.	A négy modell összehasonlítása az AUC (bal) és a hivatalos ISIC 2024 pAUC (jobb) mentén. A Gemini pAUC-értéke közelítő becslés (egy 2 000 elemű részhalmazon mérve, a hivatalos skálára átskálázva), ezért szaggatott, halványított oszlop jelöli. A pAUC elméleti maximuma 0,20.	37
5.1.	A rendszer használati eset diagramja: a felhasználó fő céljai, valamint az „elváltozás elemzése” use case kötelező lépései (képvalidáció, osztályozás, magyarázat).	41
5.2.	A rendszer komponens-diagramja: a kliensek (Android, web), a backendek (Flask, FastAPI), a modellt kiszolgáló MCP-réteg és a GPU-n futó ViT, valamint a Firebase és a Gemini szolgáltatások, a köztük lévő kommunikációs protokollokkal.	43
5.3.	Egy elemzési kérés (/analyze) szekvenciadiagramja: a kliens, a backend, a Gemini, az MCP-szerver, a ViT és a Firebase interakciói. Az elágazás (<i>alt</i>) az értékelhetetlen kép esetét, a ciklus (<i>loop</i>) a token-szintű (SSE) válasz továbbítását jelöli.	45

1. fejezet

Bevezető

1.1. Motiváció és problémafelvetés

A bőrrák napjaink egyik legelterjedtebb daganatos megbetegedése, és bár a melanoma a bőrdaganatos eseteknek csak kisebb hányadát teszi ki, agresszív viselkedése és rossz prognózisa miatt a bőrrák okozta halálozás túlnyomó részéért felel. A betegség kimenetele döntően a felismerés időzítésén múlik: a még lokalizált stádiumban diagnosztizált melanoma jó eséllyel gyógyítható, késői, áttétes stádiumban azonban a túlélési esély drasztikusan romlik. A korai felismerés tehát nem csupán orvosi, hanem népegészségügyi szempontból is kritikus jelentőségű; a téma részletes epidemiológiai hátterét a 2. fejezet tárgyalja.

A korai felismerés legnagyobb gyakorlati akadályja a hozzáférés. A hagyományos diagnosztikai folyamat – dermatológus által végzett vizuális vizsgálat és dermatoszkópos értékelés – magas szintű szakmai tudást és speciális eszközöket igényel. A világ számos részén, különösen vidéki térségekben és alacsonyabb jövedelmű országokban, a bőrgyógyászati szakellátáshoz való hozzáférés korlátozott, ami késedelmes diagnózishoz és rosszabb kimenetelhez vezet; de még fejlett egészségügyi rendszerekben is jelentős várakozási idővel kell számolni a szakorvosi vizsgálatig.

A mesterséges intelligencia, azon belül a mély tanulás megjelenése új lehetőségeket nyitott a bőrelváltozások automatikus osztályozásában. Az úttörő munkák kimutatták, hogy a megfelelően betanított neurális hálók a bőrrák-osztályozásban elérhetik a tapasztalt dermatológusok teljesítményét [1], és az architektúrák fejlődésével ez a képesség tovább erősödött. Az okostelefonok elterjedése és fejlődő

kamerarendszerei ezt a képességet a beteg kezébe adhatják: egy ilyen rendszer a felhasználó által készített fotó alapján jelezheti, ha egy elváltozás szakorvosi vizsgálatot indokol, csökkentve a késői diagnózisok számát.

1.2. A dolgozat célja

Jelen dolgozat egy bőrelváltozás-elemző rendszer tervezését és implementációját mutatja be, amely transfertanulással (transfer learning) finomhangolt Vision Transformer (ViT) [2] modellre épül – a modellt az ISIC 2024 versenyzadathalmazon [3] tanítottuk bőrelváltozás-osztályozásra. A dolgozat két, egymást kiegészítő pillérre tagolódik: egy *kutatási* részre, amely a modell fejlesztését és tudományos kiértékelését tárgyalja, és egy *mérnöki* részre, amely a betanított modellt egy teljes, használható alkalmazássá egészíti ki.

A rendszer fő célkitűzései a következők:

- Egy bőrelváltozás-osztályozó Vision Transformer modell betanítása az ISIC 2024 adathalmazon, a modell validációja, statisztikailag megalapozott kiértékelése és viszonyítási alapokhoz mérése.
- Egy Android mobilalkalmazás fejlesztése, amely lehetővé teszi a felhasználó számára, hogy fényképet készítsen vagy töltsön fel egy bőrelváltozásról, és azonnali, AI-alapú elemzést kapjon.
- Egy webalkalmazás fejlesztése, amely lehetővé teszi a felhasználó számára, hogy fényképet készítsen vagy töltsön fel egy bőrelváltozásról, és azonnali, AI-alapú elemzést kapjon.
- A feltöltött kép minőségének és relevanciájának automatikus ellenőrzése egy nagy nyelvi modell (Gemini) segítségével, kiszűrve az értékelhetetlen vagy nem megfelelő felvételeket.
- A bőrelváltozás osztályozása *benignus/jóindulatú* vagy *malignus/rosszindulatú* kategóriába a ViT-moddellel, konfidencia-értékkel kiegészítve.
- Természetes nyelvű magyarázat és orvosi szempontú visszajelzés generálása a klasszifikációs eredmény alapján, az ABCDE-szabály¹ figyelembevételével.

¹Aszimmetria, határvonala, szín, átmérő, evolúció – a melanoma gyanújelei.

- A felhasználói interakciók és a feltöltött képek biztonságos, a bejelentkező felhasználóhoz kötött tárolása felhőalapú infrastruktúrán.

Fontos hangsúlyozni, hogy a rendszer nem helyettesíti a szakorvosi diagnózist: kizárólag tájékoztató jellegű szűrőeszközként funkcionál, amely segíti a felhasználót abban, hogy időben döntsön a dermatológiai konzultáció szükségességéről.

1.3. A dolgozat felépítése

A dolgozat hat fejezetre tagolódik. A jelen **Bevezető** után a **Szakirodalmi áttekintés** (2. fejezet) a bőrelváltozások gépi tanulással történő osztályozásának előzményeit tekinti át – a klinikai diagnosztikai gyakorlattól a klasszikus gépi tanuláson és a konvolúciós hálókön át a Vision Transformer és a multimodális nagy nyelvi modellek megjelenéséig –, valamint ismerteti az ISIC adathalmazok fejlődését. Az **Elméleti háttér** (3. fejezet) a rendszer mögötti kulcstechnológiák elméletét építi fel: a mesterséges neurontól és a hálózatok tanításától a konvolúciós hálókön, a figyelmi mechanizmuson és a Vision Transformeren át az osztály-egyensúlytalanság kezeléséig, a kiértékelési metrikákig és a kommunikációs technológiákig. A **modell fejlesztése és kiértékelése** (4. fejezet) az adathalmaz előkészítését, a ViT modell betanítását, a viszonyítási alapokat (ResNet-18, EVA02, Gemini), valamint a kvantitatív eredményeket és a statisztikai elemzést tárgyalja. A **rendszer tervezése és megvalósítása** (5. fejezet) az osztályozó modellre épülő rendszer megvalósítását mutatja be: a követelményeket, a rendszerarchitektúrát, a modellkiszolgálást, a backendet, a mobil- és webalkalmazást, valamint a hitelesítést és a felhőalapú adattárolást. Végül az **Összefoglalás és jövőbeli munka** (6. fejezet) a következtetéseket és a lehetséges továbbfejlesztési irányokat foglalja össze.

2. fejezet

Szakirodalmi áttekintés

Ez a fejezet a bőrelváltozások gépi tanulással történő osztályozásának szakirodalmi előzményeit tekintti át. A klinikai diagnosztikai gyakorlat és a korai felismerés jelentőségének ismertetése után végigköveti a terület módszertani fejlődését – a kézi jellemzőkön alapuló klasszikus gépi tanulástól a konvolúciós neurális hálókön át a Vision Transformer és a multimodális nagy nyelvi modellek megjelenéséig –, majd bemutatja az ISIC adathalmazokat, amelyek a dolgozat empirikus alapját adják.

2.1. A bőrrák és a korai diagnózis jelentősége

A bőrrák a leggyakrabban diagnosztizált rosszindulatú daganatok közé tartozik világszerte. A Nemzetközi Rákkutató Ügynökség (IARC) GLOBOCAN-bebecslései szerint 2022-ben több mint 1,5 millió új bőrdaganatos eset fordult elő, ezen belül a melanomák száma megközelítőleg 331 700 volt, mintegy 58 700 halálessel [4]. Bár a melanoma a bőrrákos esetek kisebb hányadát teszi ki, agresszív viselkedése és áttétképző hajlama miatt a bőrdaganatok okozta halálozás túlnyomó részéért felel.


A betegség kimenetele döntően a felismerés stádiumától függ. A még lokalizált stádiumban diagnosztizált melanoma ötéves relatív túlélési aránya közel 100%, míg távoli áttét megjelenése esetén ez mintegy 35%-ra csökken [5]. Ez a markáns különbség teszi a korai felismerést népegészségügyi szempontból kiemelten fontossá: a diagnózis néhány hónapos késedelme is jelentősen ronthatja a beteg túlélési esélyeit.

2.1.1. A klinikai diagnosztikai folyamat

A melanoma klinikai gyanúja jellemzően vizuális vizsgálat alapján merül fel, amelyet dermatoszkópos értékelés egészít ki; a végleges diagnózist minden esetben szövettani vizsgálat (hisztopatológia) erősíti meg [6]. A magas kockázatú betegek nyomon követésében a szekvenciális digitális dermatoszkópia és a teljes testfelszín fényképezése segíti a korai melanomák kiszűrését [6]. Ez a folyamat magas szintű szakmai tapasztalatot és speciális eszközöket igényel.

A pigmentált bőrelváltozások szabad szemmel történő, gyors megítélését a klinikai gyakorlatban az úgynevezett ABCDE-szabály támogatja. A betűszó a melanomára jellemző öt figyelmeztető jeget foglalja össze: aszimmetria (*Asymmetry*), szabálytalan határvonal (*Border*), színbeli heterogenitás (*Color*), 6 mm-t meghaladó átmérő (*Diameter*), valamint az elváltozás időbeli változása (*Evolving*); az utóbbi, ötödik kritériummal Abbasi és munkatársai egészítették ki az eredeti ABCD-szabályt, hangsúlyozva a fejlődő elváltozások jelentőségét [7]. Az ABCDE-szabály egyszerűsége miatt mind a szakemberek, mind a betegek számára jól használható, ugyanakkor önmagában nem helyettesíti a műszeres és szövettani vizsgálatot. Az ABCDE-kritériumokat a 2.1. ábra szemlélteti.

The ABCDE's of detecting melanoma



2.1. ábra. Az ABCDE-szabály öt kritériuma valós felvételeken: a felső sor jóindulatú (nem melanoma), az alsó sor melanoma eseteket szemléltet az aszimmetria (A), a határvonal (B), a szín (C), az átmérő (D) és az időbeli változás, evolúció (E) szempontjából. Forrás: Science Learning Hub (sciencelearn.org.nz).

2.1.2. A hozzáférés korlátai

A bőrgyógyászati szakellátáshoz való hozzáférés világszerte egyenetlen. Vidéki térségekben és alacsonyabb jövedelmű országokban a szakorvosi kapacitás korlátozott, ami késedelmes diagnózishoz vezet; de még fejlett egészségügyi rendszerekben is jelentős várakozási idővel kell számolni a szakvizsgálatig. Ez a hozzáférési szakadék motiválja az olyan automatizált, akár okostelefonon is futó szűrőeszközök fejlesztését, amelyek elsődleges triázsként jelezhetik, ha egy elváltozás szakorvosi vizsgálatot indokol. A mobil egészségügyi (mHealth) megközelítés ígéretét korai vizsgálatok is jelezték: Massone és munkatársai például a mobiltelefonnal készített képeken alapuló melanoma-szűrés megvalósíthatóságát igazolták [8].

2.2. Klasszikus gépi tanulás a bőrelváltozások osztályozásában

A mély tanulás elterjedése előtt a bőrelváltozás-osztályozó rendszerek jellemzően kétlépcsős felépítést követtek: először kézzel tervezett jellemzőket (*handcrafted features*) nyertek ki a képből, majd ezeken egy klasszikus gépi tanulási osztályozót – például SVM-et, decision tree-t vagy Random Forest-et – tanítottak be. A jellemzők gyakran közvetlenül az orvosi szempontokat tükrözték: az ABCDE-szabályhoz kapcsolódó alaki (aszimmetria, határvonal), színbeli (szín-momentumok, hisztogramok) és textúra jellemzőket (például a szürkeárnyaltos együttes-előfordulási mátrixból (GLCM) számított mutatókat).

Kassem és munkatársai szisztematikus áttekintése a terület módszertani fejlődését dokumentálja, és rámutat, hogy a klasszikus, kézi jellemzőkön alapuló megközelítések teljesítményét erősen korlátozza a feature engineering minősége és a felvételi körülmények (megvilágítás, felbontás, artefaktumok) iránti érzékenység [9]. Ezek a rendszerek jellemzően jól kontrollált, dermatoszkópos felvételeken működtek megbízhatóan, általánosító képességük azonban korlátozott maradt. Mindazonáltal a kézi jellemzőkön alapuló osztályozók a mai napig értékes *viszonyítási alapként* szolgálnak, mivel gyorsak, értelmezhetők, és megmutatják, mekkora teljesítmény érhető el a reprezentáció automatikus tanulása nélkül.

2.3. A mély tanulás megjelenése: konvolúciós neurális hálók

A konvolúciós neurális hálók (CNN-ek) áttörést hoztak a képosztályozásban azzal, hogy a jellemzőkinyerést és az osztályozást egyetlen, végponttól végpontig tanítható modellbe integrálták, megszüntetve a kézi feature engineering szükségességét. A bőrgyógyászati alkalmazások egyik úttörő munkájában Esteva és munkatársai kimutatták, hogy egy nagy képadatbázison előtanított CNN a vizsgált bőrrák-osztályozási feladatokban eléri a tapasztalt dermatológusok teljesítményét [1]. Ezt követően több vizsgálat is megerősítette, hogy a mély tanuláson alapuló rendszerek megközelíthetik, sőt bizonyos, jól körülhatárolt feladatokban meg is haladhatják az emberi szakértők teljesítményét: Haenssle és munkatársai egy CNN-t 58 dermatológussal vetettek össze dermatoszkópos melanoma-felismerésben [10], Brinker és munkatársai pedig arról számoltak be, hogy mély neurális hálók a melanoma képi

osztályozásában felülmúlták a bevont bőrgyógyászokat [11].

E rendszerek teljesítményének kulcsa a *transzfertanulás* (transfer learning): a modelleket először egy nagy, általános képadatbázison – jellemzően az ImageNet adathalmazon [12] – tanítják be, majd a megtanult vizuális reprezentációkat a jóval kisebb orvosi adathalmazra finomhangolják (fine-tuning). Az architektúrák fejlődése szintén hozzájárult az eredmények javulásához: a reziduális kapcsolatokat bevezető ResNet [13] lehetővé tette a nagyon mély hálók stabil tanítását, az EfficientNet pedig a hálózat mélységének, szélességének és felbontásának együttes, kiegyensúlyozott skálázásával ért el kedvező teljesítmény-paraméterszám arányt [14].

A korai rendszerek fontos korlátja volt, hogy elsősorban dermatoszkópos, nagy felbontású klinikai felvételeken működtek megbízhatóan, amelyek elkészítéséhez speciális eszköz és szakértelem szükséges. Emellett a szelekciós torzítás is jelentős problémát jelentett: az elérhető adathalmazok döntően már szakorvoshoz került, klinikailag gyanús elváltozásokat tartalmaztak, ami tovább korlátozta a modellek általánosíthatóságát hétköznapi felvételekre.

2.4. A Vision Transformer megjelenése

A természetesnyelv-feldolgozásban bevezetett Transformer-architektúra a *figyelmi* (attention) mechanizmusra épül, amely a bemenet elemei közötti összes páronkénti kapcsolatot képes közvetlenül modellezni, függetlenül azok távolságától [15]. Ezt az elvet a képosztályozásra a Vision Transformer (ViT) ültette át: a képet rögzített méretű foltokra (*patch*) bontja, ezeket lineárisan beágyazza, majd egy Transformer-kódoló dolgozza fel őket [2]. A konvolúciós hálókkal szemben a ViT nem rendelkezik beépített képi induktív torzítással (mint a lokalitás vagy az eltolás-invariancia), így a globális összefüggéseket rugalmasabban tanulja meg, cserébe viszont jellemzően nagyobb tanítóadatra vagy erőteljes előtanításra van szüksége a jó általánosításhoz [2]. Az architektúra részletes elméleti tárgyalása a 3. fejezetben található.

A ViT-architektúra a bőrgyógyászati képosztályozásban is megjelent. Dagnaw és munkatársai például Vision Transformer és konvolúciós modelleket vetettek össze magyarázható mesterséges intelligencia (XAI) technikákkal kiegészítve, és a ViT-alapú, illetve a CNN-alapú modellek esetében hasonló nagyságrendű pontosságot mértek [16]. Ez a megfigyelés alátámasztja, hogy a két architektú-


racsalád összevetése – pontosan kontrollált, azonos adat- és tanítási feltételek mellett – önmagában is érdemi tudományos kérdés, amelyre a dolgozat kutatási része is kitér.

2.5. Az ISIC adathalmaz

A bőrelváltozás-osztályozás kutatását jelentősen előmozdította az annotált, nyilvánosan elérhető adathalmazok megjelenése. A HAM10000 adathalmaz 10 015, több forrásból származó dermatoszkópos felvételt tartalmaz a gyakori pigmentált elváltozásokról, és egységes kiértékelési keretet biztosított a kutatóknak [17]. Az International Skin Imaging Collaboration (ISIC) versenysorozata tovább bővítette az elérhető képanyagot; Rotemberg és munkatársai egy beteg-központú, a képek mellett klinikai metaadatokat is tartalmazó adathalmazt mutattak be, hangsúlyozva a klinikai kontextus szerepét a melanoma azonosításában [18].

A jelen dolgozat szempontjából kiemelt jelentőségű az ISIC 2024 verseny (*Skin Cancer Detection with 3D-TBP*), amely a teljes testfelszín háromdimenziós fényképezéséből (3D total-body photography) kivágott, mintegy 400 000 elváltozás-képet tartalmaz, és binárisan – rosszindulatú, illetve jóindulatú vagy köztes kategóriába – történő osztályozást tűz ki célul [3]. Ezek a kivágott felvételek minőségükben közelebb állnak a hétköznapi, akár okostelefonnal készíthető képekhez, mint a klasszikus, nagy felbontású dermatoszkópos felvételek, ami a valós felhasználási helyzethez közelíti a feladatot.

Az ISIC 2024 adathalmaz egyik meghatározó jellemzője a rendkívül erős *osztály-egyensúlytalanság*: a rosszindulatú esetek a teljes adathalmaznak csupán töredékét (nagyságrendileg ezredrészét) teszik ki. Ennek megfelelően a verseny nem a hagyományos pontosságot, hanem a 80%-os érzékenység (true positive rate) feletti tartományra korlátozott, részleges görbe alatti területet (partial AUC) használja elsődleges metrikaként, amely orvosilag releváns módon a magas érzékenységi tartományban méri a modellek teljesítményét [3].



2.2. ábra. Reprezentatív minták az ISIC 2024 adathalmazból.

2.6. Multimodális nagy nyelvi modellek a bőrgyógyászatban

A legutóbbi években a multimodális nagy nyelvi modellek (multimodal large language models, MLLM-ek) megjelenése új lehetőségeket nyitott az orvosi képértelmezésben. Ezek a modellek – mint a Google Gemini-családja [19] – egyszerre képesek képi és szöveges bemenet feldolgozására, és természetes nyelvű magyarázatot, indoklást is tudnak generálni.

A bőrgyógyászati alkalmazásukat több vizsgálat is értékelte. Cirone és munkatársai a GPT-4 Vision és a LLaVA modelleket vetették össze melanoma és jóindulatú elváltozások megkülönböztetésében, és azt találták, hogy a GPT-4V lényegesen jobban teljesített (85% pontosság a LLaVA 45%-ával szemben), ugyanakkor mindkét modell teljesítménye érzékelhetően romlott a sötétebb bőrtónusok esetén – ami a reprezentációs torzítás kockázatára és a sokszínűbb adathalmazok szükségességére hívja fel a figyelmet [20]. Zhou és munkatársai célzottan bőrgyógyászati rendszert építettek (SkinGPT-4), amelyben egy előtanított Vision Transformert egy nagy nyelvi modellel kapcsolnak össze, és valós eseteken értékelték autonóm diagnosztikai képességét [21].

E munkák tanulsága kettős. Egyrészt a multimodális nyelvi modellek erőssége a természetes nyelvű magyarázat és a felhasználóval folytatott párbeszéd, nem pedig a megbízható, kalibrált osztályozás. Másrészt a teljesítményük populációk közötti egyenetlensége óvatosságra int a klinikai felhasználásban. Ezek a megfontolások közvetlenül indokolják a jelen dolgozatban követett tervezési döntést: a *klasszifikációt* egy célzottan betanított képi osztályozó modell (ViT) végzi, míg a nagy nyelvi modell (Gemini) szerepe a kép minőségének ellenőrzésére, az eredmény közérthető magyarázatára és a felhasználói kérdések megválaszolására korlátozódik. E munkamegosztás részletes tárgyalása és empirikus alátámasztása a dolgozat kutatási, illetve mérnöki részében található.

3. fejezet

Elméleti háttér

Ez a fejezet a dolgozatban felhasznált kulcstechnológiák elméleti hátterét építi fel, az alapoktól az alkalmazott architektúráig.

3.1. A mesterséges neuron és a többrétegű perceptron


A mesterséges neurális hálózatok koncepciója a biológiai idegrendszer működéséből merít ihletet, annak elveit igyekszik leképezni és továbbgondolni. Éppen ezért érdemes először áttekinteni a biológiai neurális hálózat alapjait, mielőtt a mesterséges megfelelőjére térnénk. Az emberi idegrendszer alapegységei az idegsejtek, amelyek szerkezetileg három jól elkülöníthető részből állnak. A dendritek a sejttestből kiágazó nyúlványok, amelyek elsődleges feladata a külső jelek és ingerek befogadása. Maga a sejttest látja el a beérkező információk integrálásának és feldolgozásának szerepét. Az axon — amely a sejttestet a szinaptikus végződésekkel köti össze — kulcsfontosságú az idegsejtek közötti kommunikációban, mivel ezen keresztül továbbítódnak az elektromos jelek. Az a mechanizmus, amelynek során egy neuron axonja egy másik neuron dendritjével kerül kapcsolatba, és a felszabaduló neurotranszmitterek révén megtörténik a jel továbbítás a két sejt között, szinapszis néven ismert.

A mély tanulás alapegysége a mesterséges neuron, amely a biológiai idegsejt erősen leegyszerűsített matematikai modellje [22]. A neuron a bemeneti jelek $(x_1, \dots, x_n)$ súlyozott összegét képezi, hozzáad egy eltolási (bias) tagot, majd az eredményt egy nemlineáris *aktivációs függvényen* (ϕ) vezeti át:

$$y = \varphi \left(\sum_{i=1}^n w_i x_i + b \right), \quad (3.1)$$

ahol w_i a bemenetekhez rendelt súlyok, b az eltolás. A súlyok és az eltolás a tanulás során hangolódó paraméterek. Egyetlen neuron csak lineárisan szétválasztható feladatokat képes megoldani; a kifejezőerőt a neuronok *rétegekbe* szervezése adja.

A *többrétegű perceptron* (multilayer perceptron, MLP) neuronok egymást követő rétegeiből épül fel: egy bemeneti rétegből, egy vagy több rejtett rétegből és egy kimeneti rétegből, ahol az egyes rétegek neuronjai a következő réteg minden neuronjához kapcsolódnak (3.1. ábra). Egy elegendően széles, nemlineáris aktivációval rendelkező rejtett réteggel az MLP tetszőleges folytonos függvényt képes tetszőleges pontossággal közelíteni – ez az *univerzális approximáció* tulajdonsága –, a gyakorlatban azonban a mélység (a rétegek száma) teszi lehetővé a bonyolult, hierarchikus reprezentációk hatékony tanulását [22].



3.1. ábra. Balra: a mesterséges neuron, amely a bemenetek súlyozott összegét egy aktivációs függvényen vezeti át. Jobbra: a többrétegű perceptron, amelyben a teljesen összekötött rétegek a bemenetből a kimenet felé továbbítják a jelet.

3.2. Aktivációs függvények

Az aktivációs függvény viszi be a nemlinearitást a hálóba; e nélkül a rétegek egymásutánja egyetlen lineáris transzformációvá esne össze, és a háló kifejezőereje nem haladná meg egyetlen réteg kifejezőerejét. A legelterjedtebb választások a következők [22]:

- **Sigmoid:** $\sigma(z) = 1/(1 + e^{-z})$, amely a bemenetet a $(0; 1)$ intervallumra képezi; bináris osztályozás kimeneti rétegében valószínűségként értelmezhető, rejtett rétegekben azonban a telítődő tartományokban eltűnő gradienst okozhat.
- **Tangens hiperbolikus:** $\tanh(z)$, amely a $(-1; 1)$ intervallumra képez, és nulla középpontú kimenetével gyakran kedvezőbb a szigmoidnál.
- **Rektifikált lineáris egység (ReLU):** $\text{ReLU}(z) = \max(0, z)$, amely egyszerűsége és a pozitív tartományban nem telítődő, gradiens-barát viselkedése miatt a mély hálók alapértelmezett választásává vált. Számos változata létezik, például a negatív tartományban kis meredekséget engedő *Leaky ReLU*, illetve a sima *GELU*, amelyet a Transformer-alapú modellek – köztük a dolgozat ViT modellje – is alkalmaznak.

A többsztályos kimeneti rétegben a **softmax** függvény használatos, amely a kimeneti pontszámokat (logitokat) egy osztályok feletti valószínűségi eloszlássá normalizálja:

$$\text{softmax}(z)_k = \frac{e^{z_k}}{\sum_j e^{z_j}}. \quad (3.2)$$

3.3. A neurális hálók tanítása

A háló tanítása a paraméterek (súlyok és eltolások) olyan beállítását jelenti, amely minimalizálja a modell előrejelzései és a valós címkék közötti eltérést. Ezt az eltérést egy *veszteségfüggvény* (loss function) számszerűsíti, a minimalizálást pedig gradiens-alapú optimalizálás végzi.

3.3.1. Veszteségfüggvények

A feladat jellegétől függően különböző veszteségfüggvényeket alkalmazunk. Regressziónál az átlagos négyzetes eltérés (mean squared error) a tipikus választás. Osztályozásnál a *keresztentropia* (cross-entropy) használatos, amely a becült és a valós valószínűségi eloszlás közötti eltérést méri; bináris esetben [22]:

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{N} \sum_{i=1}^N [y_i \log p_i + (1 - y_i) \log(1 - p_i)], \quad (3.3)$$

ahol $y_i \in \{0, 1\}$ a valós címke, p_i a modell által a pozitív osztályra becült valószínűség. Erősen kiegyensúlyozatlan feladatban e veszteség módosítására van szükség; ezt a 3.8. szakasz tárgyalja.

3.3.2. Gradiens-alapú tanulás és hiba-visszaterjesztés

A veszteség minimalizálása *gradiensereszkedéssel* (gradient descent) történik: a paramétereket a veszteségfüggvény gradiensével ellentétes irányban, kis lépésekben mozgatjuk, hiszen a gradiens a legmeredekebb növekedés irányába mutat. Egy θ paraméter frissítése:

$$\theta \leftarrow \theta - \eta \frac{\partial \mathcal{L}}{\partial \theta}, \quad (3.4)$$

ahol η a *tanulási ráta* (learning rate), amely a lépés nagyságát szabályozza. A többrétegű hálók esetén a gradienseket a *hiba-visszaterjesztés* (backpropagation) algoritmus számítja ki, amely a deriválás láncszabályát alkalmazva a kimeneti hibát rétegről rétegre, visszafelé terjeszti, és így minden paraméterre hatékonyan meghatározza a gradienst [22].

3.3.3. Optimalizálók: az SGD-től az AdamW-ig

A teljes adathalmaz feletti gradiens kiszámítása nagy adathalmazokon költséges, ezért a gyakorlatban a *sztochasztikus gradiensereszkedést* (stochastic gradient descent, SGD) alkalmazzák: a gradienst a tanítóadat kisebb, véletlenszerű részhalmazain (*batch*-ein) becsülik. Az alapváltozatot számos technika javítja, például a *momentum*, amely a korábbi lépések irányát is figyelembe veszi, gyorsítva a konvergenciát.

A modern mély tanulás egyik legelterjedtebb optimalizálója az **Adam**, amely a gradiensek első és második momentumának mozgóátlagát tartja karban, és ezek alapján paraméterenként adaptálja a tanulási rátát [23]. Az Adam egy továbbfejlesztett változata az **AdamW**, amely a súlycsökkentést (weight decay) – egy, a túltanulást mérséklő regularizációs tagot – a gradiens frissítésétől szétválasztva, helyesebben kezeli, és így jobb általánosítást ér el [24]. A dolgozat valamennyi modelljét AdamW optimalizálóval tanítottuk.

A tanulási ráta időbeli alakítása (*ütemezés*, scheduling) szintén befolyásolja a konvergenciát. Bevett gyakorlat a kezdeti néhány epochban alkalmazott *bemelegítés* (warmup), amely fokozatosan emeli a tanulási rátát, megelőzve a kezdeti nagy, destabilizáló lépéseket, majd egy *koszinusz* ütemezés, amely a ráta fokozatos csökkentésével finomhangolja a modellt.

3.3.4. Regularizáció és a túltanulás megelőzése

A nagy kapacitású hálók hajlamosak a *túltanulásra* (overfitting): a tanítóadatot kívülről megtanulják, de új adatokra rosszul általánosítanak. Ennek megelőzésére több technika áll rendelkezésre:

- **Dropout:** a tanítás során a neuronok egy véletlenszerűen kiválasztott hányadát ideiglenesen kikapcsolja, így a háló nem támaszkodhat egyetlen jellemzőre sem, ami robusztusabb reprezentációkat eredményez [25].
- **Súlycsökkentés (weight decay):** a nagy súlyokat bünteti, a modellt egyszerűbb megoldások felé terelve.
- **Adatkiterjesztés (augmentation):** a tanítóképek véletlenszerű transzformációival (tükrözés, forgatás, szín-jitter) mesterségesen növeli az adathalmaz változatosságát; ezt a dolgozat módszertani része részletezi.
- **Korai leállítás (early stopping):** a tanítást akkor állítja le, amikor a validációs teljesítmény már nem javul, megelőzve a felesleges túltanulást.

A tanítás stabilitását és gyorsaságát a **batch-normalizálás** is segíti, amely a rétegek aktivációit batch-enként normalizálja, csökkentve a belső eloszlás-eltolódást és lehetővé téve a nagyobb tanulási ráták használatát [26].

3.4. Konvolúciós neurális hálók

A teljesen összekötött MLP nem skálázódik jól képekre: egy közepes méretű kép több százezer képpontból áll, így a teljes összeköttetés kezelhetetlenül sok paramétert eredményezne, és figyelmen kívül hagyná a képek térbeli szerkezetét. A *konvolúciós neurális hálók* (CNN-ek) erre adnak választ a súlymegosztás és a lokális kapcsolatok elvével [22].


3.4.1. A konvolúciós réteg

A konvolúciós réteg kis méretű, tanulható szűrőket (*kerneleket*) csúsztat végig a képen, és minden pozícióban a szűrő alatti képrészlet és a szűrő közötti súlyozott összeget számítja ki. Egy-egy szűrő a teljes képen ugyanazokat a súlyokat használja (súlymegosztás), így egy adott lokális mintázatot (élt, sarkot, textúrát) a kép bármely pontján fel tud ismerni, miközben a paraméterek száma alacsony marad. Egy réteg több szűrője különböző jellemzőkre érzékeny *jellemzőtérképeket* (feature maps) állít elő. A rétegek egymásra építésével a háló egyre összetettebb, hierarchikus jellemzőket tanul: az alsóbb rétegek élekre és textúrákra, a felsőbbek alakzatokra és objektumrészekre reagálnak.

3.4.2. Az összevonó réteg

A konvolúciós rétegeket gyakran *összevonó* (pooling) rétegek követik, amelyek a jellemzőtérképek térbeli felbontását csökkentik: egy kis ablakon belül a maximumot (max pooling) vagy az átlagot (average pooling) veszik. Ez egyrészt csökkenti a számítási költséget és a paraméterszámot, másrészt bizonyos fokú eltolás-invarianciát biztosít. A jellemzőkinyerés (konvolúció + összevonás ismételt alkalmazása) után egy vagy több teljesen összekötött réteg végzi az osztályozást (3.2. ábra).

A konvolúciós neurális háló feldolgozási folyamata



3.2. ábra. A konvolúciós neurális háló sematikus felépítése: a konvolúciós és összevonó rétegek ismételt alkalmazásával egyre absztraktabb jellemtérképeket nyer ki a képből, majd egy teljesen összekötött réteg végzi az osztályozást.

3.4.3. Reziduális kapcsolatok és a ResNet

A hálók mélyítése elvileg növeli a kifejezőerőt, a nagyon mély hálók tanítása azonban az eltűnő gradiens jelensége miatt instabillá válhat. A ResNet architektúra [13] ezt *reziduális kapcsolatokkal* (residual/skip connections) oldja meg: az egyes rétegblokkok nem közvetlenül a kívánt leképezést, hanem ahhoz képest egy maradékot (reziduomot) tanulnak, és a blokk bemenetét egy rövidre záró kapcsolat hozzáadja a kimenethez. Ez stabilizálja a gradiensek áramlását, és lehetővé teszi a több tucat vagy száz réteg mélységű hálók megbízható tanítását. A dolgozatban a ResNet-18 – egy 18 réteg mélységű, mintegy 11 millió paraméteres reziduális háló – szolgál konvolúciós viszonyítási alapként.

3.5. A figyelmi mechanizmus és a Transformer

A Transformer-architektúra alapja az úgynevezett *skálázott pontszorzatos figyelem* (scaled dot-product attention), amely a bemenet elemei közötti összefüggéseket azok távolságától függetlenül modellezi [15]. A mechanizmus minden bemeneti elemhez három vektort rendel: egy lekérdezést (Q , query), egy kulcsot (K , key) és egy értéket (V , value). A kimenet az értékvektorok súlyozott összege, ahol a

súlyokat a lekérdezések és kulcsok hasonlósága határozza meg:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V, \quad (3.5)$$

ahol d_k a kulcsvektorok dimenziója; a $\sqrt{d_k}$ skálázó tényező a pontszorzatok nagyságát stabilizálja, megakadályozva a softmax telítődését. A gyakorlatban a modell több, párhuzamos figyelmi „fejet” (multi-head attention) alkalmaz, amelyek különböző reprezentációs alterekben tanulnak összefüggéseket, így gazdagabb leírást képesek megragadni [15].

A Transformer-kódoló e figyelmi rétegeket helyzetenkénti, teljesen összekötött előrecsatolt rétegekkel (feed-forward), maradék (reziduális) kapcsolatokkal és rétegnormalizálással kombinálja. Mivel a figyelem önmagában érzéketlen az elemek sorrendjére, a bemenethez *helyzetkódolást* (positional encoding) adnak, amely a sorrendi információt visszacsempészi a modellbe.

3.6. A Vision Transformer architektúrája


A Vision Transformer (ViT) a természetesnyelv-feldolgozásban bevált Transformer-kódolót ülteti át a képosztályozásra [2]. A feldolgozás lépései a következők:

1. **Foltokra bontás és beágyazás.** A $H \times W$ méretű bemeneti képet rögzített méretű, nem átfedő foltokra (jellemzően 16×16 pixel) bontja. Minden foltot vektorra lapít, majd egy lineáris vetítés egy rögzített dimenziójú beágyazási térbe képezi – ezek a „képtokenek”, a nyelvi modellek szótokenjeinek analógiái.
2. **Osztályozó token és helyzetkódolás.** A foltbeágyazások elé egy tanulható osztályozó token ([CLS]) fűz, amely a teljes kép összegzett reprezentációját hivatott hordozni. A sorrendi (térbeli) információt tanulható helyzetkódolás biztosítja.
3. **Transformer-kódoló.** A tokensorozatot több, egymásra épülő Transformer-kódoló réteg dolgozza fel; a többfejű önfigyelem révén minden folt közvetlen kapcsolatba kerülhet az összes többivel, így a modell a kép globális összefüggéseit is megragadja.

4. **Osztályozó fej.** A végső réteg [CLS] tokenjének reprezentációjára egy osztályozó fej (jellemzően egy- vagy kétrétegű perceptron) épül, amely az osztályok feletti döntést szolgáltatja.

A konvolúciós hálókkal szemben a ViT nem rendelkezik beépített képi induktív torzítással (lokalitás, eltolás-invariancia), ezért nagyobb adatmennyiséget vagy erős előtanítást igényel; cserébe a globális összefüggéseket rugalmasabban modellezi, és nagy adathalmazokon a CNN-ekkel versenyképes vagy azokat meghaladó teljesítményt ér el [2]. A dolgozat fő modellje egy ImageNet-en előtanított vit_base_patch16_224 architektúra, amelynek sematikus felépítését a 3.3. ábra mutatja.

A Vision Transformer feldolgozási folyamata



3.3. ábra. A Vision Transformer (ViT) sematikus felépítése: a kép foltokra bontása, lineáris beágyazás és helyzetkódolás, a [CLS] tokennel kiegészített tokenszekvencia feldolgozása a Transformer-kódoló rétegeiben, végül a [CLS] reprezentációra épülő osztályozó fej, amely a jóindulatú/rosszindulatú döntést adja.

3.7. Transzfertanulás és finomhangolás

Az orvosi képadatok jellemzően korlátozott mennyiségben állnak rendelkezésre, ami megnehezíti a nagy kapacitású modellek – különösen a ViT – nulláról történő betanítását. A *transzfertanulás* (transfer learning) erre kínál megoldást: a modellt először egy nagy, általános képadatbázison (jellemzően az ImageNet adathalmazon [12]) tanítják be, ahol általános vizuális reprezentációkat – éleket, textúrákat, alakzatokat – sajátít el. Az így előtanított modellt ezután a célfeladat kisebb adathalmazán

finomhangolják (fine-tuning). Raghu és munkatársai részletesen elemezték a transzfertanulás szerepét az orvosi képfeldolgozásban, és rámutattak, hogy az előtanított reprezentációk elsősorban a konvergencia gyorsításában és a kis adathalmazokon való stabil tanulásban segítenek [27].

A finomhangolás során bevett gyakorlat a *differentiált tanulási ráta* alkalmazása: az előtanított törzshálót (backbone) kis tanulási rátával frissítik, hogy a megtanult reprezentációk ne sérüljenek, míg az újonnan inicializált osztályozó fejet nagyobb rátával tanítják, mivel azt a feladatra nulláról kell megtanulni. A tanulás stabilitását – a már említett – bemelegítés is segíti: a kezdeti néhány epochban fokozatosan emeli a tanulási rátát. Erre azért van szükség, mert a tanítás elején a még betanítatlan osztályozó fej nagy hibát, és ezáltal nagy gradienseket termel; magas tanulási ráta mellett ezek nagy súlymódosító lépéseket okoznának, amelyek elronthatnák az előtanított törzsháló gondosan kialakult reprezentációit.

3.8. Az osztály-egyensúlytalanság kezelése

Az orvosi szűrési feladatok jellemzően erősen kiegyensúlyozatlanok: a pozitív (beteg) esetek a teljes adathalmaznak csupán töredékét teszik ki. Ilyenkor a hagyományos keresztentrópia-veszteséget a sok, könnyen osztályozható negatív példa uralja, és a modell hajlamos a többségi osztály felé torzítani. A szakirodalom több, egymást kiegészítő technikát kínál e probléma kezelésére, amelyeket a dolgozat kombináltan alkalmaz.


Súlyozott mintavételezés. Az egyik megközelítés a tanító batch-ek osztályeloszlásának kiegyensúlyozása: minden mintát az osztálya gyakoriságával fordítottan arányos súllyal választunk, így a ritka pozitív esetek a tanítás során felülreprezentálttá válnak.

Fókuszveszteség (focal loss). A Lin és munkatársai által bevezetett fókuszveszteség a keresztentrópiát úgy alakítja át, hogy a jól osztályozott példák hozzájárulását lecsökkenti, és a tanulást a nehéz, félreosztályozott esetekre összpontosítja [28]:

$$\text{FL}(p_t) = -\alpha_t (1 - p_t)^\gamma \log(p_t), \quad (3.6)$$

ahol p_t a helyes osztályhoz rendelt becsült valószínűség, $\gamma \geq 0$ a fókuszáló paraméter (amely a könnyű példák súlyát csökkenti), α_t pedig egy osztálysúly, amely a pozitív és negatív esetek közötti egyensúlyt finomhangolja. A $\gamma = 0$ választás visszaadja a súlyozott keresztentropiát.

Kétfázisú tanítás. A kiegyensúlyozott mintavételezés mellett betanított modell kimeneti valószínűségei eltérhetnek a valós, erősen kiegyensúlyozatlan előfordulási aránytól. Ezt egy második, kalibráló fázis korrigálhatja, amelyben a modellt a valós eloszlású adaton, kisebb tanulási rátával tanítjuk tovább, így a kimeneti valószínűségek a tényleges priorhoz igazodnak (3.4. ábra).



3.4. ábra. A kétfázisú tanítási stratégia: az első, kiegyensúlyozott fázis a diszkriminatív jellemzők megtanulását célozza, a második, kalibráló fázis pedig a kimeneti valószínűségeket a valós előfordulási arányhoz igazítja.

3.9. Kiértékelési metrikák

Erősen kiegyensúlyozatlan feladatban a nyers pontosság (accuracy) félrevezető, hiszen a többségi osztály triviális megjósolásával is magas érték érhető el. Ezért orvosi szűrésnél a tévesztési mátrixból (confusion matrix) származtatott, osztályérzékeny metrikákat alkalmazunk. Jelölje TP , TN , FP és FN rendre a valódi pozitív, valódi negatív, hamis pozitív és hamis negatív esetek számát.

$$\text{Érzékenység (sensitivity)} = \frac{TP}{TP + FN}, \quad \text{Specifitás (specificity)} = \frac{TN}{TN + FP}, \quad (3.7)$$

$$\text{PPV} = \frac{TP}{TP + FP}, \quad \text{NPV} = \frac{TN}{TN + FN}. \quad (3.8)$$

Az **érzékenység** azt méri, hogy a modell a valóban rosszindulatú eseteknek mekkora hányadát ismeri fel – szűrőeszköznél ez a legkritikusabb mutató, mivel a fel nem ismert rák (hamis negatív) a legsúlyosabb kimenetel. A **negatív prediktív érték** (NPV) azt fejezi ki, hogy a „jóindulatú” besorolás mennyire megbízható.

ROC-görbe és AUC. A bináris osztályozók döntési küszöbtől független értékelésére a *működési jelleggörbét* (Receiver Operating Characteristic, ROC) használjuk, amely a valódi pozitív arányt (érzékenység) a hamis pozitív arány ($FPR = FP / (FP + TN)$) függvényében ábrázolja a küszöb változtatásával. A görbe alatti terület (Area Under the Curve, AUC) egyetlen számba sűríti a rangsorolási képességet: értéke 0,5 (véletlen találgatás) és 1,0 (tökéletes elkülönítés) között mozog.

Részleges AUC (pAUC). Erős egyensúlytalanságnál és klinikai kontextusban gyakran csak a görbe egy meghatározott szakasza érdekes. Az ISIC 2024 verseny elsődleges metrikája a 80%-os érzékenység feletti tartományra korlátozott részleges AUC (partial AUC), amely kifejezetten a klinikailag elvárt, magas érzékenységi tartományban méri a teljesítményt; a metrika értéke $[0; 0,2]$ tartományba esik, ahol 0,2 a tökéletes osztályozó értéke [3].

Kalibráció és Brier-pontszám. A jó rangsorolás (magas AUC) nem garantálja, hogy a modell által kiadott valószínűségek megbízhatóak. A *kalibráció* azt méri, hogy a becsült valószínűségek mennyire felelnek meg a tényleges bekövetkezési aránynak; Guo és munkatársai rámutattak, hogy a modern neurális hálók gyakran rosszul kalibráltak [29]. A valószínűségi kimenetek minőségének egyik összegző mérőszáma a Brier-pontszám, a becsült valószínűség és a tényleges címke közötti átlagos négyzetes eltérés:

$$\text{Brier} = \frac{1}{N} \sum_{i=1}^N (p_i - y_i)^2, \quad (3.9)$$

ahol p_i a i -edik mintára becsült valószínűség, $y_i \in \{0, 1\}$ a valódi címke; az alacsonyabb érték jobb kalibrációt jelez.

3.10. Statisztikai elemzés

Mivel a tesztalmban a pozitív esetek száma korlátozott, a pontbecslések (érzékenység, specificitás, AUC) mellett azok bizonytalanságát is jelölni kell. Az arányjellegű metrikákhoz (érzékenység, specificitás) az egzakt, binomiális eloszláson alapuló Clopper–Pearson-féle konfidencia-intervallum ad megbízható becslést kis mintaszám esetén is. Az AUC esetében a DeLong-féle, nemparaméteres módszer szolgáltat konfidencia-intervallumot, illetve teszi lehetővé két modell AUC-értékének páros összehasonlítását; a módszer egy gyors, korszerű implementációját Sun és Xu adta meg [30]. E statisztikai eszközök biztosítják, hogy a modellek közötti különbségekről tett állítások ne csupán a mintavételi zaj következményei legyenek.

3.11. Kommunikációs technológiák: SSE és az MCP

A dolgozatban bemutatott rendszer valós idejű, token-szintű válaszközvetítést és egy nyelvi modellt kiszolgáló komponensekkel való kommunikációt igényel; ezt két technológia teszi lehetővé.

Szerver-küldött események (SSE). A szerver-küldött események (Server-Sent Events) a HTML szabvány részét képező, egyirányú, szerverről kliensre irányuló adatfolyam-mechanizmus egyetlen, tartós HTTP-kapcsolaton keresztül [31]. Az SSE különösen alkalmas a nagy nyelvi modellek token-szintű, fokozatos válaszainak továbbítására, mivel a kliens a szöveget generálással egyidejűleg, darabonként jeleníti meg, jelentősen javítva a felhasználói élményt.

Model Context Protocol (MCP). A Model Context Protocol az Anthropic által 2024-ben közzétett nyílt szabvány, amely egységesíti a nagy nyelvi modellek és a külső eszközök, adatforrások közötti kommunikációt [32]. Az MCP a JSON-RPC 2.0 üzenetformátumra épül [33], és többféle átviteli réteget támogat, többek között a helyi folyamatok közötti szabványos be- és kimeneti (stdio) csatornát.

A dolgozat rendszerében az MCP biztosítja a backend és a modellt kiszolgáló komponens közötti, jól strukturált kommunikációt; e megoldás részletes tárgyalása a mérnöki részben található.

4. fejezet

A bőrelváltozás-osztályozó modell fejlesztése és kiértékelése

Ez a fejezet a bőrelváltozás-osztályozó modell fejlesztését és kiértékelését mutatja be. Először az ISIC 2024 adathalmaz előkészítését ismertetjük, majd a transzfertanulás elvén finomhangolt Vision Transformer modellt és annak tanítási folyamatát, ezt követően a három viszonyítási alapot (a ResNet-18 konvolúciós hálót, az EVA02 versenymodellt és a Gemini nagy nyelvi modellt), végül a kísérleti elrendezést és az elért eredményeket a hozzájuk tartozó statisztikai elemzéssel.

4.1. Az ISIC 2024 adathalmaz és előkészítése

A kísérletekhez az ISIC 2024 verseny (*Skin Cancer Detection with 3D-TBP*) nyilvános tanító adathalmazát használtuk [3]. Az adathalmaz a teljes testfelszín háromdimenziós fényképezéséből kivágott, mintegy 401 000 bőrelváltozás-felvételt tartalmaz, amelyek mindegyikéhez bináris címke tartozik (jóindulatú vagy rosszindulatú). Az adathalmaz meghatározó tulajdonsága a rendkívül erős osztály-egyensúlytalanság: a rosszindulatú esetek száma mindössze 393, ami megközelítőleg 1:1000 pozitív–negatív arányt jelent.

A v3 előzetes kísérletektől eltérően – amelyek a többségi (jóindulatú) osztály 50%-os alulmin-tázásával (undersampling) dolgoztak – a végleges modellt a **teljes** adathalmazon tanítottuk, hogy a negatív osztály teljes változatosságát kihasználjuk. Az adathalmazt rétegzett (stratifikált) módon, rög-

zített véletlenmaggal ($seed = 42$) osztottuk fel tanító, validációs és teszhalmazra 70:15:15 arányban; a teszhalmazt a tanítás teljes folyamata alatt érintetlenül hagytuk, és kizárólag a végső kiértékeléshez használtuk fel. A felosztás eredményét a 4.1. táblázat foglalja össze.

4.1. táblázat. Az ISIC 2024 adathalmaz rétegzett felosztása (teljes adathalmaz, $seed = 42$).

Részhalmaz	Összes kép	Rosszindulatú (pozitív)
Tanító (train)	280 741	275
Validációs (val)	60 159	59
Teszt (test)	60 159	59
Összesen	401 059	393

4.2. A Vision Transformer modell

A kutatás modellfejlesztési megközelítése a **transzfertanulás** (transfer learning): az ImageNet adathalmazon előtanított, általános vizuális reprezentációkat hordozó súlyokat a bőrelváltozás-osztályozás szűk doménjére hangoltuk finomhangolással (fine-tuning). Ez a stratégia különösen indokolt, ha a céldoméni adathalmaz korlátozott számú pozitív példát tartalmaz – az ISIC 2024 esetén mindössze 393 rosszindulatú esetet a közel 401 000 képből –, mivel az előtanított jellemzők (textúrák, alakok, élek) hatékonyan transzferálhatók még az orvosi képi feladatokra is [27].

A fő modell a `vit_base_patch16_224` architektúra [2], amelyet a `timm` könyvtárból [34] töltöttünk be. A törzsháló a 224×224 pixeles bemenetből egy 768 dimenziós reprezentációt állít elő, amelyre egy egyedi osztályozó fejet illesztettünk: rétegnormalizálás, dropout ($p = 0,3$), egy 256 neuronos lineáris réteg GELU aktivációval, majd egy újabb dropout ($p = 0,2$) és a kétosztályos kimeneti réteg.

4.2.1. Kétfázisú tanítás

A modellt két fázisban tanítottuk, hogy egyszerre kezeljük az osztály-egyensúlytalanságot és a kimeneti valószínűségek kalibrációját (3.4. ábra):

- **1. fázis – kiegyensúlyozott tanítás.** Súlyozott mintavételezéssel (`WeightedRandomSampler`) közel 1:1 arányú batch-eket állítottunk elő, így a ritka pozitív esetek a tanítás során felülreprezentáltakká váltak. A veszteségfüggvény súlyozott fókuszveszteség [28] volt.
- **2. fázis – kalibráció.** A modellt a valós, erősen kiegyensúlyozatlan eloszlású adaton, tizedére csökkentett tanulási rátával tanítottuk tovább, hogy a kimeneti valószínűségek a tényleges priorhoz igazodjanak.

4.2.2. Az osztály-egyensúlytalanság kezelése

Az egyensúlytalanságot három, egymást kiegészítő technikával kezeltük: (i) súlyozott mintavételezés a kiegyensúlyozott batch-ekhez; (ii) súlyozott fókuszveszteség, amely a nehéz, félreosztályozott eseteket helyezi előtérbe (3.6. egyenlet, $\alpha = 0,25$, $\gamma = 2,0$, a pozitív osztály súlya 7,0); valamint (iii) a kisebbségi osztályra alkalmazott erősebb képaugmentáció. A számítási költség kézben tartására az 1. fázis epochonkénti mintaszámát 50 000-re korlátoztuk; mivel a kiegyensúlyozott mintavételezés a 275 pozitív esetet erősen felülmintázza, ez a korlátozás a tanítási stratégiát érdemben nem befolyásolja, viszont gyakoribb validációt és korai leállítást tesz lehetővé.

4.2.3. Adataugmentáció

A túltanulás csökkentésére tanítás közben véletlenszerű augmentációt alkalmaztunk. A többségi (jóindulatú) osztályra alapszintű transzformációkat – vízszintes és függőleges tükrözés, elforgatás, szín-jitter és affin torzítás –, a kisebbségi (rosszindulatú) osztályra ezeknél erősebb augmentációt (nagyobb szögű forgatás, erősebb szín-jitter, perspektivikus torzítás, elmosás) használtunk, hogy az egyes pozitív példák minél több, eltérő változatban kerüljenek a modell elé. A validációs és teszhalmazon nem alkalmaztunk augmentációt, biztosítva a determinisztikus, reprodukálható kiértékelést.

4.2.4. Hiperparaméterek

A tanítás hiperparamétereit a 4.2. táblázat foglalja össze. Az optimalizáló AdamW volt, differenciált tanulási rátával (a törzsháló kisebb, a fej nagyobb rátát kapott), háromepochos lineáris bemelegítéssel,

amelyet koszinusz ütemezésű csökkentés követett. A tanítás vegyes pontosságú (mixed precision) módban, gradiens-akkumulációval futott, az effektív batch-méret 128 volt.

4.2. táblázat. A ViT modell tanításának fő hiperparaméterei.

Paraméter	Érték
Architektúra	vit_base_patch16_224 (ImageNet-előtanított)
Bemeneti felbontás	224×224
Batch-méret	32 (effektív 128, grad. akkumuláció $\times 4$)
Optimalizáló	AdamW, súlycsökkenés 10^{-2}
Tanulási ráta (törzs)	2×10^{-6}
Tanulási ráta (fej)	2×10^{-5}
Ütemezés	3 epoch bemelegítés + koszinusz csökkenés
1. fázis epochsza	18 (korai leállítás, türelem = 5)
2. fázis epochsza	3 (kalibráció)
Mintasza / epoch	50 000
Fókuszvesztés	$\alpha = 0,25$, $\gamma = 2,0$, pozitív súly = 7,0

4.3. A ResNet-18 viszonyítási alap

Viszonyítási alapként egy szintén transzfertanulással adaptált, ImageNet-en előtanított ResNet-18 hálót [13] finomhangoltunk, amely a mély tanulásban széles körben alkalmazott, standard konvolúciós referenciamodell. A ResNet-18 **pontosan ugyanazt** a feldolgozási folyamatot használja, mint a ViT – azonos adatfelosztás (azonos véletlenmaggal, így azonos teszhalmaz), azonos egyensúlytalanságkezelés, azonos kiértékelési protokoll –, így a teljesítménykülönbség értelmezésekor a tanítási és kiértékelési feltételek nem jelentenek zavaró tényezőt. A finomhangoláshoz – mivel a konvolúciós hálók nagyobb tanulási rátát viselnek el – a törzsháló, illetve a fej tanulási rátáját 1×10^{-5} , illetve 1×10^{-4} értékre emeltük; minden egyéb beállítás megegyezett a ViT-ével.

Fontos ugyanakkor megjegyezni, hogy a ResNet-18 lényegesen kevesebb paraméterrel rendelkezik (mintegy 11 millió), mint a ViT-Base (mintegy 86 millió). A két modell tehát nem csupán az

architektúrában (konvolúció kontra figyelem), hanem a kapacitásban is különbözik; a ResNet-18-at ezért *standard viszonyítási alapként* kezeljük, nem pedig szigorúan azonos kapacitású kontrollként. A megfigyelt teljesítménykülönbséget ennek megfelelően a két tényező együttes hatásaként értelmezzük.

4.4. Az EVA02 viszonyítási alap

Harmadik viszonyítási alapként az ISIC 2024 verseny egyik legjobb, kizárólag képeket használó publikált megoldását, egy EVA02-alapú modellt (`eva02_small_patch14_336`) is kiértékelünk. Ez a modell a saját, szivárgásmentes validációs foldján szerepel: mivel a teljes adat 80%-án tanították, a mi teszhalmazonkon történő kiértékelése adatszivárgást okozna, ezért a hivatalos ISIC 2024 pAUC-metrikát a saját, szivárgásmentes foldján számítottuk ki. Fontos megjegyezni, hogy az EVA02 a natív 336×336 felbontáson fut (szemben a ViT 224×224 -ével), ezért nem szigorú, azonos felbontású kontroll, hanem az EVA02-vel szembeni viszonyítás.

4.5. A Gemini zero-shot viszonyítási alap

Negyedik viszonyítási alapként a Google Gemini multimodális nagy nyelvi modelljét [19] (a `gemini-2.5-flash` változatot) értékeltük *zero-shot* módban, azaz célzott betanítás nélkül. A modell minden képhez egy minimális szöveges utasítást kapott, amely a rosszindulatúság valószínűségének $[0; 1]$ skálán történő becslésére kérte; sem példákat (few-shot), sem klinikai metaadatot nem adtunk a bemenethez. Mivel a Gemini API-alapú, soronkénti lekérdezése a teljes, mintegy 60 000 elemű teszhalmazon nem volt gyakorlatias, a Gemini-kiértékelést egy 2 000 képes részhalmazon végeztük, amely a teszhalmaz **összes** pozitív esetét és véletlenszerűen mintavételezett negatív eseteket tartalmazott; a tisztességes összehasonlítás érdekében a ViT modellt ugyanezen a részhalmazon is kiértékeljük.

A Gemini szerepe a dolgozatban kettős szempontból tanulságos: egyrészt megmutatja, mire képes egy általános célú, célzott betanítás nélküli multimodális modell ezen a feladaton, másrészt rávilágít a célzottan betanított osztályozó modell előnyeire – összhangban a szakirodalmi megfigyelésekkel [20].

4.6. Kísérleti elrendezés

A modelleket a Kaggle felhőplatformján, NVIDIA Tesla T4 GPU-n tanítottuk és értékeltük. Az implementáció a PyTorch keretrendszerre [35], a modellek betöltése a `timm` könyvtárra [34], a metrikák és statisztikai számítások pedig a `scikit-learn` könyvtárra [36] épültek. A reprodukálhatóság érdekében minden véletlenszerű folyamatot rögzített maggal ($seed = 42$) inicializáltunk.

A kiértékelést két klinikailag értelmezhető *működési ponton* végeztük: a $\geq 0,90$ érzékenységnél (klinikai szűrési standard) és a $\geq 0,80$ érzékenységnél (az ISIC 2024 verseny pAUC-küszöbe). A döntési küszöböt minden esetben a validációs halmazon kalibráltuk, majd a rögzített küszöböt alkalmaztuk a teszhalmazon. A teljesítményt a 3.7–3.8. egyenletekben definiált metrikákkal, az AUC-val és a hivatalos ISIC 2024 pAUC-val mértük; a pontbecslések bizonytalanságát Clopper–Pearson-féle (arányok) és DeLong-féle (AUC) konfidencia-intervallumokkal [30] jelöltük, a modellek közötti AUC-különbségeket pedig a DeLong-féle páros teszttel vizsgáltuk. A valószínűségi kalibrációt a Brier-pontszámmal [29] jellemeztük.

4.6.1. Reprodukálhatóság

A kísérletek megismételhetőségét az alábbiak biztosítják.

- **Környezet és hardver.** A tanítás és a kiértékelés a Kaggle felhőplatformján, egyetlen NVIDIA Tesla T4 (16 GB) GPU-n futott; a teljes tanítás körülbelül 10 órát vett igénybe. A megvalósítás PyTorch 2.6 alatt készült, a Kaggle-környezet akkori `timm` (modellbetöltés), `torchvision`, `scikit-learn` (felosztás, metrikák), `SciPy` (konfidencia-intervallumok), `NumPy`, `pandas` és `Pillow` verzióival.
- **Determinizmus.** A rögzített mag ($seed = 42$) a PyTorch, a `NumPy` és az adatfelosztás (`train_test_split`) véletlenszerű folyamataira egyaránt érvényes.
- **Adatfelosztás.** Rétegzett (stratifikált) 70:15:15 felosztás (`random_state = 42`), a 4.1. táblázat darabszámaival; a teszhalmazt a tanítás teljes folyamata alatt érintetlenül hagytuk.


- **Tanítási recept.** A 4.2. táblázat hiperparaméterei szerint: kétfázisú tanítás, AdamW optimalizáló, differenciált tanulási ráta, 3 epoch bemelegítés és koszinusz csökkenés, vegyes pontosság, effektív 128-as batch-méret és epochonként 50 000 mintára korlátozott merítés.
- **Küszöbválasztás.** A két működési pont döntési küszöbét a validációs halmazon rögzítettük (0,170, illetve 0,270), majd változatlanul alkalmaztuk a teszhalmazon; a küszöböket az `inference_config.json` fájlban tároltuk.
- **Mentett artefaktumok.** A legjobb modellállapot (`vit_isic_best.pth`), a küszöböket és a validációs pAUC-t tartalmazó `inference_config.json`, a tanítási napló (`training_log.csv`), a teszhalmazon készült nyers predikciók (`predictions_test.csv`) és a ROC-adatok (`roc_test.csv`) a projekt tárolójában elérhetők.

4.7. Eredmények

Ebben a szakaszban a ViT modell teljesítményét értékeljük a teszhalmazon, majd összevetjük a ResNet-18, az EVA02 és a Gemini viszonyítási alapokkal.


4.7.1. A tanítás konvergenciája

A 4.1. ábra a ViT modell tanítása során mért veszteség, valamint a validációs AUC és pAUC alakulását mutatja epochonként. A validációs AUC a kezdeti 0,73-ról 0,90-re, a pAUC 0,055-ről 0,132-re emelkedett; a legjobb validációs pAUC a 11. epochnál állt elő, a korai leállítás pedig a 16. epochnál aktiválódott. A második (kalibrációs) fázis a validációs metrikákat érdemben nem változtatta, így a végső modell lényegében az első fázis legjobb állapota.



4.1. ábra. A ViT modell tanításának konvergenciája: a tanítási veszteség, valamint a validációs AUC és pAUC alakulása az epochok függvényében.

A 4.2. ábra a ViT és a ResNet-18 validációs konvergenciáját veti össze. Jól látszik, hogy a ViT az első epochoktól kezdve következetesen magasabb validációs AUC-t és pAUC-t ér el, és a tanítás során végig megőrzi előnyét; a két görbe nem keresztezi egymást, ami a ViT robusztus fölényére utal a teljes tanítási folyamat alatt.



4.2. ábra. Tanítási konvergencia: a ViT-Base és a ResNet-18 validációs AUC-jának (bal) és pAUC-jának (jobb) alakulása epochonként, az első (kiegyensúlyozott) tanítási fázisban.


4.7.2. A ViT teljesítménye a teszhalmazon

A 4.3. táblázat a ViT modell teljesítményét foglalja össze a két működési ponton.

4.3. táblázat. A ViT modell teljesítménye a tesztalmazon (60 159 kép, 59 pozitív), két működési ponton.


Metrika	Érzékenység $\geq 0,90$	Érzékenység $\geq 0,80$
AUC (95% CI)	0,939 (0,915–0,963)	
pAUC (TPR $\geq 0,80$)	0,159	
Brier-pontszám	0,047	
Küszöb	0,170	0,270
Érzékenység (95% CI)	0,966 (0,883–0,996)	0,881 (0,771–0,951)
Specifitás (95% CI)	0,668 (0,664–0,671)	0,843 (0,840–0,846)
PPV / NPV	0,003 / 1,000	0,005 / 1,000

A 4.3. ábra a ViT modell ROC-görbét mutatja, kiemelve a pAUC számításához használt, $TPR \geq 0,80$ tartományt.



4.3. ábra. A ViT modell ROC-görbéje a teszhalmazon, a pAUC számításához használt $TPR \geq 0,80$ tartomány kiemelésével.

A modell osztályozási viselkedését szemléletesen mutatja a 4.4. ábra, amely a teszhalmaz jó- és rosszindulatú eseteire külön ábrázolja a becsült rosszindulatúság-valószínűségek eloszlását. A jóindulatú esetek pontszámai erősen a nulla közelébe tömörülnek, míg a rosszindulatú esetek eloszlása a magasabb értékek felé tolódik; a két eloszlás közötti – ámbár nem tökéletes – elkülönülés magyarázza a magas AUC-t, az átfedés pedig azt, hogy egyetlen küszöb mellett miért elkerülhetetlen a hamis pozitívok jelentős száma az extrém egyensúlytalanság mellett.



4.4. ábra. A ViT modell által becsült rosszindulatúság-valószínűségek eloszlása a teszhalmazon, osztályonként (logaritmikus függőleges tengely). A szaggatott vonalak a két működési pont döntési küszöbét jelölik.


4.7.3. A ResNet-18 teljesítménye

A ResNet-18 viszonyítási alap teljesítményét a 4.4. táblázat foglalja össze. A konvolúciós háló a $\geq 0,90$ érzékenységi ponton a teszhalmaz mind a 59 pozitív esetét felismerte (érzékenység 1,0), ehhez azonban rendkívül alacsony, 0,40 specificitás társult – vagyis a negatív esetek 60%-át tévesen jelölte gyanúsnak.

4.4. táblázat. A ResNet-18 modell teljesítménye a tesztalmazon (60 159 kép, 59 pozitív).

Metrika	Érzékenység $\geq 0,90$	Érzékenység $\geq 0,80$
AUC (95% CI)	0,876 (0,837–0,914)	
pAUC (TPR $\geq 0,80$)	0,122	
Brier-pontszám	0,075	
Küszöb	0,172	0,241
Érzékenység (95% CI)	1,000 (0,939–1,000)	0,864 (0,750–0,940)
Specifitás (95% CI)	0,400 (0,396–0,404)	0,625 (0,621–0,629)
PPV / NPV	0,002 / 1,000	0,002 / 1,000

A két képi modell osztályozási viselkedését a 4.5. ábra tévesztési mátrixai szemléltetik a két működési ponton. Az ábrából közvetlenül leolvasható a ViT előnye: azonos érzékenységi tartományban a ViT lényegesen kevesebb hamis pozitívot (a felső sor jobb oldali cellája) termel, mint a ResNet-18.



4.5. ábra. A ViT és a ResNet-18 tévesztési mátrixai a tesztalmazon, a két működési ponton (VP: valódi pozitív, VN: valódi negatív, HP: hamis pozitív, HN: hamis negatív). A színskála logaritmus, az extrém osztály-egyensúlytalanság miatt.

4.7.4. Összehasonlítás a viszonyítási alapokkal


A 4.5. táblázat a négy modellt veti össze a két közvetlenül összehasonlítható minőség-mérőszám – az AUC és a hivatalos ISIC 2024 pAUC – mentén. Mindkét mutató a modellek rangsorolási képességét

méri, és független a döntési küszöbtől, így akkor is értelmes az összevetésük, ha az egyes modellek saját, szivárgásmentes (held-out) halmazukon kerültek kiértékelésre.

4.5. táblázat. A négy modell összehasonlítása az AUC és a hivatalos pAUC mentén. Az EVA02 a saját, szivárgásmentes validációs foldján szerepel; a Gemini csak egy 2 000 elemű részhalmazon futott, ezért a feltüntetett pAUC-ja a részhalmazon mért érték hivatalos $[0;0,20]$ skálára átskálázott közelítő becslése ($\approx$).

Modell	AUC	pAUC	Kiértékelési halmaz
ViT-Base (saját, finomhangolt)	0,939	0,159	teszt (60 159, 59 poz.)
EVA02 (Kaggle-ref.)	0,929	0,158	val-fold (1 651, 79 poz.)
ResNet-18 (CNN, viszonyítási alap)	0,876	0,122	teszt (60 159, 59 poz.)
Gemini 2.5 Flash (zero-shot)	0,740	$\approx 0,078$	részhalmaz (2 000, 59 poz.)

A 4.6. ábra a négy modell AUC- és pAUC-értékeit szemlélteti.



4.6. ábra. A négy modell összehasonlítása az AUC (bal) és a hivatalos ISIC 2024 pAUC (jobb) mentén. A Gemini pAUC-értéke közelítő becslés (egy 2 000 elemű részhalmazon mérve, a hivatalos skálára átskálázva), ezért szaggatott, halványított oszlop jelöli. A pAUC elméleti maximuma 0,20.

ViT kontra ResNet-18 (azonos teszhalmaz). A két modell pontosan ugyanazon a teszhalmazon, azonos feldolgozási folyamattal került kiértékelésre, így a tanítási és kiértékelési feltételek nem zavaró tényezők (a kapacitásbeli különbségre tett megjegyzés mellett). A ViT minden mutatóban érdemben felülmúlja a ResNet-et: AUC 0,939 kontra 0,876, pAUC 0,159 kontra 0,122. A különbség a magas érzékenységű tartományban a legmarkánsabb: a $\geq 0,80$ érzékenységi ponton a specificitás 0,843 kontra 0,625, a $\geq 0,90$ ponton pedig 0,668 kontra 0,400 – vagyis a ViT azonos érzékenység mellett lényegesen kevesebb téves riasztást ad.

ViT kontra EVA02. A ViT-Base az EVA02-vel összemérhető szintet ér el: a hivatalos pAUC szinte azonos (0,159 kontra 0,158), az AUC pedig hasonló (0,939 kontra 0,929). Mivel mindkettő szívárgásmentes halmazon, a hivatalos metrikával készült, az összevetés releváns; ugyanakkor csak *indikatív*, mivel az EVA02 eltérő, kisebb és magasabb prevalenciájú halmazon szerepelt. Fontos azonban, hogy az EVA02 a natív 336×336 felbontásán fut (szemben a ViT 224×224 -ével), ezért ez nem szigorú, azonos felbontású kontroll.

ViT kontra Gemini (zero-shot). A célzott betanítás nélküli, általános célú Gemini modell jelentősen elmarad (AUC 0,740): hajlamos a legtöbb elváltozást gyanúsaknak jelölni, ezért a specificitása alacsony. A ViT és a Gemini AUC-jának különbsége a DeLong-féle páros teszttel statisztikailag erősen szignifikáns ($z = 6,49$, $p < 0,001$). Ez megerősíti a rendszer tervezési döntését, amely a klasszifikációt egy célzottan betanított modellre, a magyarázatot pedig a nagy nyelvi modellre bízta.

4.7.5. Statisztikai elemzés

A modellek rangsorolási teljesítményének bizonytalanságát a DeLong-féle 95%-os konfidenciaintervallumok jellemzik. A ViT AUC-jának intervalluma (0,915–0,963) és a ResNet-é (0,837–0,914) gyakorlatilag nem fed át, ami a két modell közötti különbség statisztikai szignifikanciájára utal. Mivel a ViT és a ResNet ugyanazon a teszhalmazon került kiértékelésre, a mentett predikciókból a DeLong-féle páros teszt formálisan is elvégezhető.

A valószínűségi kalibrációt a Brier-pontszám jellemzi. Mindkét képi modell Brier-pontszáma (ViT: 0,047, ResNet: 0,075) magasabb a triviális, a prevalenciát jósló alapvonalénál (0,001), ami a

kimeneti valószínűségek gyenge kalibráltságát jelzi – ez az erős osztály-egyensúlytalanság és a ki-egyensúlyozott mintavételezés ismert következménye. A ViT ugyanakkor jobban kalibrált, mint a ResNet. Hangsúlyozandó, hogy a *rangsorolás* (AUC, pAUC) erős; a nyers valószínűségek utólagos kalibrálása a jövőbeli munka tárgya.

4.7.6. Az eredmények megbeszélése és korlátai

Az eredmények fő tanulsága, hogy a finomhangolt ViT-Base modell eléri az EVA02 szintjét, miközben jelentősen felülmúlja mind a klasszikus konvolúciós alapot (ResNet-18), mind a zero-shot nagy nyelvi modellt (Gemini). A magas érzékenységu működési ponton mért közel tökéletes negatív prediktív érték ($NPV \approx 1,0$) klinikai szűrőeszközként kedvező: a „jóindulatú” besorolás megbízható. Hangsúlyozandó ugyanakkor, hogy ezt a közel tökéletes NPV-t nagyrészt az extrém alacsony prevalencia magyarázza; a gyakorlati hasznót elsősorban a magas érzékenység adja.

Az értelmezésnél több korlátot figyelembe kell venni. (i) A tesztalmazban csak 59 pozitív eset szerepel, ami a metrikák – különösen az érzékenység és a pAUC – becslését érzékenyvé teszi a mintavételi zajra; ezt a megadott konfidencia-intervallumok tükrözik. (ii) A pozitív prediktív érték (PPV) nagyon alacsony ($\approx 0,005$), ami az extrém, $\sim 1:1000$ arányú osztály-egyensúlytalanság közvetlen következménye – nagyszámú negatív eset mellett még jó specificitás mellett is sok a hamis pozitív. A modell kimenete ezért nem diagnózis, hanem kockázati jelzés: a gyakorlatban egy pozitív jelzés sokszor téves riasztás, így az eredmény kizárólag a szakorvosi vizsgálat indokoltságának jelzésére alkalmas. (iii) Az EVA02 eltérő (kisebb, magasabb prevalenciájú) halmazon és felbontáson került kiértékelésre, ezért referenciaként, nem szigorú kontrollként értelmezendő. (iv) A kimeneti valószínűségek kalibrációja további javítást igényel. (v) A tanító- és tesztalmaz a teljes test háromdimenziós fényképezéséből (3D-TBP) kivágott felvételekből áll, amelyek eloszlása eltér egy átlagos felhasználó okostelefonnal készített képeitől (megvilágítás, fókusz, felbontás, testtáj); a tesztalmazon mért teljesítmény ezért nem vihető át automatikusan valós, otthoni használatra, aminek igazolása prospektív, valós környezetű vizsgálatot igényelne.

5. fejezet

A rendszer tervezése és megvalósítása

Ez a fejezet a DermAI rendszer mérnöki megvalósítását mutatja be: a betanított osztályozó modellt egy teljes, végponttól végpontig működő alkalmazássá egészíti ki, amely okostelefonon és webböngészőben egyaránt elérhető. Először a követelményeket és a rendszerarchitektúrát ismertetjük, majd komponensenként a megvalósítást: a modellt kiszolgáló réteget, a backendet, a mobil- és webalkalmazást, a hitelesítést és a felhőalapú adattárolást, végül a hálózati hibatűrést és a biztonsági megfontolásokat.

5.1. Követelmények

A rendszerrel szemben támasztott elvárások két forrásból fakadnak: egyrészt a dolgozat céljából – egy nem szakértő felhasználó által, hétköznapi eszközön végigvihető szűrési folyamatból –, másrészt a megvalósítás valós körülményeiből: a változó hálózati elérhetőségből, az érzékeny egészségügyi adatok kezeléséből és a korlátozott, gyakran cserélődő GPU-erőforrásból. Az alábbiakban előbb a funkcionális, majd a nem-funkcionális elvárásokat foglaljuk össze.


5.1.1. Funkcionális követelmények

A rendszerrel szemben támasztott fő funkcionális elvárások a következők:

- A felhasználó fényképet készíthet vagy tölthet fel egy bőrelváltozásról (kamera vagy galéria).

- A rendszer a feldolgozás előtt ellenőrzi a kép minőségét és relevanciáját, és elutasítja az értékelhetetlen felvételeket.
- A bőrelváltozást egy ViT-alapú modell osztályozza (jóindulatú / rosszindulatú), konfidencia-értékkel.
- A rendszer természetes nyelvű magyarázatot ad az eredményről, az ABCDE-szabály figyelembevételével.
- A felhasználó utólagos kérdéseket tehet fel az elváltozással kapcsolatban (párbeszéd).
- A felhasználó bejelentkezik, és a feltöltött képek, valamint a beszélgetések a saját fiókjához kötve, biztonságosan tárolódnak.

A rendszer fő használati eseteit a 5.1. ábra foglalja össze.



5.1. ábra. A rendszer használati eset diagramja: a felhasználó fő céljai, valamint az „elváltozás elemzése” use case kötelező lépései (képvalidáció, osztályozás, magyarázat).

5.1.2. Nem-funkcionális követelmények

- **Reszponzivitás:** az AI-válaszok token-szintű, fokozatos megjelenítése, hogy a felhasználó ne egy hosszú várakozás után, hanem folyamatosan kapjon visszajelzést.
- **Hibatűrés:** a rendszer alkalmazkodjon a változó hálózati körülményekhez és a modellt kiszolgáló komponens időszakos elérhetetlenségéhez.
- **Biztonság:** a felhasználói adatok hitelesített hozzáférés mögött, felhasználónként elkülönítve tárolódjanak; a titkos kulcsok ne kerüljenek a forráskódba.
- **Hordozhatóság:** a modellt kiszolgáló komponens címe futás közben módosítható legyen, hogy a (gyakran változó címen elérhető) GPU-háttér újraindítása ne igényelje az alkalmazás újratelepítését.


Ezek a nem-funkcionális elvárások közvetlenül alakították a rendszer felépítését: a responzivitást a token-szintű adatfolyam (SSE), a hibatűrést az újrapróbálkozó hálózati réteg és az önjavító modellkliens, a hordozhatóságot a modellszolgáló futásidejű címfrissítése, a biztonságot pedig a hitelesített végpontok és a felhasználónként elkülönített tárolás valósítja meg. E megoldások részleteit a következő szakaszok tárgyalják.

5.2. Rendszerarchitektúra

A DermAI több, jól elkülönülő komponensből álló, elosztott rendszer. A két kliens (Android alkalmazás és webes felület) külön-külön backendhez kapcsolódik, amelyek azonban közös elveken működnek, és ugyanazt a modellt kiszolgáló réteget, illetve felhőszolgáltatásokat használják. A komponensek és kapcsolataik áttekintését a 5.2. ábra mutatja.

- **Android alkalmazás** (Kotlin) – a mobil kliens; a **Flask** alapú backendhez [37] kapcsolódik.
- **Webes felület** (HTML/JavaScript) – a böngészőkliens; a **FastAPI** alapú backendhez [38] kapcsolódik.

- **Modellt kiszolgáló réteg** – egy MCP-szerver [32], amely a GPU-n futó ViT modellt szolgáltató meg.
- **Gemini 2.5 Flash** [19] – a képvalidációt, a magyarázatgenerálást és a párbeszédet végző nagy nyelvi modell.
- **Firebase** [39] – hitelesítés (Authentication), adatbázis (Firestore) és fájl tárolás (Storage).



5.2. ábra. A rendszer komponens-diagramja: a kliensek (Android, web), a backendek (Flask, FastAPI), a modellt kiszolgáló MCP-réteg és a GPU-n futó ViT, valamint a Firebase és a Gemini szolgáltatások, a köztük lévő kommunikációs protokollokkal.

A rendszer rétegzett, a felelősségi körök szerint szétválasztott felépítést követ. A kliensek kizárólag a felhasználói interakcióért és a megjelenítésért felelnek; az üzleti logikát – a kérések összehangolását, a külső szolgáltatások hívását és a hozzáférés-ellenőrzést – a backend végzi; a számításigényes modellinferencia pedig egy külön, GPU-val rendelkező rétegbe került. Ez a szétválasztás lehetővé teszi, hogy az egyes komponensek egymástól függetlenül legyenek fejleszthetők, cserélhetők és skálázhatók.

A backend tölti be a központi összehangoló (orkesztrátor) szerepét: ez fogadja a kliensek kéréseit, ellenőrzi a hitelesítő tokent, majd sorrendben meghívja a képvalidációt (Gemini), az osztályozást (a modellt kiszolgáló rétegen keresztül a ViT) és a magyarázatgenerálást, közben pedig gondoskodik az adatok tartós tárolásáról (Firebase). A kliensek így soha nem érik el közvetlenül sem a modellt, sem a nagy nyelvi modellt – minden külső hívás a backenden, hitelesített végpontok mögött történik, ami biztonsági szempontból is előnyös.


Két tervezési döntés emelendő ki. Egyrészt a modellt kiszolgáló réteg tudatosan le van választva a backendről: a ViT egy önálló, GPU-s környezetben fut, amelyet a backend az MCP-rétegen keresztül ér el; a GPU-háttér (gyakran változó) nyilvános címe futás közben átállítható, így annak újraindítása vagy cseréje nem igényli a backend módosítását. Másrészt a két mesterséges intelligencia komponens szerepe szigorúan elkülönül: a kvantitatív döntést a célzottan betanított ViT hozza, míg a nagy nyelvi modell (Gemini) szerepe a bemenet ellenőrzésére, az eredmény közérthető magyarázatára és a párbeszédre korlátozódik.

5.2.1. Egy elemzési kérés életciklusa

Egy kép elemzésének tipikus folyamata a következő lépésekből áll:

1. A kliens elküldi a képet és a hitelesítő tokent a backendnek.
2. A backend ellenőrzi a tokent, majd a képet a Gemini modellnek továbbítja *minőség- és relevanciaellenőrzésre*. Ha a kép nem értékelhető (pl. nem bőrelváltozás, túl távoli, életlen vagy több léziót tartalmaz), a folyamat itt megszakad, és a felhasználó célzott visszajelzést kap.
3. Megfelelő kép esetén a backend feltölti a képet a felhasználó tárhelyére (Firebase Storage), majd az MCP-rétegen keresztül lefuttatja a ViT-osztályozást.
4. A backend létrehozza vagy frissíti a munkamenet rekordját a Firestore adatbázisban.
5. A backend a klasszifikációs eredményt belefoglalja a Gemini számára összeállított utasításba, és a magyarázatot **token-szintű adatfolyamként** (SSE) küldi vissza a kliensnek.

A folyamat teljes lefutását a 5.3. ábra szekvenciadiagramja szemlélteti.



5.3. ábra. Egy elemzési kérés (/analyze) szekvenciadiagramja: a kliens, a backend, a Gemini, az MCP-szerver, a ViT és a Firebase interakciói. Az elágazás (*alt*) az értékelhetetlen kép esetét, a ciklus (*loop*) a token-szintű (SSE) válasz továbbítását jelöli.

A folyamat két eleme érdemel külön figyelmet. A Gemini-alapú *előzetes képvalidáció* kapuként működik: az értékelhetetlen felvételeket még a számításigényesebb osztályozás előtt kiszűri, csökkentve a felesleges erőforrás-használatot és annak kockázatát, hogy a felhasználó értelmezhetetlen képre kapjon megtévesztő eredményt. A magyarázat *token-szintű, szerver-küldött eseményekkel* (SSE) történő visszaküldése pedig azt biztosítja, hogy a felhasználó ne egy hosszú várakozás után, hanem fokozatosan, a generálással egyidejűleg kapja meg a választ.

5.3. A modellt kiszolgáló komponens: MCP-szerver

A betanított ViT modell a backendtől elkülönített, GPU-val rendelkező környezetben (Google Colab) fut, és HTTP-végponton fogadja a klasszifikációs kéréseket. A backend és a modellszolgáló közötti kommunikációt egy MCP- (Model Context Protocol) szerver [32] közvetíti, amely a backendből indított alfolyamatként, szabványos be- és kimeneti (stdio) csatornán, JSON-RPC 2.0 üzenetekkel [33] kommunikál. A szerver egyetlen eszközt (tool) tesz közzé, a `classify_lesion` függvényt; egy klasszifikációs kérés üzenetformátuma például:

```
{"jsonrpc": "2.0", "id": 1, "method": "tools/call",  
  "params": {"name": "classify_lesion",  
             "arguments": {"image_base64": "..."}}}
```

Az MCP-szerver a kapott, base64 kódolású képet továbbítja a GPU-n futó modell `/classify` végpontjának, és a választ – a címkét, a konfidenciát és az osztályonkénti pontszámokat – adja vissza a backendnek. A megoldás egyik kulcseleme egy `update_model_url` metódus, amely lehetővé teszi a modellszolgáló címének **futás közbeni** módosítását: mivel a GPU-háttér újraindításakor a nyilvános cím (alagút) megváltozik, a mechanizmus révén a backend új cím esetén sem igényel újraindítást. A modellt kiszolgáló réteg ilyen módon történő leválasztása lehetővé teszi, hogy a GPU-háttér bármikor újraindítható vagy lecserélhető legyen anélkül, hogy a backend kódját módosítani kellene.

5.4. A backend

A rendszer két backendet tartalmaz, amelyek a két klienst szolgálják ki, de azonos belső felépítést követnek. A mobil kliens egy **Flask** [37] alapú szerveret, a webes felület pedig egy **FastAPI** [38] alapú szerveret használ. Mindkét backend ugyanazt az MCP-klienst, ugyanazt a Gemini-integrációt és ugyanazokat a Firebase-szolgáltatásokat használja. A FastAPI aszinkron működése a webes streaminghez, a Flask egyszerűsége pedig a mobil végpontok kiszolgálásához bizonyult kényelmesnek.

A két szerver egy közös belső magra épül: ugyanazokat a modulokat használják a modellszolgáló elérésére (MCP-kliens), a Gemini-integrációra és a Firebase-műveletekre. Így a kétféle kiszolgálás viselkedése következetes marad, és az üzleti logika nem duplikálódik a két kódrendszerben – a két

backend gyakorlatilag csak a webes keretrendszerben és a kérés-/válaszkezelés módjában (szinkron, illetve aszinkron) tér el.

5.4.1. Végpontok

A webes (FastAPI) backend főbb végpontjait a 5.1. táblázat foglalja össze; a mobil (Flask) backend ezekkel funkcionálisan egyenértékű végpontokat biztosít.

5.1. táblázat. A webes backend (FastAPI) főbb végpontjai.

Metódus	Útvonal	Funkció
POST	/analyze	Kép elemzése (validálás, osztályozás, magyarázat)
POST	/chat	Utólagos kérdés (kép nélkül), párbeszéd
GET	/history/{id}	Egy korábbi munkamenet lekérése
GET	/sessions	A felhasználó munkameneiteinek listája
PUT	/model-url	A modellkiszolgáló címének frissítése
GET	/health	Állapotellenőrzés

A végpontok REST-elvek és állapotmentesek: minden kérés önállóan hordozza a hitelesítő token-t, a munkamenet állapotát pedig nem a szerver memóriája, hanem a Firestore tárolja. Ez egyszerűsíti a kiszolgálást, és megkönnyíti a backend esetleges vízszintes skálázását.

5.4.2. A Gemini integrációja és a képvalidáció

A nagy nyelvi modell (Gemini 2.5 Flash) a rendszerben három feladatot lát el. Az **elsődleges szűrés** során a feltöltött képet egy rögzített utasítással értékeli, amely egyetlen kódot kér vissza: OK (értékelhető), NOT_SKIN, TOO_FAR, MULTIPLE, BLURRY vagy NOT_ASSESSABLE. Ha a kód nem OK, a felhasználó a hibának megfelelő, célzott útmutatást kap (például: tartsa közelebb a kamerát, vagy fényképezzen egyetlen léziót). A **magyarázatgenerálás** során a Gemini a ViT klasszifikációs eredményét beépítve, az ABCDE-szabály szerint értelmezi az elváltozást, közérthető nyelven. Végül a Gemini kezeli a felhasználó **utólagos kérdéseit** is, a beszélgetés előzményeinek figyelembevételével. Ez a munkamegosztás tudatos tervezési döntés: a kvantitatív osztályozást a célzottan betanított ViT

végzi, a nyelvi modell pedig az erősségeire – a közérthető magyarázatra és a párbeszédre – összpontosít.

5.4.3. Token-szintű adatfolyam (SSE)

A reszponzív felhasználói élmény érdekében a Gemini válaszait nem egyben, hanem token-szintű adatfolyamként továbbítjuk a kliensnek, szerver-küldött események (Server-Sent Events) formájában [31]. Az adatfolyam egyes eseményei egy-egy szövegdarabot tartalmaznak, a lezárást pedig egy különleges jelző jelzi:

```
data: {"session_id": "...", "image_url": "...", "classification": {...}}
data: {"token": "Az elváltozás "}
data: {"token": "aszimmetrikus, ..."}
data: [DONE]
```

Így a felhasználó a szöveget a generálással egyidejűleg, folyamatosan látja megjelenni. Az első adatfolyam-esemény a munkamenet metaadatait (azonosító, feltöltött kép URL-je, klasszifikáció) hordozza, így a kliens már a szöveges válasz előtt frissítheti a felületet.

5.5. A mobilalkalmazás

A mobil kliens natív Android alkalmazás, Kotlin nyelven, az MVVM (Model–View–ViewModel) mintát követve. Indításkor egy bejelentkező képernyő (LoginActivity) fogadja a felhasználót, ahol Google-fiókkal jelentkezhet be; sikeres hitelesítés után a fő képernyőre (MainActivity) jut.

A fő képernyő chat-alapú felületet biztosít: a felhasználó a kamerával fényképet készíthet, vagy a galériából választhat képet, majd szöveges üzenettel együtt elküldheti azt elemzésre. A beérkező AI-válaszokat a felület token-szintű adatfolyamként, folyamatosan jeleníti meg, a klasszifikáció eredményét pedig egy színkódolt jelvény (jóindulatú / rosszindulatú) emeli ki. A jobb felső sarokban elérhető menü három funkciót kínál: új beszélgetés indítása (*New Chat*), az alkalmazás ismertetője (*About*) és a kijelentkezés (*Sign out*).

Az MVVM-minta szétválasztja a felületet és az állapotkezelést, ami egy adatfolyam-alapú, hosszan futó interakciónál – a token-szintű válaszok fokozatos megjelenítésénél – különösen előnyös. A felület a klasszifikáció eredményét tudatosan *kockázati jelzésként*, nem diagnózisként jeleníti meg, összhangban a rendszer tájékoztató jellegével.

5.5.1. Kameramodul és makrófelvétel

A bőrelváltozások fényképezéséhez a közeli (makró) fókusz elengedhetetlen. Az alkalmazás ezért egy dedikált CameraActivity osztályt használ, amely a CameraX könyvtárra épül. A modul a CameraManager segítségével felsorolja az eszköz hátsó kameráit, és a legkisebb fókusz távolságot támogató kamerát választja ki, lehetővé téve az elváltozás éles, közeli felvételét; a kép rögzítése a legjobb minőséget célzó módban történik. Így az alkalmazás a makró lencsével rendelkező készülékeken is kihasználja azok közelfókuszáló képességét.

5.5.2. Hálózati réteg

Az alkalmazás hálózati rétege az OkHttp és a Retrofit könyvtárakra épül. A streaming (SSE) válaszokat egy Kotlin Flow kezeli, az állapotot pedig egy ChatViewModel tartja karban, így az adatfolyam a képernyő-forgatást is túléli. Minden kéréshez egy elfogó (AuthInterceptor) automatikusan hozzáfűzi a felhasználó Firebase azonosítótokenjét. A backend címét egy beállítási réteg (NetworkConfig) tárolja a SharedPreferences-ben, amely a fordításkor beállított alapértelmezett címről indul – ez teszi lehetővé, hogy az alkalmazás ott keresse a backendet, ahol az ténylegesen elérhető.

5.6. A webes felület

A webes felület egy egyoldalas, sötét témájú alkalmazás, amely a FastAPI backend által kiszolgált sablonra épül. A felület a Firebase JavaScript SDK-t használja a Google-alapú bejelentkezéshez: amíg a felhasználó nincs bejelentkezve, egy bejelentkező réteg takarja a felületet, sikeres hitelesítés után pedig megjelenik a chat-felület. Minden, a backendhez intézett kérés tartalmazza a felhasználó hitelesítő tokenjét. A felületen egy beépített, lapváltás nélküli ismertető (About) ablak érhető el,

amely megőrzi a beszélgetés addigi tartalmát; kijelentkezéskor a felület a helyi állapotot (üzenetek, munkamenet-azonosító) is törli. A token-szintű válaszokat a böngésző a szerver-küldött események feldolgozásával jeleníti meg fokozatosan.

A webes kliens szándékosan keretrendszer nélküli (sima HTML, CSS és JavaScript): ez az egyszerű, build-lépést nem igénylő felépítés elegendő a chat-alapú felülethez, és a FastAPI által kiszolgált egyetlen sablonból közvetlenül futtatható. Funkcionálisan a webes és a mobil kliens ugyanazt a folyamatot kínálja, így a felhasználó a platformtól függetlenül azonos élményt kap.

5.7. Hitelesítés és felhőalapú adattárolás

A rendszer a Firebase szolgáltatásait [39] használja a hitelesítéshez és az adattároláshoz.

5.7.1. Hitelesítés

A bejelentkezés mindkét platformon Google-fiókkal, a Firebase Authentication segítségével történik. A kliens a sikeres bejelentkezés után egy azonosítótokent (ID token) kap, amelyet minden backend-kéréshez mellékel az Authorization fejlécben. A backend e tokent szerveroldalon ellenőrzi a Firebase Admin SDK segítségével, és a kérésből kinyeri a felhasználó egyedi azonosítóját (uid) és e-mail-címét; érvénytelen vagy hiányzó token esetén a kérést elutasítja.

5.7.2. Adatbázis és fájl tárolás

A munkameneteket a Firestore adatbázis tárolja, munkamenetenként egy dokumentumban, amely tartalmazza a tulajdonos azonosítóját és e-mail-címét, a klasszifikáció eredményét, a feltöltött kép azonosítóját és a beszélgetés üzeneteit. A dokumentum szerkezete vázlatosan:

```
sessions/{session_id}
```

user_id	: a tulajdonos Firebase-azonosítója
user_email	: a tulajdonos e-mail-címe
created_at	: létrehozás időbélyege
source	: "web" vagy "android"


```
image_id      : a feltöltött kép azonosítója
classification : {label, confidence, all_scores}
messages      : [{role, text, timestamp}, ...]
```

A feltöltött képeket a Firebase Storage tárolja, **felhasználónként elkülönített** útvonalon: `users/{uid}/lesions/{image_id}.jpg`. Így a képek a feltöltő felhasználó fiókjához kötődnek, és a munkamenetek listázásakor a backend a tulajdonos azonosítója szerint szűr, biztosítva, hogy minden felhasználó kizárólag a saját adatait érje el.

5.8. Hálózati robusztusság és hibatűrés

Mivel a rendszer több, egymástól független szolgáltatásra támaszkodik – és a modellt kiszolgáló GPU-háttér címe is változhat –, a hálózati hibatűrés kiemelt tervezési szempont volt. A megvalósított mechanizmusok:

- **Újrapróbálkozás exponenciális visszalépéssel.** A REST-hívásokhoz egy OkHttp-elfogó (interceptor), az SSE-adatfolyamhoz pedig a Kotlin Flow `retryWhen` operátora biztosít automatikus újrapróbálkozást átmeneti hálózati hiba esetén.
- **Az MCP-kliens önjavítása.** A backend MCP-kliense a sikertelen hívásokat többször újrapróbálja, és szükség esetén újraindítja a modellt kiszolgáló alfolyamatot.
- **Dinamikus címkezelés.** A modellkiszolgáló címe futás közben frissíthető (`update_model_url`, illetve a `/model-url` végpont), a backend címe pedig a kliensoldali beállításokban módosítható, így a rendszer alkalmazkodik a változó nyilvános címekhez.

5.9. Biztonsági megfontolások

A rendszer a titkos kulcsokat (a Gemini API-kulcsot és a Firebase hozzáférési adatokat) környezeti változókból, futásidőben tölti be, és **soha nem tárolja a forráskódban**; e fájlokat a verziókezelés is kizárja. A backend minden védett végponton ellenőrzi a Firebase azonosítótokent, így a klasszifikációs és párbeszéd-funkciók kizárólag hitelesített felhasználók számára érhetők el. A felhasználói adatok

– a feltöltött képek és a munkamenetek – felhasználónként elkülönítve tárolódnak, így egy felhasználó nem férhet hozzá más adataihoz.

Hangsúlyozandó továbbá, hogy a rendszer kialakítása tudatosan **tájékoztató jellegű**: a klasszifikációt egy célzottan betanított képi osztályozó modell végzi, míg a nagy nyelvi modell szerepe a magyarázatra és a párbeszédre korlátozódik. A rendszer nem helyettesíti a szakorvosi diagnózist, hanem szűrőeszközként segíti a felhasználót a dermatológiai konzultáció szükségességének megítélésében.

6. fejezet

Összefoglalás és jövőbeli munka

6.1. A dolgozat eredményeinek összegzése

A dolgozatban egy végponttól végpontig megvalósított, AI-alapú bőrelváltozás-elemző rendszert (DermAI) terveztünk és valósítottunk meg, amely a korai bőrrákszűrést egy okostelefonon és webböngészőben egyaránt elérhető eszközzel támogatja. A munka két, egymást kiegészítő pillérre épült.

A **kutatási rész** egy Vision Transformer modellt tanított be – a transfertanulás elvén, ImageNet-előtanítás után finomhangolva – az ISIC 2024 adathalmazon a bőrelváltozások jó-indulatú/rosszindulatú osztályozására, megfelelő figyelmet fordítva az adathalmaz rendkívül erős osztály-egyensúlytalanságára (súlyozott mintavételezés, fókuszvesztés, kétfázisú tanítás). A modellt három viszonyítási alappal vetettük össze: egy azonos feltételek mellett betanított ResNet-18 konvolúciós hálózattal (az architektúra hatásának izolálására), az EVA02 versenymodellel és egy zero-shot Gemini nagy nyelvi modellel. A kiértékelés a hivatalos ISIC 2024 részleges AUC metrikán, két klinikailag értelmezhető működési ponton, valamint statisztikai szignifikancia-vizsgálattal (DeLong-teszt, konfidencia-intervallumok) és kalibrációs elemzéssel (Brier-pontszám) történt.

A finomhangolt ViT-Base modell a teszhalmazon AUC 0,939-et és pAUC 0,159-et ért el, és minden mutatóban érdemben felülmúlta a ResNet-18 konvolúciós alapot (AUC 0,876, pAUC 0,122) – különösen a magas érzékenységű tartományban, ahol azonos érzékenység mellett lényegesen jobb specificitást nyújtott. A zero-shot Gemini modell jelentősen elmaradt (AUC 0,740; a ViT-tel szem-

beni különbség DeLong-tesztrel $p < 0,001$). A ViT egyúttal gyakorlatilag elérte az EVA02 szintjét is (pAUC 0,158), ami a saját modell versenyképességét igazolja.

A **mérnöki rész** a betanított modellt egy teljes, működő alkalmazássá egészítette ki: natív Android kliens, webes felület, két backend (Flask, illetve FastAPI), a modellt kiszolgáló MCP-réteg, valamint a Gemini nagy nyelvi modellre épülő képvalidáció, magyarázatgenerálás és párbeszéd. A rendszer a felhasználói adatokat hitelesített hozzáférés mögött, felhasználónként elkülönítve tárolja (Firebase), a token-szintű válaszközvetítést szerver-küldött eseményekkel valósítja meg, és több szintű hálózati hibatűréssel alkalmazkodik a változó környezethez.

6.2. Korlátok

Az eredmények értelmezésekor több korlátot figyelembe kell venni:

- **Kevés pozitív eset.** Az ISIC 2024 adathalmazban mindössze 393 rosszindulatú eset szerepel, a teszhalmazban 59. Ez a metrikák – különösen az érzékenység és a pAUC – becslését érzékenyíti a mintavételi zajra, amit a megadott konfidencia-intervallumok tükröznek.
- **Alacsony pozitív prediktív érték.** Az extrém, $\sim 1:1000$ arányú osztály-egyensúlytalanság miatt a pozitív prediktív érték még jó specificitás mellett is alacsony marad, ami a hamis pozitívak nagy számával jár. Szűrőeszközként ez elfogadható (a cél a rosszindulatú esetek kiszűrése), de a felhasználó tájékoztatásánál figyelembe veendő: a pozitív kimenet kockázati jelzés, nem diagnózis.
- **Kizárólag képi bemenet.** A modell csak a képet használja; az ISIC 2024 verseny tapasztalata szerint a klinikai metaadatok bevonása érdemben javíthatja a teljesítményt.
- **Adathalmaz-jellegű torzítások.** A 3D-TBP felvételek nem fedik le a hétköznapi okostelefonos fényképezés teljes változatosságát, és a populációs reprezentáció (például a bőrtónusok eloszlása) korlátozott lehet, ami az általánosíthatóságot befolyásolja; a teszhalmazon mért teljesítmény ezért nem feltétlenül egyezik a valós, otthoni okostelefonos használatban elérhetővel.

- **Gyenge valószínűségi kalibráció.** A kimeneti valószínűségek Brier-pontszáma elmarad az ideálistól, ami a kalibráció utólagos javítását indokolja.
- **Tájékoztató jelleg.** A rendszer nem klinikai diagnosztikai eszköz; kimenete nem helyettesíti a szakorvosi vizsgálatot.

6.3. Jövőbeli fejlesztési irányok

A dolgozat eredményei több irányban is folytathatók:

- **Multimodális fúzió.** A képi modell és a klinikai metaadatok együttes felhasználása (például gradiens-alapú döntésifa-együttessel kombinálva), az ISIC 2024 győztes megoldásainak mintájára, várhatóan tovább javítaná a teljesítményt.
- **Kalibráció és bizonytalanságbecslés.** A kimeneti valószínűségek utólagos kalibrálása (például hőmérséklet-skálázással) és a predikciós bizonytalanság becslése növelné a klinikai megbízhatóságot.
- **Magasabb felbontás.** A bemeneti felbontás növelése (a ViT 224×224 -éről az EVA02 336×336 -os szintjére) az összevetés alapján további javulást hozhat, a számítási költség növekedése árán.
- **Robusztusság és méltányosság.** Sokszínűbb – különböző bőrtónusokat és felvételi körülményeket lefedő – adathalmazokon történő tanítás és kiértékelés csökkentené a populációk közötti teljesítménykülönbségeket.
- **Magyarázhatóság.** A figyelmi térképek vagy más vizuális magyarázó technikák integrálása átláthatóbbá tenné a modell döntéseit a felhasználó és a szakorvos számára.
- **Klinikai validáció.** A rendszer valós környezetben, prospektív vizsgálatban történő értékelése elengedhetetlen a tényleges klinikai hasznosság igazolásához.

Összességében a dolgozat azt mutatta meg, hogy egy modern, figyelem-alapú képi modell és egy nagy nyelvi modell összehangolt alkalmazásával egy hozzáférhető, felhasználóbarát bőrrákszűrő rendszer építhető, amely – a fenti korlátok tudatában – értékes első lépés lehet a korai felismerés támogatásában.

Irodalomjegyzék

- [1] A. Esteva, B. Kuprel, R. A. Novoa, J. Ko, S. M. Swetter, H. M. Blau, and S. Thrun, „Dermatologist-level classification of skin cancer with deep neural networks,” *Nature*, vol. 542, no. 7639, pp. 115–118, 2017.
- [2] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, *et al.*, „An image is worth 16x16 words: Transformers for image recognition at scale,” in *International Conference on Learning Representations*, 2021.
- [3] ISIC Archive, „ISIC 2024 – skin cancer detection with 3D-TBP.” <https://www.kaggle.com/competitions/isic-2024-challenge/>, 2024. Kaggle verseny.
- [4] International Agency for Research on Cancer, „Melanoma of skin — GLOBOCAN 2022.” Global Cancer Observatory, World Health Organization, 2024. <https://gco.iarc.who.int/media/globocan/factsheets/cancers/16-melanoma-of-skin-fact-sheet.pdf>.
- [5] National Cancer Institute, „Cancer stat facts: Melanoma of the skin.” Surveillance, Epidemiology, and End Results (SEER) Program, 2024. <https://seer.cancer.gov/statfacts/html/melan.html>.
- [6] C. Garbe, T. Amaral, K. Peris, A. Hauschild, P. Arenberger, *et al.*, „European consensus-based interdisciplinary guideline for melanoma. Part 1: Diagnostics: Update 2022,” *European Journal of Cancer*, vol. 170, pp. 236–255, 2022.
- [7] N. R. Abbasi, H. M. Shaw, D. S. Rigel, R. J. Friedman, W. H. McCarthy, I. Osman, A. W. Kopf, and D. Polsky, „Early diagnosis of cutaneous melanoma: revisiting the ABCD criteria,” *JAMA*, vol. 292, no. 22, pp. 2771–2776, 2004.

- [8] C. Massone, R. Hofmann-Wellenhof, V. Ahlgrim-Siess, G. Gabler, C. Ebner, and H. P. Soyer, „Melanoma screening with cellular phones,” *PLoS ONE*, vol. 2, no. 5, p. e483, 2007. <https://doi.org/10.1371/journal.pone.0000483>.
- [9] M. A. Kassem, K. M. Hosny, R. Damasevicius, and M. M. Eltoukhy, „Machine learning and deep learning methods for skin lesion classification and diagnosis: a systematic review,” *Diagnostics*, vol. 11, no. 8, 2021.
- [10] H. A. Haenssle, C. Fink, R. Schneiderbauer, F. Toberer, T. Buhl, A. Blum, A. Kalloo, A. B. H. Hassen, L. Thomas, A. Enk, *et al.*, „Man against machine: diagnostic performance of a deep learning convolutional neural network for dermoscopic melanoma recognition in comparison to 58 dermatologists,” *Annals of Oncology*, vol. 29, no. 8, pp. 1836–1842, 2018.
- [11] T. J. Brinker, A. Hekler, A. H. Enk, J. Klode, A. Hauschild, C. Berking, B. Schilling, S. Haferkamp, D. Schadendorf, M. Schlaak, *et al.*, „Deep neural networks are superior to dermatologists in melanoma image classification,” *European Journal of Cancer*, vol. 119, pp. 11–17, 2019.
- [12] O. Russakovsky, J. Deng, H. Su, J. Krause, S. Satheesh, S. Ma, Z. Huang, A. Karpathy, A. Khosla, M. Bernstein, A. C. Berg, and L. Fei-Fei, „ImageNet large scale visual recognition challenge,” *International Journal of Computer Vision*, vol. 115, no. 3, pp. 211–252, 2015.
- [13] K. He, X. Zhang, S. Ren, and J. Sun, „Deep residual learning for image recognition,” in *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 770–778, 2016.
- [14] M. Tan and Q. Le, „EfficientNet: Rethinking model scaling for convolutional neural networks,” in *International Conference on Machine Learning*, pp. 6105–6114, PMLR, 2019.
- [15] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, „Attention is all you need,” *Advances in Neural Information Processing Systems*, vol. 30, 2017.
- [16] G. H. Dagnaw, M. El Mouhtadi, and M. Mustapha, „Skin cancer classification using vision transformers and explainable artificial intelligence,” *Journal of Medical Artificial Intelligence*, vol. 7, 2024.

- [17] P. Tschandl, C. Rosendahl, and H. Kittler, „The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions,” *Scientific Data*, vol. 5, no. 1, pp. 1–9, 2018.
- [18] V. Rotemberg, N. Kurtansky, B. Betz-Stablein, L. Caffery, E. Chousakos, N. Codella, M. Combalia, S. Dusza, P. Guitera, D. Gutman, *et al.*, „A patient-centric dataset of images and metadata for identifying melanomas using clinical context,” *Scientific Data*, vol. 8, no. 1, p. 34, 2021.
- [19] Gemini Team, Google, „Gemini: A family of highly capable multimodal models.” arXiv preprint arXiv:2312.11805, 2023. <https://arxiv.org/abs/2312.11805>.
- [20] K. Cirone, M. Akrouf, L. Abid, and A. Oakley, „Assessing the utility of multimodal large language models (GPT-4 vision and large language and vision assistant) in identifying melanoma across different skin tones,” *JMIR Dermatology*, vol. 7, p. e55508, 2024.
- [21] J. Zhou, X. He, L. Sun, J. Xu, X. Chen, Y. Chu, L. Zhou, X. Liao, B. Zhang, S. Afvari, and X. Gao, „Pre-trained multimodal large language model enhances dermatological diagnosis using SkinGPT-4,” *Nature Communications*, vol. 15, p. 5649, 2024.
- [22] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. MIT Press, 2016. <http://www.deeplearningbook.org>.
- [23] D. P. Kingma and J. Ba, „Adam: A method for stochastic optimization,” in *International Conference on Learning Representations (ICLR)*, 2015.
- [24] I. Loshchilov and F. Hutter, „Decoupled weight decay regularization,” in *International Conference on Learning Representations (ICLR)*, 2019.
- [25] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, and R. Salakhutdinov, „Dropout: A simple way to prevent neural networks from overfitting,” *Journal of Machine Learning Research*, vol. 15, no. 56, pp. 1929–1958, 2014.

- [26] S. Ioffe and C. Szegedy, „Batch normalization: Accelerating deep network training by reducing internal covariate shift,” in *International Conference on Machine Learning (ICML)*, pp. 448–456, 2015.
- [27] M. Raghu, C. Zhang, J. Kleinberg, and S. Bengio, „Transfusion: Understanding transfer learning for medical imaging,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 32, 2019.
- [28] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, „Focal loss for dense object detection,” in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pp. 2980–2988, 2017.
- [29] C. Guo, G. Pleiss, Y. Sun, and K. Q. Weinberger, „On calibration of modern neural networks,” in *Proceedings of the 34th International Conference on Machine Learning (ICML)*, vol. 70, pp. 1321–1330, PMLR, 2017.
- [30] X. Sun and W. Xu, „Fast implementation of DeLong’s algorithm for comparing the areas under correlated receiver operating characteristic curves,” *IEEE Signal Processing Letters*, vol. 21, no. 11, pp. 1389–1393, 2014.
- [31] WHATWG, „HTML living standard — server-sent events,” 2024. <https://html.spec.whatwg.org/multipage/server-sent-events.html>.
- [32] Anthropic, „Model context protocol – specification.” Open standard, 2024. <https://modelcontextprotocol.io/specification>.
- [33] JSON-RPC Working Group, „JSON-RPC 2.0 specification,” 2013. <https://www.jsonrpc.org/specification>.
- [34] R. Wightman, „PyTorch image models (timm).” GitHub repository, 2019. <https://github.com/huggingface/pytorch-image-models>.
- [35] A. Paszke, S. Gross, F. Massa, A. Lerer, J. Bradbury, G. Chanan, T. Killeen, Z. Lin, N. Gimeshein, L. Antiga, *et al.*, „PyTorch: An imperative style, high-performance deep learning library,” in *Advances in Neural Information Processing Systems*, vol. 32, 2019.

- [36] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, *et al.*, „Scikit-learn: Machine learning in Python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [37] Pallets Projects, „Flask – web development, one drop at a time.” Dokumentáció, 2024. <https://flask.palletsprojects.com/>.
- [38] S. Ramírez, „FastAPI.” Dokumentáció, 2024. <https://fastapi.tiangolo.com/>.
- [39] Google, „Firebase documentation.” Dokumentáció, 2024. <https://firebase.google.com/docs>.

A. függelék

A mesterséges intelligencia használata

A dolgozat elkészítése során generatív mesterséges intelligencia eszközt (Anthropic Claude) **segéd-eszközként** vettem igénybe. A főbb felhasználási területek a következők voltak:

- a forráskód hibakeresése és egyes kódrészletek működésének tisztázása;
- az ábrák egy részét előállító matplotlib-szkriptek elkészítése (a sematikus diagramok és az eredmény-grafikonok);
- a L^AT_EX-dokumentum formázása és szerkesztése;
- a szöveg nyelvi és stilisztikai csiszolása (helyesírás, terminológiai következetesség);
- a szakirodalmi hivatkozások formai és tartalmi ellenőrzése;
- a kivonat angol és román nyelvű fordításának előkészítése.

Az eszköz által javasolt tartalmat a végleges változatba illesztés előtt minden esetben ellenőriztem.